

ТЕОРИЯ ИСКУССТВЕННЫХ НЕЙРОННЫХ СЕТЕЙ

Каганов Ю.Т.

к.т.н., доцент каф. ИУ-9

**«Теоретическая информатика и компьютерные
технологии»**

ЛЕКЦИЯ № 7

- 1. Эффективность численных методов оптимизации.**
- 2. Машинное обучение и минимизация эмпирического риска.**
- 3. Теорема Байеса.**
- 4. Регрессионный анализ и методы построения целевых функций.**

Эффективность численных методов ОПТИМИЗАЦИИ

В настоящее время не существует универсальных методов решения задач оптимизации.

Невозможно определить наилучший метод решения некоторой задачи $\mathcal{P}$. Однако возможно определить класс методов для определенного класса задач. Т.е. класс задач $\mathcal{F}$, где $\mathcal{P} \subset \mathcal{F}$ и $\mathcal{F}$ - выделенный класс задач. Обычно численные методы разрабатываются для решения многих однотипных задач с близкими характеристиками. Поэтому эффективность метода $\mathcal{M}$ на всем классе задач $\mathcal{F}$ можно считать естественной характеристикой его качества.

При этом следует учитывать, что метод $\mathcal{M}$ не имеет полной информации о решаемой задаче.

Теорема о «бесплатных завтраках»

- **Теорема Дэвида Волперта и Уильяма Макриди** о бесплатном обеде (иногда во множественном числе) “No Free Lunch” (NFL) появляется в 1997 году в "No Free Lunch Theorems for Optimization». Название отсылает к поговорке «Бесплатных завтраков не бывает», то есть нет простых путей к успеху.
- **Формулировка теоремы**

Если алгоритм хорошо работает над определенным классом задач, то он обязательно платит за это снижением производительности на множестве всех оставшихся задач.

Эффективность численных методов оптимизации

Заранее известная численному методу «часть» задачи $\mathcal{P}$ называется моделью решаемой задачи.

Обозначим модель решаемой задачи символом Σ . Обычно в модель включаются формулировка задачи, описание свойств функциональных компонент и т. д.

Для того чтобы распознать задачу $\mathcal{P}$ среди всех прочих задач из данного класса (и тем самым решить ее), численный метод должен уметь накапливать специфическую информацию о решаемой задаче. Этот процесс удобно описывать с помощью понятия оракула. Оракул $\mathcal{O}$ проще всего представить в виде некоторого устройства, которое отвечает на последовательные вопросы численного метода.

Эффективность численных методов оптимизации

Естественно определить эффективность метода $\mathcal{M}$ на паре $(\Sigma, \mathcal{O})$ как его эффективность на наихудшем представителе $\mathcal{P}_w$ из $(\Sigma, \mathcal{O})$. Заметим, что задача $\mathcal{P}_w$ может быть трудной только для этого конкретного метода $\mathcal{M}$

Эффективность метода $\mathcal{M}$ на задаче $\mathcal{P}$ определяется через общие вычислительные затраты метода $\mathcal{M}$, необходимые для того, чтобы решить задачу $\mathcal{P}$.

Решить задачу $\mathcal{P}$ означает найти ее приближенное решение с заранее заданной точностью $\varepsilon > 0$.

Введем обозначение $\mathcal{T}_\varepsilon$ для некоторого критерия остановки, способного оценить качество предлагаемого решения.

Эффективность численных методов оптимизации

Формальное определение класса решаемых задач

$$\mathcal{F} = (\Sigma, \mathcal{O}, \mathcal{T}_\varepsilon).$$

Для решения конкретной задачи $\mathcal{P} \in \mathcal{F}$ естественно применить некую *итеративную процедуру*. Именно в таком виде удобно записывать любой метод $\mathcal{M}$, работающий с оракулом $\mathcal{O}$.

Эффективность численных методов ОПТИМИЗАЦИИ

Общая итеративная схема

Вводные данные: начальная точка x_0 и требуемая точность $\varepsilon > 0$.

Настройка. Полагаем $k = 0$ и $I_{-1} = \emptyset$. Здесь k — это счетчик итераций, а I_k — это накапливаемая информационная модель решаемой задачи.

Основной цикл.

Шаг 1. Задаем вопрос оракулу $\mathcal{O}$ в точке x_k .

Шаг 2. Пересчитываем информационную модель: $I_k = I_{k-1} \cup (x_k, \mathcal{O}(x_k))$.

Шаг 3. Применяем правила метода $\mathcal{M}$ для анализа модели I_k и формируем точку x_{k+1} .

Шаг 4. Проверяем критерий остановки $\mathcal{T}_\varepsilon$. Если ответ положительный, то генерируем ответ $\bar{x}$. В противном случае полагаем $k := k + 1$ и переходим на шаг 1.

Эффективность численных методов оптимизации

Наиболее трудоемкими являются два шага. Первый — это обращение к оракулу $\mathcal{O}$ Шаг 1. Второй Шаг 3, на котором анализируется накопленная модель и формируется следующая тестовая точка.

Таким образом, можно ввести две меры сложности задачи $\mathcal{P}$ и для метода $\mathcal{M}$.

Аналитическая сложность. Это число обращений к оракулу, необходимое для решения задачи $\mathcal{P}$ с точностью ε .

Арифметическая сложность. Это общее число всех вычислений (включая как работу оракула, так и работу метода), необходимых для решения задачи $\mathcal{P}$ с точностью ε .

Эффективность численных методов оптимизации

В соответствии со степенью гладкости функциональной модели можно пользоваться разными типами оракулов.

- Оракул *нулевого порядка*: возвращает значение функции $f(x)$.
- Оракул *первого порядка*: возвращает значение функции $f(x)$ и ее градиент $f'(x)$.
- Оракул *второго порядка*: возвращает $f(x)$, ее градиент $f'(x)$ и матрицу гессиана $f''(x)$.

Мы рассмотрим применение этих оракулов в различных методах.

ОБУЧЕНИЕ МОДЕЛИ, ТЕОРЕМА БАЙЕСА И ТРАНСДУКЦИЯ

ОБУЧЕНИЕ МОДЕЛИ

Введем обозначения:

$\theta = \langle W, b \rangle$ — кортеж весов и порогов (соответствует параметрам модели).

$D = \langle X, Y \rangle$ — кортеж исходных данных (соответствует входным и выходным данным).

θ^* — параметры модели после окончания обучения (оптимальные параметры).

$L(\theta)$ — функция потерь в процессе обучения (целевая функция в процессе оптимизации).

Процесс оценивания θ по D называется *обучением модели*. Он составляет основное содержание машинного обучения. Основной способ получения оценок сводится к задаче оптимизации:

$\theta^* = \underset{\theta}{\operatorname{argmin}} L(\theta)$. При этом процесс оптимизации состоит в подборе таких $\theta(n+1) = \theta(n) + \Delta\theta(n)$, при которых $L(\theta(n+1)) \leq L(\theta(n))$.

Обучение модели и теорема Байенса

Обучение модели:

Пусть имеется некоторая модель (гипотеза, теория) - M , которая предварительно (априорно) получена из наблюдаемых исходных данных - D . Тогда для обучения этой модели M необходимо обеспечить соответствие этой модели новым данным D' .

Теорема Байеса:

$$P(M'|D') P(D') = P(M) P(D|M),$$

Откуда получаем формулу Байеса:

$$P(M'|D') = \frac{P(M) P(D|M)}{P(D')}.$$

Формула Байеса

Формула Байеса служит для вычисления распределения вероятностей возможных значений модели - M при наличии наблюдаемых данных — D .

$$P(M'|D') = \frac{P(M)P(D|M)}{P(D')}.$$

$P(M)$ — априорная вероятность, связанная со структурой модели.

$P(D|M)$ — априорная вероятность данных при заданной модели.

$P(D')$ — апостериорная вероятность данных.

$P(M'|D')$ — апостериорная вероятность модели при известных данных.

Задача познания состоит в том, чтобы максимизировать апостериорную вероятность $P(M'|D')$.

Трансдукция

$$P(M'|D') = \frac{P(M)P(D|M)}{P(D')}.$$

Эта формула имеет непосредственное отношение к процессу познания. Она носит итеративный характер. В этом случае соответствующие вероятности можно трактовать следующим образом:

$P(M)$ – переход от индуктивных к дедуктивным моделям (абдукция).

$P(D|M)$ – переход от формулировки модели к соответствию с данными (дедукция).


$P(D')$ – переход от гипотетических данных к экспериментальным (аддукция).

$P(M'|D')$ – переход от экспериментальных данных к построению новой модели (индукция).

Трансдукция

(“Сначала восходят к аксиомам, а затем спускаются к практике” Ф. Бэкон)

$$P(M'|D') = \frac{P(M)P(D|M)}{P(D')}.$$



ОБУЧЕНИЕ И ОЦЕНКА МАКСИМАЛЬНОГО ПРАВДОПОДОБИЯ (MLE)

Введем обозначения:

MLE (Maximum Likelihood Estimation) – оценка максимального правдоподобия определяется следующим образом:

$$\theta^* = \underset{\theta}{\operatorname{argmax}} p(D|\theta) \text{ или } \theta^* = \underset{\theta}{\operatorname{argmin}} \{-p(D|\theta)\}$$

Если учесть, что обучающие примеры независимо выбраны из одного и того же распределения, то правдоподобие принимает вид

$p(D|\theta) = \prod_{n=1}^N p(y_n|x_n, \theta)$ – это дает возможность при логарифмировании перейти от оператора произведения к оператору суммирования. Таким образом получаем

$$\log p(D|\theta) = \sum_{n=1}^N \log[p(y_n|x_n, \theta)].$$

Тогда задача состоит в максимизации $\theta^* = \underset{\theta}{\operatorname{argmax}} \sum_{n=1}^N \log p(y_n|x_n, \theta)$. Или, учитывая удобство минимизации запишем функцию с отрицательным знаком

$$\theta^* = \underset{\theta}{\operatorname{argmin}} \left(- \sum_{n=1}^N \log [p(y_n|x_n, \theta)]. \right)$$

ФУНКЦИЯ ПРАВДОПОДОБИЯ

Правдоподобие – это вероятность получения имеющихся наблюдений для заданных параметров модели. Пусть имеется n наблюдений $x_1, x_2, \dots, x_n$. Будем предполагать, что все наблюдения независимы и подчиняются одному и тому же нормальному распределению со средним μ и дисперсией σ^2 .

Тогда функция правдоподобия может быть выражена:

$$P(\text{данные/параметры модели}) = P(x_1, x_2, \dots, x_n / \mu, \sigma^2).$$

Поскольку все наблюдения независимы, то можно представить как факторизованную модель:

$$P(\text{данные/параметры модели}) = \prod_{i=1}^n P(x_i / \mu, \sigma^2).$$

Учитывая нормальность распределения запишем функцию правдоподобия:

$$P(\text{данные/параметры модели}) = \prod_{i=1}^n \frac{1}{\sigma\sqrt{2\pi}} e^{\frac{-(x_i - \mu)^2}{2\sigma^2}}.$$

МЕТОД МАКСИМАЛЬНОГО ПРАВДОПОДОБИЯ

Метод максимального правдоподобия – (maximum likelihood estimation, MLE) – это метод оценивания неизвестных параметров распределения или модели путем максимизации функции правдоподобия. Т.е. максимизации вероятности распределения данных при заданных параметрах модели.

Функцию правдоподобия можно представить в виде:

$$P(\text{данные/параметры})=L(\theta) = \prod_{i=1}^n P(x_i / \theta).$$

Чтобы максимизировать функцию вероятности $L(\theta)$, необходимо продифференцировать $L(\theta)$ по θ и приравнять 0. Более удобно максимизировать не саму функцию правдоподобия, а ее логарифм. Т.е. $\log L(\theta)$. Поскольку логарифм - монотонно возрастающая функция, то с ростом параметра θ будет максимизироваться и логарифм. С точки зрения математики производная от логарифма находится проще.

Поэтому можно записать: $\log L(\theta) = \sum_{i=1}^n \log(P(x_i / \theta))$. Для того, чтобы найти максимум следует $\log L(\theta)$ продифференцировать и приравнять нулю. Учитывая, что максимизация соответствует минимизации функции взятой с отрицательным знаком, получим

$$\theta^* = \text{Argmin}(-\log L(\theta))$$

МЕТОД МАКСИМАЛЬНОГО ПРАВДОПОДОБИЯ

В случае классификации можно использовать *схему Бернулли*, которая предполагает взаимоисключающие и исчерпывающие исходы экспериментов. При этом возможными исходами эксперимента по схеме Бернулли может быть «успех» или «неудача». Пусть p – вероятность успеха. Тогда, в силу того, что этими двумя событиями исчерпывается все выборочное пространство, вероятность неудачи равна $p - 1$. Будем считать, что успешному исходу соответствует значение $x = 1$, а неудачному - $x = 0$, Тогда вероятность успеха или неудачи можно выразить формулой

$$P(X = x) = f(x) = p^x(1 - p)^{(1-x)}$$

МЕТОД МАКСИМАЛЬНОГО ПРАВДОПОДОБИЯ

Для каждой точки данных $(y^i / x^i, \theta) - \text{Bernulli}(1, p)$, тогда для функции вероятности можно записать:

$$P(y^i / x^i, \theta) = f(x) = (1 - p_i)^{(1-y^i)},$$

где $p_i = \frac{1}{(1+e^{(-\theta^T x)})}$.

Перепишем функцию правдоподобия в виде $L = P(\text{данные} / \text{модель}) = P(D^1, D^2, \dots, D^m / \theta)$, где D^i представляет собой i - й обучающий пример (y^i / x^i) .

Исходя из допущения о независимости обучающих примеров, можно представить $L(\theta)$ в следующем факторизованном виде

$$L(\theta) = P(D^1, D^2, \dots, D^m / \theta) = \prod_{i=1}^m P(D^i / \theta).$$

Логарифмируя обе части этого равенства, преобразуем произведение вероятностей в сумму их логарифмов $\log L(\theta) = \sum_{i=1}^m \log P(D^i / \theta)$. Так как $P(D^i / \theta) = k P(y^i / x^i, \theta)$. В результате получаем $\log L(\theta) = \sum_{i=1}^m (\log k + y^i \log p_i + (1 - y^i) \log(1 - p_i))$. Учитывая эквивалентность максимизации и минимизации функций получим

$$\theta^* = \text{Argmin}(-\log L(\theta)), \text{ где } p_i = \frac{1}{(1+e^{(-\theta^T x)})}.$$

ЛИНЕЙНАЯ РЕГРЕССИЯ

Рассмотрим нормальное (гауссово) распределение:

$$N(y|W^T x + b; \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y-W^T x-b)^2}{2\sigma^2}\right)$$

В многомерном случае мы получим:

$$N(\mathbf{y}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{n/2}} \exp\left[-\frac{1}{2}(\mathbf{y} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{y} - \boldsymbol{\mu})\right],$$

где $\boldsymbol{\mu} = \mathbf{E}[\mathbf{y}] \in \mathbf{R}^n$ - вектор средних, а $\boldsymbol{\Sigma} = \text{Cov}[\mathbf{y}]$ – ковариационная матрица размера $n \times n$, определяются следующим образом $\text{Cov}[\mathbf{y}] = \mathbf{E}[(\mathbf{y} - \mathbf{E}[\mathbf{y}])(\mathbf{y} - \mathbf{E}[\mathbf{y}])^T]$. Что равно:

$$\text{Cov}[\mathbf{y}] = \begin{bmatrix} V[Y_1] & \text{Cov}[Y_1 Y_2] & \text{Cov}[Y_1 Y_n] \\ \text{Cov}[Y_2 Y_1] & V[Y_2] & \text{Cov}[Y_2 Y_n] \\ \text{Cov}[Y_n Y_1] & \text{Cov}[Y_n Y_2] & V[Y_n] \end{bmatrix}, \text{ где } \text{Cov}[Y_i Y_j] = \mathbf{E}[Y_i Y_j] - \mathbf{E}[Y_i] \mathbf{E}[Y_j], \text{ а } V[Y_j] = \text{Cov}[Y_i Y_i]$$

Расстояние Махаланобиса:

Если рассматривать логарифмическую вероятность в точке $\mathbf{y}$, то мы получим

$$\log p(\mathbf{y}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \left[-\frac{1}{2}(\mathbf{y} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{y} - \boldsymbol{\mu})\right] + \text{const.} \text{ Тогда расстояние Махаланобиса } \Delta \text{ между } \mathbf{y} \text{ и } \boldsymbol{\mu} \text{ выразим}$$
$$\Delta^2 = (\mathbf{y} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{y} - \boldsymbol{\mu}).$$

ЛИНЕЙНАЯ РЕГРЕССИЯ

Предположим, что имеется m выборок $(y^1 / x^1, y^2 / x^2, \dots, y^m / x^m)$. Можно вычислить функцию стоимости $J(\theta) = \sum_{i=1}^m (\theta^T x^i - y^i)^2$. Можно минимизировать эту функцию относительно θ , чтобы определить параметры модели. Таким образом можно записать

$$\theta^* = \text{Argmin} \sum_{i=1}^m (\theta^T x^i - y^i)^2.$$

Выразим вектор прогноза Y^p как $Y^p = X\theta$, а погрешность $e = X\theta - Y$. Тогда $J(\theta)$ можно выразить в виде квадрата l^2 нормы вектора невязки

$$\|e\|_2^2 = \|X\theta - Y\|_2^2 = (X\theta - Y)^T (X\theta - Y).$$

Можно записать вероятность для линейной регрессии следующим образом

$$p(y|x; \theta) = N(y|W^T x + b; \sigma^2), \text{ где } \theta = (W, b, \sigma^2)$$

Если дисперсия фиксирована и не зависит от исходных данных, то такая модель называется *гомоскедастической регрессией*.

Если дисперсия зависит от входных данных, то такая модель называется *гетероскедастической регрессией*. В линейной постановке получаем

$$p(y|x; \theta) = N(y|W^T x + b; \sigma^2(W_0^T x))$$

ЛИНЕЙНАЯ РЕГРЕССИЯ

Линейная регрессия соответствует модели

$$p(y|x; \theta) = N(y|W^T x + b; \sigma^2)$$

где $\theta = (W, \sigma^2)$. Будем считать, что σ^2 фиксировано. Задача состоит в определении W .

1) Определим **отрицательный логарифм правдоподобия NLL**:

$$NLL(W) = - \sum_{n=1}^N \log \left[\left(\frac{1}{2\pi\sigma^2} \right)^{\frac{1}{2}} \exp \left(-\frac{1}{2\sigma^2} (y_n - W^T x_n)^2 \right) \right].$$

2) Отбросив несущественные постоянные слагаемые, получим сумму квадратов невязок **RSS**.

$$RSS(W) = \sum_{n=1}^N (y_n - W^T x_n)^2 = \sum_{n=1}^N (r_n)^2, \text{ где } r_n - \text{невязка.}$$

3) Поделив $(r_n)^2$ на число примеров получим **среднеквадратическую ошибку MSE**.

$$MSE(W) = \frac{1}{N} RSS = \frac{1}{N} \sum_{n=1}^N (y_n - W^T x_n)^2.$$

4) Извлекая квадратный корень получим **корень из среднеквадратичной ошибки RMSE**

$$RMSE(W) = \sqrt{MSE(W)} = \sqrt{\frac{1}{N} \sum_{n=1}^N (y_n - W^T x_n)^2}$$

ЛИНЕЙНАЯ РЕГРЕССИЯ

Для вычисления *MLE* – оценки максимального правдоподобия можно минимизировать любую из предложенных оценок – *NLL, RSS, MSE, RMSE*. Во всех случаях результат будет один и тот же, поскольку целевая функция будет одной и той же .

Рассмотрим $RSS(W) = \sum_{n=1}^N (y_n - W^T x_n)^2 = \|xW - y\|_2^2 = (xW - y)^T (xW - y)$.

Для того, чтобы получить оптимальные значения

$$W_{MLE} = \text{Argmin} RSS(W) = (X^T X)^{-1} X^T y$$

Эта оценка обыкновенных наименьших квадратов (*OLS*) эквивалентна *MLE*

ДИВЕРГЕНЦИЯ КУЛЬБАКА-ЛЕЙБЛЕРА И ПЕРЕКРЕСТНАЯ ЭНТРОПИЯ

Понятие *расстояние (дивергенция) Кульбака-Лейблера* пришло из теории информации. Оно является мерой разницы между двумя вероятностями распределения Q и P . Будем считать распределение P – истинное распределение, Q – его приближение. Дивергенция Кульбака – Лейблера от распределения P до распределения Q обозначается $KL(P||Q)$ и определяется следующим образом

$$KL(P||Q) = \int \log \frac{dP}{dQ} dP, \text{ где интеграл берется по всему пространству исходов, общих для } P \text{ и } Q.$$

Рассмотрим следующие случаи:

- Q и P – дискретные случайные величины, заданные на дискретном множестве

$$X = \{x_1, \dots, x_n\}. \text{ Расстояние Кульбака – Лейблера } KL(P||Q) = \sum_i p(x_i) \log \frac{p(x_i)}{q(x_i)}.$$

- Q и P – непрерывные случайные величины в пространстве R^d . Расстояние

$$KL(P||Q) = \int_{R^d} p(x) \log \frac{p(x)}{q(x)}.$$

Дивергенция Кульбака-Лейблера дает возможность перейти к перекрестной энтропии (cross-entropy)

$$H(p, q) = E_p[-\log(q)] = - \sum_x p(x) \log(q(x)).$$