

# **ТЕОРИЯ ИСКУССТВЕННЫХ НЕЙРОННЫХ СЕТЕЙ**

**Каганов Ю.Т.**

**к.т.н., доцент каф. ИУ-9**

**«Теоретическая информатика и компьютерные  
технологии»**

## **ЛЕКЦИЯ № 9**

- 1. Эффективность численных методов оптимизации**
- 2. Машинное обучение и минимизация эмпирического риска.**
- 3. Теорема Байеса.**
- 4. Регрессионный анализ и методы построения целевых функций.**

# Эффективность численных методов ОПТИМИЗАЦИИ

**В настоящее время не существует универсальных методов решения задач оптимизации.**

Невозможно определить наилучший метод решения некоторой задачи  $\mathcal{P}$ . Однако возможно определить класс методов для определенного класса задач. Т.е. класс задач  $\mathcal{F}$ , где  $\mathcal{P} \subset \mathcal{F}$  и  $\mathcal{F}$  - выделенный класс задач. Обычно численные методы разрабатываются для решения многих однотипных задач с близкими характеристиками. Поэтому эффективность метода  $\mathcal{M}$  на всем классе задач  $\mathcal{F}$  можно считать естественной характеристикой его качества.

При этом следует учитывать, что метод  $\mathcal{M}$  не имеет полной информации о решаемой задаче.

# Теорема о «бесплатных завтраках»

- **Теорема Дэвида Волперта и Уильяма Макриди** о бесплатном обеде (иногда во множественном числе) “No Free Lunch” (NFL) появляется в 1997 году в "No Free Lunch Theorems for Optimization». Название отсылает к поговорке «Бесплатных завтраков не бывает», то есть нет простых путей к успеху.
- **Формулировка теоремы**

Если алгоритм хорошо работает над определенным классом задач, то он обязательно платит за это снижением производительности на множестве всех оставшихся задач.

# Эффективность численных методов оптимизации

Заранее известная численному методу «часть» задачи  $\mathcal{P}$  называется моделью решаемой задачи.

Обозначим модель решаемой задачи символом  $\Sigma$ . Обычно в модель включаются формулировка задачи, описание свойств функциональных компонент и т. д.

Для того чтобы распознать задачу  $\mathcal{P}$  среди всех прочих задач из данного класса (и тем самым решить ее), численный метод должен уметь накапливать специфическую информацию о решаемой задаче. Этот процесс удобно описывать с помощью понятия оракула. Оракул  $\mathcal{O}$  проще всего представить в виде некоторого устройства, которое отвечает на последовательные вопросы численного метода.

# Эффективность численных методов оптимизации

Естественно определить эффективность метода  $\mathcal{M}$  на паре  $(\Sigma, \mathcal{O})$  как его эффективность на наихудшем представителе  $\mathcal{P}_w$  из  $(\Sigma, \mathcal{O})$ . Заметим, что задача  $\mathcal{P}_w$  может быть трудной только для этого конкретного метода  $\mathcal{M}$

*Эффективность метода  $\mathcal{M}$  на задаче  $\mathcal{P}$  определяется через общие вычислительные затраты метода  $\mathcal{M}$ , необходимые для того, чтобы решить задачу  $\mathcal{P}$ .*

*Решить задачу  $\mathcal{P}$  означает найти ее приближенное решение с заранее заданной точностью  $\varepsilon > 0$ .*

Введем обозначение  $\mathcal{T}_\varepsilon$  для некоторого критерия остановки, способного оценить качество предлагаемого решения.

# Эффективность численных методов оптимизации

Формальное определение класса решаемых задач

$$\mathcal{F} = (\Sigma, \mathcal{O}, \mathcal{T}_\varepsilon).$$

Для решения конкретной задачи  $\mathcal{P} \in \mathcal{F}$  естественно применить некую *итеративную процедуру*. Именно в таком виде удобно записывать любой метод  $\mathcal{M}$ , работающий с оракулом  $\mathcal{O}$ .

# Эффективность численных методов ОПТИМИЗАЦИИ

## Общая итеративная схема

**Вводные данные:** начальная точка  $x_0$  и требуемая точность  $\varepsilon > 0$ .

**Настройка.** Полагаем  $k = 0$  и  $I_{-1} = \emptyset$ . Здесь  $k$  — это счетчик итераций, а  $I_k$  — это накапливаемая информационная модель решаемой задачи.

**Основной цикл.**

**Шаг 1.** Задаем вопрос оракулу  $\mathcal{O}$  в точке  $x_k$ .

**Шаг 2.** Пересчитываем информационную модель:  $I_k = I_{k-1} \cup (x_k, \mathcal{O}(x_k))$ .

**Шаг 3.** Применяем правила метода  $\mathcal{M}$  для анализа модели  $I_k$  и формируем точку  $x_{k+1}$ .

**Шаг 4.** Проверяем критерий остановки  $\mathcal{T}_\varepsilon$ . Если ответ положительный, то генерируем ответ  $\bar{x}$ . В противном случае полагаем  $k := k + 1$  и переходим на шаг 1.

# Эффективность численных методов оптимизации

Наиболее трудоемкими являются два шага. Первый — это обращение к оракулу  $\mathcal{O}$  Шаг 1. Второй Шаг 3, на котором анализируется накопленная модель и формируется следующая тестовая точка.

Таким образом, можно ввести две меры сложности задачи  $\mathcal{P}$  и для метода  $\mathcal{M}$ .

**Аналитическая сложность.** Это число обращений к оракулу, необходимое для решения задачи  $\mathcal{P}$  с точностью  $\varepsilon$ .

**Арифметическая сложность.** Это общее число всех вычислений (включая как работу оракула, так и работу метода), необходимых для решения задачи  $\mathcal{P}$  с точностью  $\varepsilon$ .

# Эффективность численных методов оптимизации

В соответствии со степенью гладкости функциональной модели можно пользоваться разными типами оракулов.

- Оракул *нулевого порядка*: возвращает значение функции  $f(x)$ .
- Оракул *первого порядка*: возвращает значение функции  $f(x)$  и ее градиент  $f'(x)$ .
- Оракул *второго порядка*: возвращает  $f(x)$ , ее градиент  $f'(x)$  и матрицу гессиана  $f''(x)$ .

Мы рассмотрим применение этих оракулов в различных методах.

# **ОБУЧЕНИЕ МОДЕЛИ, ТЕОРЕМА БАЙЕСА И ТРАНСДУКЦИЯ**

# ОБУЧЕНИЕ МОДЕЛИ

**Введем обозначения:**

$\theta = \langle W, b \rangle$  — кортеж весов и порогов (соответствует параметрам модели).

$D = \langle X, Y \rangle$  — кортеж исходных данных (соответствует входным и выходным данным).

$\theta^*$  — параметры модели после окончания обучения (оптимальные параметры).

$L(\theta)$  — функция потерь в процессе обучения (целевая функция в процессе оптимизации).

Процесс оценивания  $\theta$  по  $D$  называется *обучением модели*. Он составляет основное содержание машинного обучения. Основной способ получения оценок сводится к задаче оптимизации:

$\theta^* = \underset{\theta}{\operatorname{argmin}} L(\theta)$ . При этом процесс оптимизации состоит в подборе таких  $\theta(n+1) = \theta(n) + \Delta\theta(n)$ , при которых  $L(\theta(n+1)) \leq L(\theta(n))$ .

# Обучение модели и теорема Байенса

## Обучение модели:

Пусть имеется некоторая модель (гипотеза, теория) -  $M$ , которая предварительно (априорно) получена из наблюдаемых исходных данных -  $D$ . Тогда для обучения этой модели  $M$  необходимо обеспечить соответствие этой модели новым данным  $D'$ .

## Теорема Байеса:

$$P(M'|D') P(D') = P(M) P(D|M),$$

Откуда получаем формулу Байеса:

$$P(M'|D') = \frac{P(M) P(D|M)}{P(D')}.$$

# Формула Байеса

Формула Байеса служит для вычисления распределения вероятностей возможных значений модели -  $M$  при наличии наблюдаемых данных —  $D$ .

$$P(M'|D') = \frac{P(M)P(D|M)}{P(D')}.$$

$P(M)$  — априорная вероятность, связанная со структурой модели.

$P(D|M)$  — априорная вероятность данных при заданной модели.

$P(D')$  — апостериорная вероятность данных.

$P(M'|D')$  — апостериорная вероятность модели при известных данных.

Задача познания состоит в том, чтобы максимизировать апостериорную вероятность  $P(M'|D')$ .

# Трансдукция

$$P(M'|D') = \frac{P(M)P(D|M)}{P(D')}.$$

Эта формула имеет непосредственное отношение к процессу познания. Она носит итеративный характер. В этом случае соответствующие вероятности можно трактовать следующим образом:

$P(M)$  – переход от индуктивных к дедуктивным моделям (абдукция).

$P(D|M)$  – переход от формулировки модели к соответствию с данными (дедукция).


$P(D')$  – переход от гипотетических данных к экспериментальным (аддукция).

$P(M'|D')$  – переход от экспериментальных данных к построению новой модели (индукция).

# Трансдукция

(“Сначала восходят к аксиомам, а затем спускаются к практике” Ф. Бэкон)

$$P(M'|D') = \frac{P(M)P(D|M)}{P(D')}.$$



# ОБУЧЕНИЕ И ОЦЕНКА МАКСИМАЛЬНОГО ПРАВДОПОДОБИЯ (MLE)

Введем обозначения:

**MLE (Maximum Likelihood Estimation)** – оценка максимального правдоподобия определяется следующим образом:

$$\theta^* = \underset{\theta}{\operatorname{argmax}} p(D|\theta) \text{ или } \theta^* = \underset{\theta}{\operatorname{argmin}} \{-p(D|\theta)\}$$

Если учесть, что обучающие примеры независимо выбраны из одного и того же распределения, то правдоподобие принимает вид

$p(D|\theta) = \prod_{n=1}^N p(y_n|x_n, \theta)$  – это дает возможность при логарифмировании перейти от оператора произведения к оператору суммирования. Таким образом получаем

$$\log p(D|\theta) = \sum_{n=1}^N \log[p(y_n|x_n, \theta)].$$

Тогда задача состоит в максимизации  $\theta^* = \underset{\theta}{\operatorname{argmax}} \sum_{n=1}^N \log p(y_n|x_n, \theta)$ . Или, учитывая удобство минимизации запишем функцию с отрицательным знаком

$$\theta^* = \underset{\theta}{\operatorname{argmin}} \left( - \sum_{n=1}^N \log [p(y_n|x_n, \theta)]. \right)$$

## ФУНКЦИЯ ПРАВДОПОДОБИЯ

**Правдоподобие** – это вероятность получения имеющихся наблюдений для заданных параметров модели. Пусть имеется  $n$  наблюдений  $x_1, x_2, \dots, x_n$ . Будем предполагать, что все наблюдения независимы и подчиняются одному и тому же нормальному распределению со средним  $\mu$  и дисперсией  $\sigma^2$ .

Тогда функция правдоподобия может быть выражена:

$$P(\text{данные/параметры модели}) = P(x_1, x_2, \dots, x_n / \mu, \sigma^2).$$

Поскольку все наблюдения независимы, то можно представить как факторизованную модель:

$$P(\text{данные/параметры модели}) = \prod_{i=1}^n P(x_i / \mu, \sigma^2).$$

Учитывая нормальность распределения запишем функцию правдоподобия:

$$P(\text{данные/параметры модели}) = \prod_{i=1}^n \frac{1}{\sigma\sqrt{2\pi}} e^{\frac{-(x_i - \mu)^2}{2\sigma^2}}.$$

# МЕТОД МАКСИМАЛЬНОГО ПРАВДОПОДОБИЯ

**Метод максимального правдоподобия** – (maximum likelihood estimation, MLE) – это метод оценивания неизвестных параметров распределения или модели путем максимизации функции правдоподобия. Т.е. максимизации вероятности распределения данных при заданных параметрах модели.

**Функцию правдоподобия** можно представить в виде:

$$P(\text{данные/параметры})=L(\theta) = \prod_{i=1}^n P(x_i / \theta).$$

Чтобы максимизировать функцию вероятности  $L(\theta)$ , необходимо продифференцировать  $L(\theta)$  по  $\theta$  и приравнять 0. Более удобно максимизировать не саму функцию правдоподобия, а ее логарифм. Т.е.  $\log L(\theta)$ . Поскольку логарифм - монотонно возрастающая функция, то с ростом параметра  $\theta$  будет максимизироваться и логарифм. С точки зрения математики производная от логарифма находится проще.

Поэтому можно записать:  $\log L(\theta) = \sum_{i=1}^n \log(P(x_i / \theta))$ . Для того, чтобы найти максимум следует  $\log L(\theta)$  продифференцировать и приравнять нулю. Учитывая, что максимизация соответствует минимизации функции взятой с отрицательным знаком, получим

$$\theta^* = \text{Argmin}(-\log L(\theta))$$

## МЕТОД МАКСИМАЛЬНОГО ПРАВДОПОДОБИЯ

В случае классификации можно использовать *схему Бернулли*, которая предполагает взаимоисключающие и исчерпывающие исходы экспериментов. При этом возможными исходами эксперимента по схеме Бернулли может быть «успех» или «неудача». Пусть  $p$  – вероятность успеха. Тогда, в силу того, что этими двумя событиями исчерпывается все выборочное пространство, вероятность неудачи равна  $p - 1$ . Будем считать, что успешному исходу соответствует значение  $x = 1$ , а неудачному -  $x = 0$ , Тогда вероятность успеха или неудачи можно выразить формулой

$$P(X = x) = f(x) = p^x(1 - p)^{(1-x)}$$

## МЕТОД МАКСИМАЛЬНОГО ПРАВДОПОДОБИЯ

Для каждой точки данных  $(y^i / x^i, \theta) - \text{Bernulli}(1, p)$ , тогда для функции вероятности можно записать:

$$P(y^i / x^i, \theta) = f(x) = (1 - p_i)^{(1-y^i)},$$

где  $p_i = \frac{1}{(1+e^{(-\theta^T x)})}$ .

Перепишем функцию правдоподобия в виде  $L = P(\text{данные} / \text{модель}) = P(D^1, D^2, \dots, D^m / \theta)$ , где  $D^i$  представляет собой  $i$  - й обучающий пример  $(y^i / x^i)$ .

Исходя из допущения о независимости обучающих примеров, можно представить  $L(\theta)$  в следующем факторизованном виде

$$L(\theta) = P(D^1, D^2, \dots, D^m / \theta) = \prod_{i=1}^m P(D^i / \theta).$$

Логарифмируя обе части этого равенства, преобразуем произведение вероятностей в сумму их логарифмов  $\log L(\theta) = \sum_{i=1}^m \log P(D^i / \theta)$ . Так как  $P(D^i / \theta) = k P(y^i / x^i, \theta)$ . В результате получаем  $\log L(\theta) = \sum_{i=1}^m (\log k + y^i \log p_i + (1 - y^i) \log(1 - p_i))$ . Учитывая эквивалентность максимизации и минимизации функций получим

$$\theta^* = \text{Argmin}(-\log L(\theta)), \text{ где } p_i = \frac{1}{(1+e^{(-\theta^T x)})}.$$

# ЛИНЕЙНАЯ РЕГРЕССИЯ

Рассмотрим нормальное (гауссово) распределение:

$$N(y|W^T x + b; \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y-W^T x-b)^2}{2\sigma^2}\right)$$

В многомерном случае мы получим:

$$N(\mathbf{y}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{n/2}} \exp\left[-\frac{1}{2}(\mathbf{y} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{y} - \boldsymbol{\mu})\right],$$

где  $\boldsymbol{\mu} = \mathbf{E}[\mathbf{y}] \in \mathbf{R}^n$  - вектор средних, а  $\boldsymbol{\Sigma} = \text{Cov}[\mathbf{y}]$  – ковариационная матрица размера  $n \times n$ , определяются следующим образом  $\text{Cov}[\mathbf{y}] = \mathbf{E}[(\mathbf{y} - \mathbf{E}[\mathbf{y}])(\mathbf{y} - \mathbf{E}[\mathbf{y}])^T]$ . Что равно:

$$\text{Cov}[\mathbf{y}] = \begin{bmatrix} V[Y_1] & \text{Cov}[Y_1 Y_2] & \text{Cov}[Y_1 Y_n] \\ \text{Cov}[Y_2 Y_1] & V[Y_2] & \text{Cov}[Y_2 Y_n] \\ \text{Cov}[Y_n Y_1] & \text{Cov}[Y_n Y_2] & V[Y_n] \end{bmatrix}, \text{ где } \text{Cov}[Y_i Y_j] = \mathbf{E}[Y_i Y_j] - \mathbf{E}[Y_i] \mathbf{E}[Y_j], \text{ а } V[Y_j] = \text{Cov}[Y_i Y_i]$$

Расстояние Махаланобиса:

Если рассматривать логарифмическую вероятность в точке  $\mathbf{y}$ , то мы получим

$$\log p(\mathbf{y}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \left[-\frac{1}{2}(\mathbf{y} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{y} - \boldsymbol{\mu})\right] + \text{const.} \text{ Тогда расстояние Махаланобиса } \Delta \text{ между } \mathbf{y} \text{ и } \boldsymbol{\mu} \text{ выразим}$$
$$\Delta^2 = (\mathbf{y} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{y} - \boldsymbol{\mu}).$$

# ЛИНЕЙНАЯ РЕГРЕССИЯ

Предположим, что имеется  $m$  выборок  $(y^1 / x^1, y^2 / x^2, \dots, y^m / x^m)$ . Можно вычислить функцию стоимости  $J(\theta) = \sum_{i=1}^m (\theta^T x^i - y^i)^2$ . Можно минимизировать эту функцию относительно  $\theta$ , чтобы определить параметры модели. Таким образом можно записать

$$\theta^* = \text{Argmin} \sum_{i=1}^m (\theta^T x^i - y^i)^2.$$

Выразим вектор прогноза  $Y^p$  как  $Y^p = X\theta$ , а погрешность  $e = X\theta - Y$ . Тогда  $J(\theta)$  можно выразить в виде квадрата  $l^2$  нормы вектора невязки

$$\|e\|_2^2 = \|X\theta - Y\|_2^2 = (X\theta - Y)^T (X\theta - Y).$$

Можно записать вероятность для линейной регрессии следующим образом

$$p(y|x; \theta) = N(y|W^T x + b; \sigma^2), \text{ где } \theta = (W, b, \sigma^2)$$

Если дисперсия фиксирована и не зависит от исходных данных, то такая модель называется *гомоскедастической регрессией*.

Если дисперсия зависит от входных данных, то такая модель называется *гетероскедастической регрессией*. В линейной постановке получаем

$$p(y|x; \theta) = N(y|W^T x + b; \sigma^2(W_0^T x))$$

# ЛИНЕЙНАЯ РЕГРЕССИЯ

Линейная регрессия соответствует модели

$$p(y|x; \theta) = N(y|W^T x + b; \sigma^2)$$

где  $\theta = (W, \sigma^2)$ . Будем считать, что  $\sigma^2$  фиксировано. Задача состоит в определении  $W$ .

1) Определим **отрицательный логарифм правдоподобия NLL**:

$$NLL(W) = - \sum_{n=1}^N \log \left[ \left( \frac{1}{2\pi\sigma^2} \right)^{\frac{1}{2}} \exp \left( -\frac{1}{2\sigma^2} (y_n - W^T x_n)^2 \right) \right].$$

2) Отбросив несущественные постоянные слагаемые, получим сумму квадратов невязок **RSS**.

$$RSS(W) = \sum_{n=1}^N (y_n - W^T x_n)^2 = \sum_{n=1}^N (r_n)^2, \text{ где } r_n - \text{невязка.}$$

3) Поделив  $(r_n)^2$  на число примеров получим **среднеквадратическую ошибку MSE**.

$$MSE(W) = \frac{1}{N} RSS = \frac{1}{N} \sum_{n=1}^N (y_n - W^T x_n)^2.$$

4) Извлекая квадратный корень получим **корень из среднеквадратичной ошибки RMSE**

$$RMSE(W) = \sqrt{MSE(W)} = \sqrt{\frac{1}{N} \sum_{n=1}^N (y_n - W^T x_n)^2}$$

## ЛИНЕЙНАЯ РЕГРЕССИЯ

Для вычисления *MLE* – оценки максимального правдоподобия можно минимизировать любую из предложенных оценок – *NLL, RSS, MSE, RMSE*. Во всех случаях результат будет один и тот же, поскольку целевая функция будет одной и той же .

Рассмотрим  $RSS(W) = \sum_{n=1}^N (y_n - W^T x_n)^2 = \|xW - y\|_2^2 = (xW - y)^T (xW - y)$ .

Для того, чтобы получить оптимальные значения

$$W_{MLE} = \text{Argmin} RSS(W) = (X^T X)^{-1} X^T y$$

Эта оценка обыкновенных наименьших квадратов (*OLS*) эквивалентна *MLE*

# ДИВЕРГЕНЦИЯ КУЛЬБАКА-ЛЕЙБЛЕРА И ПЕРЕКРЕСТНАЯ ЭНТРОПИЯ

Понятие *расстояние (дивергенция) Кульбака-Лейблера* пришло из теории информации. Оно является мерой разницы между двумя вероятностями распределения  $Q$  и  $P$ . Будем считать распределение  $P$  – истинное распределение,  $Q$  – его приближение. Дивергенция Кульбака – Лейблера от распределения  $P$  до распределения  $Q$  обозначается  $KL(P||Q)$  и определяется следующим образом

$$KL(P||Q) = \int \log \frac{dP}{dQ} dP, \text{ где интеграл берется по всему пространству исходов, общих для } P \text{ и } Q.$$

Рассмотрим следующие случаи:

- $Q$  и  $P$  – дискретные случайные величины, заданные на дискретном множестве

$$X = \{x_1, \dots, x_n\}. \text{ Расстояние Кульбака – Лейблера } KL(P||Q) = \sum_i p(x_i) \log \frac{p(x_i)}{q(x_i)}.$$

- $Q$  и  $P$  – непрерывные случайные величины в пространстве  $R^d$ . Расстояние

$$KL(P||Q) = \int_{R^d} p(x) \log \frac{p(x)}{q(x)}.$$

Дивергенция Кульбака-Лейблера дает возможность перейти к перекрестной энтропии (cross-entropy)

$$H(p, q) = E_p[-\log(q)] = - \sum_x p(x) \log(q(x)).$$