

ТЕОРИЯ ИСКУССТВЕННЫХ НЕЙРОННЫХ СЕТЕЙ

Каганов Ю.Т.

к.т.н., доцент каф. ИУ-9

**«Теоретическая информатика и компьютерные
технологии»**

ЛЕКЦИЯ № 10

Регуляризация в глубоком обучении

ПЛАН ЛЕКЦИИ

1. Основная задача регуляризации.
2. Постановка задачи регуляризации.
2. Основные виды регуляризации.
3. Регуляризация – как оптимизация с ограничениями.
4. Регуляризация параметров по норме L_2 .
5. Регуляризация параметров по норме L_1 .
6. Регуляризация *LASSO*.
7. Ранняя остановка.
8. DROPOUT.
9. BAGGING (Bootstrap aggregating)

Основная задача регуляризации

В процессе обучения глубокой нейронной сети возникают проблемы, связанные с перобучением и недообучением. Это определяется степенью обобщения. То есть в процессе обучения возникают ситуации, когда модель оказывается менее адекватной обучаемым данным. Как правило **недообучение** связана с ситуацией, когда сложность устройства данных выше, чем сложность устройства модели. В свою очередь **переобучение** – это явление, когда построенная модель хорошо соответствует данным из обучающей выборки, но плохо работает на данных не участвовавших в обучении (тестовая выборка). Обычно это связано с тем, что резко возрастают величины весов θ . Назначение регуляризации – приведение в равновесие обучение и тестирование. Таким образом регулируя величины весов можно добиться адекватного поведения модели.

Постановка задачи регуляризации

Большинство подходов к регуляризации основаны на ограничении емкости модели путем прибавления штрафа по норме параметра $\varphi(\theta)$ к целевой функции $f(\theta; X, Y)$. В этом случае обозначим регуляризованную целевую функцию:

$$F(\theta; X, Y) = f(\theta; X, Y) + \alpha \varphi(\theta),$$

где $\alpha \in [0, \infty]$ – гиперпараметр, задающий вес члена $\varphi(\theta)$ штрафующий по норме относительно стандартной целевой функции $f(\theta; X, Y)$. Если $\alpha = 0$, то регуляризация отсутствует. Чем больше значение α , тем сильнее регуляризация.

Необходимые и достаточные условия существования экстремума функции

Условия существования экстремума с учетом ограничений

Постановка задачи:

Пусть $f: X \rightarrow Y; X \subset E^n, Y \subset E^1$ $y=f(x)$ – выпуклая функция;

$x \in X, y \in Y; f(x) \in C^1(X)$ и пусть $g: X \rightarrow Z; X \subset E^n, Z \subset E^m$
 $f(x) \in C^1(X)$

$g_i(x) \in C^1(X), j = 1..m.$ – вогнутые или выпуклые функции,

$g = [g_1(x), g_2(x), \dots, g_m(x)]^T$, а также $\forall g_j(x) = 0$ – ограничения типа равенства.

Тогда задачу поиска экстремума функции при наличии ограничений
можно записать:

$$\begin{cases} x^e = \text{Arg min } f(x) \\ x_i \geq 0, i = 1..n \\ g_j(x) = 0, j = 1..m \end{cases}$$

Необходимые и достаточные условия существования экстремума функции.

Метод множителей Лагранжа.

(1788г."Аналитическая механика")

Функция вида: $L(x, \lambda) = f(x) + \sum_{j=1}^m \lambda_j g_j(x).$

Если взять вариацию от функции $L(x, \lambda)$ в $U_\varepsilon(x^e)$

$$\delta L(x, \lambda) = \sum_{i=1}^n \frac{\partial f(x)}{\partial x_i} \delta x_i + \sum_{i=1}^n \sum_{j=1}^m \lambda_j \frac{\partial g_j}{\partial x_i} \delta x_i = 0 \quad \text{при} \quad x = x^e$$

$$\delta L(x, \lambda) = \sum_{i=1}^n \left[\frac{\partial f}{\partial x_i} + \sum_{j=1}^m \lambda_j \frac{\partial g_j}{\partial x_i} \right]_{x=x^e} \delta x_i = 0$$

Таким образом получаем систему уравнений :

$$\left[\frac{\partial f}{\partial x_i} + \sum_{j=1}^m \lambda_j \frac{\partial g_j}{\partial x_i} = 0 \right]_{x=x^e}$$

Подбором определенных значений λ_j можно добиться того, чтобы эти уравнения удовлетворялись при $\forall i = \overline{1..n}$. Именно в точке x^e достигается стационарность функции $L(x, \lambda)$, т.е. экстремум функции $f(x)$ при заданных ограничениях $g_j(x)=0$.

Необходимые и достаточные условия существования экстремума функции.

Метод множителей Лагранжа.

Задачу можно переформулировать следующим образом.

Требуется найти:

$$\begin{cases} x^e = \operatorname{Arg} \min_{x \in X} L(x, \lambda) \\ \lambda^e = \operatorname{Arg} \max_{\lambda \in \Lambda} L(x, \lambda) \end{cases}$$

Тогда решение задачи состоит в совместном решении уравнений:

$$\begin{cases} \frac{\partial L(x, \lambda)}{\partial x_i} = 0, i = 1..n \\ \frac{\partial L(x, \lambda)}{\partial \lambda_j} = 0, j = 1..m \end{cases} \quad \begin{cases} \frac{\partial f}{\partial x_i} + \sum_{j=1}^m \lambda_j \frac{\partial g_j}{\partial x_i} = 0, -n \text{ _ уравнений} \\ g_j(x) = 0, -m \text{ _ уравнений} \end{cases}$$

Составляются и решаются 2 системы уравнений:

Необходимые и достаточные условия существования экстремума функции.

Область применения классического метода множителей Лагранжа.

Задача поиска экстремума методами классического математического анализа связана с удовлетворением следующих условий, накладываемых на функции:

1. Целевая функция $f(x)$ должна быть выпуклой (в случае поиска минимума).
2. Функции ограничений $g_j(x)$ должны быть вогнутыми или выпуклыми функциями.
3. Ограничения $g_j(x) = 0$ только типа равенств.

Последнее условие связано с тем, что если $g_j(x) < 0$, то классический метод множителей Лагранжа не дает единственного решения $x^e = \text{Arg min } f(x)$ и, следовательно, не работает.

Задачи выпуклого программирования

Формулировка задачи

Пусть $f: X \rightarrow Y; X \subset E^n, Y \subset E^1$,

$g: X \rightarrow Z; X \subset E^n, Z \subset E^m$,

$f(x) \in C^1(X), g(x) \in C^1(X)$,

$x^e = \operatorname{Arg} \min f(x), x_i \geq 0, i = 1..n$


$g_j(x) = 0, j = 1..\ell$ – ограничения типа равенств.

$g_j(x) \leq 0, k = (\ell + 1)..m$ – ограничения типа неравенств.

Обозначим множество индексов: $K = \{l + 1, m\}, k \in K$.

Задачи выпуклого программирования.

Активные ограничения.



В процессе решения задачи происходит перемещение текущей точки из заданной начальной точки в конечную точку. При этом возможен выход на границу области допустимых решений X . Такие нарушенные ограничения носят название активных.

Определение множества индексов активных ограничений:

$$K_A = \left\{ k \in K \mid (\forall g_k(x) \leq 0) \wedge (\exists g_{k_A}(x) = 0) \Rightarrow k_A \in K_A \subset K \right\}$$


Функция Куна-Таккера (функция Лагранжа) для задач выпуклого программирования (1951г.)

$$L(x, \lambda, \mu) = f(x) + \sum_{j=1}^l \lambda_j g_j(x) + \sum_{k=l+1}^m \mu_k g_k(x)$$

Продифференцируем функцию $L(x, \lambda, \mu)$ по x и приравняем 0.

Если продифференцировать по μ_k , то получим неравенства $g_k(x) \leq 0$, что не позволяет получить единственное решение. Противоречие состоит в том, что для ЗВП имеется единственное решение.

$$\left. \frac{\partial L(x, \lambda, \mu)}{\partial x_i} \right|_{x^e} = 0 \Rightarrow \nabla_x f(x^e) = -\sum_{j=1}^l \lambda_j \nabla g_j(x) - \sum_{k=l+1}^m \mu_k \nabla g_k(x)$$



Лемма: Градиент целевой функции $\nabla f(x^e)$ равен линейной комбинации градиентов функций ограничений в точке условного экстремума x^e : $-\nabla f(x^e) = \sum_{j=1}^l \lambda_j \nabla g_j(x^e) + \sum_{k=l+1}^m \mu_k \nabla g_k(x^e)$

Множество всех векторов

называется множеством **возможных направлений**.

Теорема Каруша-Куна-Таккера

Рассмотрим задачу выпуклого программирования

Пусть $f: X \rightarrow Y; X \subset E^n, Y \subset E^1; f(x) \in C^1(X)$

$g: X \rightarrow Z; X \subset E^n, Z \subset E^m; g(x) \in C^1(X)$

Требуется найти: $x^e = \text{Arg min } f(x), x \in X$

$x_i \geq 0, i = 1..n$,

$g_j(x) = 0, j = 1..l$,

$g_k(x) \leq 0, k = l + 1..m.$ Для этого решение ЗВП должно удовлетворять следующим условиям:

$x^e \in X,$

$\mu_k g_k(x^e) = 0, \lambda_j g_j(x^e) = 0.$

$\nabla_x f(x^e) + \sum_{j=1}^l \lambda_j \nabla g_j(x^e) + \sum_{k=l+1}^m \mu_k \nabla g_k(x^e) = 0$. Условия:

$\mu_k \begin{cases} = 0, g_k(x) < 0, \\ > 0, g_{kA}(x) = 0. \end{cases}$

Если эти условия выполнены, то

x^e – решение ЗВП.

- называются **условиями дополняющей нежесткости.**

Теория двойственности

Седловая точка функции Лагранжа. Двойственность.

Рассмотрим упрощенную задачу выпуклого программирования.

Пусть заданы условия на $f(x)$ и $g(x)$ как и ранее.

$$\begin{cases} x^e = \text{Arg min } f(x), \\ x_i \geq 0, i = 1..n, \\ g_j(x) \leq 0, j = 1..m. \end{cases}$$

Тогда функция Лагранжа может быть записана:


$$L(x, \mu) = f(x) + \sum_{j=1}^m \mu_j g_j(x).$$

Рассмотрим случай, когда $x = x^e, \mu = \mu^e$:

$$L(x, \mu^e) \geq L(x^e, \mu^e) \geq L(x^e, \mu).$$

Таким образом седловая точка функции Лагранжа (функции Куна-Таккера) является $[x^e, \mu^e]^T$.

Именно эта точка является решением ЗВП.



Постановка задачи многомерной оптимизации

Рассмотрим задачи нелинейной оптимизации в общем случае.

Пусть $x = (x^{(1)}, \dots, x^{(n)})^T \in R^n$, S – некоторое множество из пространства R^n . Пусть $f_0(x), \dots, f_m(x): S \rightarrow R^1$. Тогда задачу минимизации можно рассматривать в следующем виде

$$\min f_0(x) \text{ при } f_j(x) \leq 0, j = 1, \dots, m, x \in S. \quad (1)$$

$f_0(x)$ - будем называть *целевой функцией*. Функции $f_j(x) \leq 0$, как было принято нами ранее, обозначим $g_j(x) \leq 0$ или $g_j(x) = 0$.

Они называются *функциями ограничений* и зависят от типа ограничений – равенств или неравенств. Множество S – называется *базовым допустимым множеством*, а множество Q

$Q = (x \in S | g_j(x) \leq 0, j=1, \dots, m)$. Называется просто *допустимым множеством*.