



Министерство науки и высшего образования Российской
Федерации Федеральное государственное автономное
образовательное учреждение высшего образования
«Московский государственный технический
университет имени Н.Э. Баумана
(национальный исследовательский
университет)» (МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ Информатика и системы управления

КАФЕДРА Теоретическая информатика и компьютерные
технологии

РАСЧЕТНО-ПОЯСНИТЕЛЬНАЯ ЗАПИСКА
К ПРЕДДИПЛОМНОЙ ПРАКТИКЕ
НА ТЕМУ:

«Информационная система классификации
предметов на горизонтальном конвейере»

Студент ИУ9-82Б

группа

подпись, дата

Морозов Д. В.

фамилия, и.о.

Руководитель

подпись, дата

Посевин Д.П.

фамилия, и.о.

2026 г.

СОДЕРЖАНИЕ

ОПИСАНИЕ БАЗЫ ПРАКТИКИ.....	3
ВВЕДЕНИЕ.....	4
1. Реализация информационной системы.....	6
1.1 Разработка модуля захвата и предобработки видеопотока.....	6
1.2 Реализация метода яркости.....	8
1.3 Реализация SVD алгоритма классификации.....	9
1.4 Реализация базовой свёрточной нейронной сети.....	12
1.5 Реализация дообученной модели MobileNetV3.....	15
1.6 Итоги реализации информационной системы.....	16
2. Тестирование.....	19
2.1 Тестирование метода яркости.....	19
2.2 Тестирование SVD-метода классификации.....	21
2.3 Тестирование базовой свёрточной нейронной сети.....	22
2.4 Тестирование дообученной модели MobileNetV3.....	23
2.5 Сравнительный анализ качества и скорости.....	24
ЗАКЛЮЧЕНИЕ.....	29
СПИСОК ИСПОЛЬЗУЕМЫХ ИСТОЧНИКОВ.....	31

ОПИСАНИЕ БАЗЫ ПРАКТИКИ

Отдел информационных технологий и поддержки (ОИТП) — это подразделение МГТУ им. Н.Э. Баумана, которое обеспечивает работу информационно-технологической инфраструктуры университета: развивает цифровые сервисы, поддерживает пользователей, управляет сетями, серверами и информационными системами.

Помимо текущего сопровождения, сотрудники ОИТП участвуют во внедрении новых программных решений, модернизации оборудования и повышении уровня кибербезопасности. Отдел также оперативно реагирует на сбои в работе сервисов, проводит профилактические работы и консультирует по вопросам использования университетских информационных систем.

ВВЕДЕНИЕ

Ленточный конвейер (горизонтальный конвейер) — транспортное устройство непрерывного действия с движущейся лентой, на котором размещаются предметы. Он служит контролируемой средой для съёмки объектов, подлежащих классификации: обеспечивает фиксированное положение камеры, стабильное однородное освещение и равномерное перемещение объектов через зону захвата изображений.

Разработка информационной системы для классификации предметов на движущемся конвейере требует создания надёжного программного решения, способного быстро обрабатывать поток изображений и выдавать точный класс объекта обнаружения. В данной научно-исследовательской работе рассматривается построение такой системы, где основной задачей является выбор и программная реализация алгоритмов, которые смогут стабильно работать в контролируемых условиях реальной конвейерной ленты. Проектирование системы представляет собой связывание логики захвата изображений, их передачи, первичной подготовки, работы классификатора и отображения результата. Чтобы найти оптимальный баланс между скоростью работы программы и качеством распознавания, на 5 разных наборах данных сравниваются четыре различных алгоритма. Первый — это простейший метод яркости, который классифицирует объект по порогу яркости и строит вокруг него рамку, что позволяет оценить габариты предмета с минимальными затратами ресурсов. Второй метод использует SVD-разложение матриц для выделения ключевых признаков изображения, преобразуя картинку в набор компактных векторов. Третий и четвёртый методы представляют собой нейросетевой подход: это базовая свёрточная нейронная сеть (CNN), собранная вручную, и оптимизированная архитектура MobileNetV3, дообученная под конкретные задачи классификации. Сначала система будет проверяться в контролируемых условиях конвейера: на наборах данных с болтами и гайками, а также разноцветными фломастерами, где фон всегда

однороден, а освещение почти не меняется. Затем проверка будет произведена в более сложных условиях, чтобы понять предел устойчивости и качество алгоритмов. Для этого будут использоваться наборы данных с изображениями огня в домашних условиях, масштабных возгораний и задымлений. Эти данные имитируют неконтролируемую среду с переменным фоном и плохой видимостью, что позволит наглядно сравнить, насколько хорошо нейросети и классические алгоритмы компьютерного зрения справляются с шумами и нестандартными ситуациями. Такой поэтапный переход от простых объектов на ленте к сложным сценам с огнём и дымом необходим для того, чтобы оценить готовность итоговой информационной системы к возможным сбоям в освещении или появлению посторонних предметов в кадре.

Целью работы является разработка и программная реализация информационной системы для классификации предметов на горизонтальном конвейере, а также сравнение четырёх алгоритмов распознавания на данных разной сложности для выбора наиболее стабильного решения.

1. Реализация информационной системы

1.1 Разработка модуля захвата и предобработки видеопотока

Разработка модуля захвата и предобработки видеопотока является первым этапом программной реализации информационной системы, поскольку именно от корректности и своевременности получения исходных изображений зависит работа всех последующих алгоритмов классификации. Данный модуль охватывает две функциональные части: прошивка микроконтроллера NodeMCU на чипе ESP8266, написанная на языке C++ в среде разработки ArduinoIDE, и приёмный модуль на языке Python, работающий на центральном вычислительном узле: персональном компьютере, Raspberry Pi 4 Model B или Raspberry Pi Zero W.

На стороне микроконтроллера NodeMCU на чипе ESP8266 реализована прошивка, обеспечивающая захват изображений с камеры OVM2640 с интервалом в полторы секунды. Камера подключается к микроконтроллеру через физические выводы GPIO с использованием интерфейсов SPI для передачи данных пикселей и I2C для отправки управляющих команд: настройка экспозиции, баланса белого, размера кадра, частоты смены кадров. В основной функции прошивки выполняется инициализация периферии: настройка тактирования SPI на максимально возможную частоту, стабильную для выбранной длины линий, конфигурация выводов GPIO в соответствии с таблицей соединений, инициализация последовательного порта UART с заданной скоростью для последующей передачи данных на центральный узел. В прошивке реализован циклический захват кадра: камера OVM2640 по команде микроконтроллера выполняет фиксацию кадра и выставляет пиксельные значения на линии MISO интерфейса SPI, а микроконтроллер последовательно считывает байты, соответствующие яркости и цветовым компонентам каждого пикселя. Такой подход минимизирует вычислительную нагрузку на NodeMCU, который не обладает достаточной

производительностью для сложных алгоритмов предобработки, а решает лишь задачу передачи данных в исходном виде.

После завершения захвата кадра микроконтроллер формирует пакет данных для передачи по последовательному порту согласно протоколу, описанному в конструкторской части. Провода от выводов микроконтроллера подключаются к USB-UART преобразователю, который, в свою очередь, соединён с центральным вычислительным узлом через порт USB. Такая схема позволяет передавать кадры на расстоянии до нескольких метров без существенных потерь и помех. На стороне центрального вычислительного узла разработан модуль на языке Python, который выполняет приём последовательности байт из виртуального последовательного порта, например, `/dev/ttyUSB0` в Linux или COM3 в Windows, проверку целостности принятых данных и восстановление двумерной матрицы пикселей для дальнейшей обработки. Для работы с последовательным портом используется стандартная библиотека `pySerial`. В отдельном процессе организован цикл чтения: скрипт ожидает поступления стартового байта, затем считывает поле длины, определяющее, сколько байт изображения необходимо принять. Принятый массив байт передаётся на обработку, после чего система переходит в ожидание следующего стартового байта. Корректно принятый плоский массив байт преобразуется в многомерный массив `NumPy`. Далее в зависимости от требований конкретного алгоритма выполняются дополнительные операции предобработки. Для метода яркости дополнительно применяется пороговая бинаризация с использованием фиксированного порога, после чего выполняется поиск контуров и построение ограничивающей рамки вокруг обнаруженного объекта. Для SVD-разложения изображение переводится в чёрно-белое, представляя собой 1 матрицу значения пикселей, вместо трёх для RGB.

Таким образом, разработанный модуль захвата и предобработки видеопотока обеспечивает полный цикл преобразования данных от

физического считывания пикселей с камеры до подготовки массива, готового к подаче на вход любого из четырёх алгоритмов классификации. Использование прошивки на C++ в ArduinoIDE гарантирует высокую производительность микроконтроллера при минимальном энергопотреблении, а приёмный модуль на Python с применением стабильных и популярных библиотек обеспечивает гибкость и удобство интеграции с остальными компонентами информационной системы.

1.2 Реализация метода яркости

Метод яркости представляет собой простейший детерминированный алгоритм классификации, не использующий машинное обучение и основанный на анализе геометрических признаков объектов, выделенных из бинаризованного изображения. В рамках данной научно-исследовательской работы данный метод реализован на языке программирования Python. Выбор метода яркости обусловлен необходимостью получить базовый уровень точности и производительности, с которым впоследствии сравниваются более сложные алгоритмы: SVD-разложение, базовая свёрточная нейронная сеть и дообученная MobileNetV3.

Входными данными для метода служит одноканальное монохромное изображение размером 240 на 240 пикселей, полученное из модуля захвата и предобработки видеопотока. Первым этапом обработки является бинаризация — преобразование градаций серого в двоичное чёрно-белое изображение, где пиксели, соответствующие объекту, получают значение 255 (белый цвет), а пиксели фона — значение 0 (чёрный цвет). Выбор порога бинаризации обоснован эмпирическим экспериментом, основанном на том, что условия на конвейере, а именно фон, освещение и удалённость камеры от конвейера, являются контролируемыми.

После получения бинарного изображения выполняется поиск контуров объектов, который возвращает значения крайних пикселей, относящихся к целевому объекту. Поскольку в кадре может присутствовать не более одного

предмета за раз, благодаря нормальной работе конвейера с разнесёнными объектами, все найденные точки относятся к одному объекту. Для каждого выбранного контура вычисляется ограничивающая, возвращающей координаты верхнего левого угла, ширину и высоту рамки.

На основе полученной ограничивающей рамки и бинарного изображения вычисляются следующие геометрические признаки, используемые для классификации. Первый признак — отношение ширины рамки к её высоте. Для объектов вытянутой формы это отношение значительно больше единицы, тогда как для компактных объектов оно близко к единице. Вторым признаком — значение пикселя в центре рамки. Данное значение характеризует, насколько плотно объект заполняет свою ограничивающую рамку: гайки с внутренним отверстием дают противоположное значение со сплошными болтами. Решающее правило классификации реализовано в виде последовательности пороговых проверок этих двух признаков. Для задачи классификации фломастеров по цвету метод яркости не применяется, так как он не различает цветовые характеристики. Данный датасет был выбран специально, чтобы показать слабые стороны алгоритма.

После завершения классификации метод возвращает результат, содержащий метку предсказанного класса, а также рассчитанные признаки для последующего логирования и отладки. Помимо этого, как и остальные алгоритмы, выводит полученное изображение с камеры и выводит результат классификации поверх него.

1.3 Реализация SVD алгоритма классификации

Метод классификации на основе сингулярного разложения матриц (SVD) представляет собой гибридный подход, сочетающий извлечение признаков с помощью методов линейной алгебры и классификацию на основе метода, рассчитывающего расстояние до центроидов классов предварительно обученных классов. В рамках данной научно-исследовательской работы

данный метод реализован с использованием двух языков программирования: Python отвечает за высокоуровневую логику, загрузку изображений, предобработку, обучение классификатора и принятие итогового решения, а Julia является вычислительным ядром, в котором реализуется степенной метод для усечённого сингулярного разложения, который работает непосредственно с матрицей пикселей изображения (рисунок 11). Такое разделение обусловлено необходимостью достичь максимальной производительности при выполнении итерационного алгоритма разложения, поскольку Julia обеспечивает скорость выполнения, близкую к компилируемым языкам, сохраняя при этом выразительность синтаксиса для численных методов.




Рисунок 11 — Схема работы SVD алгоритма

Входными данными для SVD-алгоритма служит монохромное изображение размером 240 на 240 пикселей, представленное в виде двумерной матрицы яркостей A размером 240 на 240, где каждый элемент является целым числом в диапазоне от 0 до 255. На стороне Python перед передачей в Julia матрица преобразуется к типу `float64`. Организация межязыкового взаимодействия реализована через механизм `PyCall.jl` в Julia, который

позволяет вызывать из Julia функции Python и передавать данные. В отличие от полного SVD, вычисляемого библиотечными функциями вроде `svd()` из SciPy, степенной метод позволяет последовательно находить только первые k сингулярных значений и соответствующих сингулярных векторов, что существенно сокращает объём вычислений при решении задачи извлечения признаков. Итерационный процесс повторяется k раз, что позволяет получить k наибольших сингулярных значений в порядке убывания. В рамках данной работы значение k подбиралось экспериментально и составляло от 48 до 96 — такое количество сингулярных чисел обеспечивает достаточную информативность признаков для различения классов при приемлемой вычислительной сложности. Результатом работы степенного метода является матрица признаков, которая далее используется для классификации. Полученная матрица из Julia передаётся обратно в Python (рисунок 12).




Рисунок 12 — Схема SVD разложения

Для выполнения классификации в пространстве признаков предварительно необходимо обучить классификатор на размеченных данных. Для каждого изображения из тренировочной выборки датасета вычисляется матрица признаков описанным выше способом. Затем для каждого класса вычисляется центроид — среднее арифметическое всех векторов признаков,

принадлежащих данному классу. Каждый центроид отдельно сохраняется в файл. На этапе классификации нового изображения система выполняет следующую последовательность действий. Изображение проходит через степенной метод на Julia, в результате чего получается матрица признаков размерности 240 на k. Затем вычисляются евклидовы расстояния от этой матрицы до каждого из сохранённых центроидов. Итоговым предсказанным классом объявляется тот класс, для которого евклидово расстояние до центроида минимально.

1.4 Реализация базовой свёрточной нейронной сети

Базовая свёрточная нейронная сеть представляет собой классическую архитектуру глубокого обучения, спроектированную для задачи классификации предметов на горизонтальном конвейере. Данная модель реализована с использованием библиотеки PyTorch — одного из наиболее популярных фреймворков для глубинного обучения, предоставляющего гибкие средства для построения произвольных архитектур, автоматического дифференцирования и обучения на графических процессорах. Выбор PyTorch обусловлен его интуитивно понятным интерфейсом, динамическим построением вычислительных графов и широкой экосистемой инструментов для компьютерного зрения, включая torchvision для предобработки изображений и аугментации данных. В отличие от библиотеки TensorFlow или Keras, PyTorch даёт более низкоуровневый контроль над процессом обучения, что особенно важно при экспериментальном подборе гиперпараметров и отладке архитектуры. В рамках данной научно-исследовательской работы базовая CNN служит эталонным представителем классических нейросетевых подходов, с которым сравниваются более лёгкая архитектура MobileNetV3 и методы, не использующие нейронные сети: метод яркости и SVD.

Входными данными для свёрточной нейронной сети являются цветные RGB-изображения постоянного размера 240 на 240 пикселей. Тензор на входе сети имеет размерность 3 на 240 на 240, где первая размерность соответствует

трём цветовым каналам RGB, вторая и третья — высоте и ширине изображения соответственно.

Архитектура разработанной свёрточной нейронной сети построена по иерархическому принципу и включает последовательность из четырёх свёрточных блоков, за которыми следуют полносвязные слои-классификаторы. Каждый свёрточный блок имеет единообразную структуру: два последовательных свёрточных слоя Conv2d с размером ядра 3 на 3, за каждым из которых следуют слой пакетной нормализации BatchNorm2d и функция активации ReLU. После завершения каждого блока применяется операция максимального пулинга MaxPool2d с окном 2 на 2, уменьшающая пространственную размерность карт признаков в два раза. Такая структура обеспечивает постепенное увеличение глубины, то есть количества каналов, при одновременном уменьшении пространственного разрешения. Это является классическим приёмом в архитектурах свёрточных нейронных сетей, позволяющим извлекать иерархические признаки от простых, представляющие собой границы и углы на ранних слоях, до сложных и абстрактных, в виде формы частей объектов на глубоких слоях.

Начальный свёрточный блок принимает трёхканальное RGB-изображение и увеличивает количество каналов до 32. После двух свёрток 3 на 3 и слоя пулинга размерность тензора становится 32 на 120 на 120. Второй свёрточный блок преобразует 32 канала в 64, после пулинга размерность составляет 64 на 60 на 60. Третий блок увеличивает количество каналов до 128, после пулинга 128 на 30 на 30. Последний четвёртый свёрточный блок расширяет каналы до 256, после чего операция максимального пулинга с окном 2 на 2 уменьшает пространственное разрешение до 256 на 15 на 15. Таким образом, на выходе последнего пулингового слоя формируется тензор признаков размерностью 256 на 15 на 15, который представляет собой 256 карт признаков размером 15 на 15 пикселей каждая. Данная размерность является

критической точкой архитектуры, поскольку дальнейшие слои будут работать именно с этим объёмом признаковой информации.

Завершающая часть сети — классификатор, построенный на полносвязных слоях. Тензор сначала выпрямляется при помощи слоя Flatten в одномерный вектор размерностью 256 на 15 на 15, имеющий размерность 57600. Такой вектор содержит все признаки, извлечённые свёрточной частью сети, и передаётся в последовательность полносвязных слоёв. Первый полносвязный слой уменьшает размерность с 57600 до 512 и сопровождается функцией активации ReLU, а также слоем дропаута (Dropout) с вероятностью отключения нейронов 0.4. Дропаут необходим для регуляризации и предотвращения переобучения: во время обучения каждый нейрон с вероятностью 40% «выключается», что вынуждает сеть обучаться более общим признакам, не зависящим от отдельных нейронов. Второй полносвязный слой преобразует вектор размерности 512 в 256, после чего снова применяется ReLU и дропаут с вероятностью 0.3. Финальный полносвязный слой отображает 256-мерный вектор в пространство классов: количество выходных нейронов равно числу классов в текущей задаче. 2 для болтов/гаек, 3 для фломастеров, 2 для огня/дыма/отсутствие.

Обучение сети осуществляется с использованием оптимизатора Adam с начальной скоростью обучения 0.001. Функция потерь — кросс-энтропия. Для повышения обобщающей способности применяются аугментации данных.

Таким образом, разработанная базовая свёрточная нейронная сеть обеспечивает полный цикл извлечения иерархических признаков из цветных изображений с последующей классификацией. Её архитектура с четырьмя свёрточными блоками и прогрессивным расширением каналов от 3 до 256 позволяет эффективно улавливать как низкоуровневые, так и высокоуровневые визуальные паттерны, характерные для распознаваемых предметов. Применение пакетной нормализации ускоряет и стабилизирует

обучение, а дропаут снижает риск переобучения, что особенно важно при работе с ограниченными датасетами.

1.5 Реализация дообученной модели MobileNetV3

MobileNetV3 представляет собой современную лёгкую архитектуру свёрточной нейронной сети, разработанную компанией Google специально для эффективной работы на мобильных и встраиваемых устройствах с ограниченными вычислительными ресурсами. В рамках данной научно-исследовательской работы используется предобученная версия модели MobileNetV3, которая изначально обучена на масштабном наборе данных ImageNet, содержащем более миллиона изображений и 1000 различных классов. Такое предварительное обучение позволяет сети сформировать универсальные и высококачественные визуальные признаки: границы, текстуры, формы, цветовые сочетания и другие низкоуровневые и среднеуровневые паттерны. Основная идея дообучения (fine-tuning) заключается в том, чтобы взять эту уже обученную модель и адаптировать её под конкретную задачу классификации предметов на горизонтальном конвейере, заменив только её классификационную «голову», представляющую собой последние полносвязные слои. И дообучив всю модель с небольшой скоростью обучения на специализированных наборах данных, например болты и гайки, фломастеры, огонь или дым. Такой подход существенно сокращает объём требуемых тренировочных данных и время обучения по сравнению с обучением сети с нуля, поскольку свёрточная часть модели уже содержит богатое и обобщённое представление о визуальном мире.

Реализация дообучения выполнена с использованием библиотеки PyTorch, что обеспечивает единообразие инструментария с базовой свёрточной нейронной сетью и упрощает сравнение результатов. После загрузки все параметры базовой свёрточной части модели замораживаются, то есть для них отключается вычисление градиентов. Это делается путём

установки атрибута `requires_grad` в значение `False` для каждого параметра в модели. Заморозка необходима для того, чтобы при первом этапе дообучения не происходило разрушение полезных универсальных признаков, выработанных на ImageNet, которые являются общими для большинства задач компьютерного зрения. Кроме того, заморозка значительно уменьшает количество обучаемых параметров, ускоряет обучение и снижает риск переобучения на небольших датасетах.

Ключевым изменением, вносимым в архитектуру MobileNetV3, является полная замена классификационной головы. Исходная модель MobileNetV3 имеет классификатор, состоящий из нескольких полносвязных слоёв, которые отображают признаки размерностью 960 после глобального пулинга в 1000 классов ImageNet. Поскольку в рассматриваемых задачах количество классов существенно меньше, а именно 2 для болтов и гаек, 3 для фломастеров, 2 для детекции огня/дыма, исходный классификатор удаляется и заменяется на новый, адаптированный под конкретную задачу. Новая классификационная голова проектируется следующим образом. Сначала из последнего свёрточного блока MobileNetV3 извлекается признаковый тензор, который проходит через слой глобального среднего пулинга `AdaptiveAvgPool2d`, преобразующий пространственные размерности и оставляющий количество каналов неизменным. Полученный вектор размерности 960 подаётся на последовательность полносвязных слоёв. Финальный полносвязный слой отображает выходные нейроны в N классов, где N зависит от решаемой задачи. Важно отметить, что все остальные слои модели — все свёрточные блоки, глубинно-разделимые свёртки, блоки с механизмами внимания (`squeeze-and-excitation`), функции активации `h-swish` — остаются неизменными и работают в точном соответствии с оригинальной архитектурой MobileNetV3.

1.6 Итоги реализации информационной системы

В рамках технологической части научно-исследовательской работы была полностью реализована информационная система классификации

предметов на горизонтальном конвейере, включающая все заявленные функциональные компоненты: модуль захвата и предобработки видеопотока на микроконтроллере NodeMCU ESP8266 с прошивкой на языке программирования C++, приёмный модуль на языке программирования Python, четыре алгоритма классификации различных типов: метод яркости, SVD-метод на основе степенного разложения на языке программирования Julia, базовая свёрточная нейронная сеть на PyTorch и дообученная MobileNetV3. А также реализован модуль визуализации результатов и пользовательский интерфейс. Все компоненты интегрированы в единую систему с унифицированным интерфейсом, что позволяет гибко переключаться между алгоритмами в зависимости от требований к точности и производительности.

Основным результатом реализации является создание работоспособного программного обеспечения и сбор экспериментальной установки (рисунки 13, 14), которую можно развёртывать на трёх различных вычислительных платформах с разными параметрами: персональном компьютере, одноплатном компьютере Raspberry Pi 4 Model B и сверхкомпактной платформе Raspberry Pi Zero W. Разработанная система способна обрабатывать поток изображений в реальном времени и отображать результаты классификации в пользовательский интерфейс, подавая также в виде выходных данных более подробную информацию о самом объекте и результате работы того или иного классификатора.

Таким образом, поставленная в работе цель по разработке и программной реализации информационной системы для классификации предметов на горизонтальном конвейере достигнута. Созданное программное обеспечение отличается модульной архитектурой, кроссплатформенностью и готовностью к тестированию, а реализованные четыре алгоритма предоставляют широкий набор вариантов.




Рисунок 13 — Экспериментальная установка с персональным компьютером




Рисунок 14 — Экспериментальная установка с Raspberry PI Zero W

2. Тестирование

2.1 Тестирование метода яркости

Метод яркости, являющийся наиболее простым и вычислительно лёгким среди четырёх рассматриваемых алгоритмов, прошёл экспериментальную проверку на всех пяти наборах данных. Как и предполагалось в исследовательской части, данный метод показал свою эффективность исключительно в условиях контролируемой среды, характеризующейся однородным фоном, стабильным освещением и наличием хорошо выраженных геометрических различий между классами. На неконтролируемых наборах данных, а также на задачах, где ключевым классифицирующим признаком выступает цвет, метод яркости оказался неприменимым.

Единственным набором данных, на котором метод яркости продемонстрировал работоспособность, стал датасет с болтами и гайками, содержащий 156 изображений металлических крепёжных изделий на чёрном однородном фоне. Благодаря стабильным условиям съёмки и ярко выраженным геометрическим различиям между двумя классами, а именно вытянутая форма болта с отношением ширины к высоте значительно больше единицы против компактной шестигранной формы гайки с внутренним отверстием, алгоритм смог выделить контуры объектов, построить ограничивающие рамки и вычислить признаки для классификации. Полученные метрики качества представлены в таблице 1.

Таблица 1 — Значение метрик для метода яркости, %

	Accuracy	Precision	Recall	F1-Score
Датасет №1	60	88	46	59

Высокое значение точности (precision) свидетельствует о том, что лишь в 12% случаев предсказанный класс оказывался неверным. Иными словами, метод яркости даёт мало ложноположительных срабатываний. Однако низкое

значение полноты (recall) указывает на серьёзную проблему: алгоритм пропускает более половины всех объектов, которые действительно присутствуют в кадре. То есть из всех болтов и гаек, подлежащих классификации, метод яркости правильно распознал менее половины. Такое расхождение между высокой точностью и низкой полнотой объясняется чувствительностью метода к вариациям в ориентации и положении объектов. Если болт располагался не строго горизонтально или вертикально, а под углом, отношение сторон ограничивающей рамки могло исказиться, что приводило к неправильному отнесению к классу или к полному пропуску объекта. Также внутреннее отверстие гайки при определённых углах съёмки могло сливаться с фоном, меняя коэффициент заполнения рамки и сбивая пороговое правило классификации. Итоговое значение точности (ассигасу) в 60% лишь незначительно превышает случайное угадывание, что подтверждает ограниченную применимость метода даже на простых контролируемых данных без дополнительной настройки. На остальных четырёх наборах данных метод яркости оказался полностью неприменимым из-за сложности изображений, что было зафиксировано в ходе экспериментального тестирования.

Датасет №2, представляющий собой фломастеры трёх цветов, содержит объекты одинаковой формы, различающиеся исключительно цветом корпуса. Метод яркости работает с монохромными изображениями, теряя всю цветовую информацию при преобразовании в градации серого. Поскольку три цвета фломастеров, а именно синий, фиолетовый и зелёный, при переводе в оттенки серого дают близкие значения яркости, пороговая бинаризация и последующий анализ геометрических признаков не позволяют различить классы. Контуры всех фломастеров имеют практически идентичную форму и размеры, что делает разделение объектов по рассчитанным признакам невозможным. Таким образом, для задач, где классификация основывается на цвете, метод яркости принципиально не подходит.

Остальные наборы данных представляют собой сцены с открытым пламенем, характеризующиеся нестационарной, постоянно меняющейся формой объекта, отсутствием чётких границ и высокой вариативностью освещения. Пламя не имеет фиксированного контура, который можно было бы устойчиво выделить методом бинаризации и поиска контуров. Пороговая обработка либо приводила к фрагментации области пламени на множество мелких контуров, либо к слиянию пламени с ярко освещённым фоном, что делало невозможным построение единой ограничивающей рамки. Даже в тех редких случаях, когда контур удавалось выделить, его геометрические варьировались от кадра к кадру настолько сильно, что невозможно было установить стабильные пороговые правила для классификации.

Экспериментально подтверждено, что метод яркости сохраняет работоспособность только в узком классе задач, где одновременно выполняются несколько условий: однородный контрастный фон, стабильное освещение, объекты имеют устойчивую геометрическую форму, а классифицирующие признаки основаны на форме и размерах, а не на цвете или текстуре.

2.2 Тестирование SVD-метода классификации

Метод классификации на основе сингулярного разложения матриц (SVD), реализованный с использованием степенного метода на языке Julia и классификацией по евклидову расстоянию до предварительно вычисленных центроидов классов, прошёл экспериментальную проверку на всех пяти наборах данных. В отличие от метода яркости, который оказался применим только на датасете с болтами и гайками, SVD-метод продемонстрировал работоспособность на всех пяти наборах, показав при этом более высокую точность на сложных неконтролируемых сценах, включающих в себя огонь и дым, и невысокие результаты на задаче, где ключевым признаком является цвет, а именно на наборе данных с фломастерами. В таблице 2 представлена

информация о всех метриках качества SVD-алгоритма для каждого из пяти наборов данных.

Таблица 2 — Значение метрик для SVD алгоритма, %

	Accuracy	Precision	Recall	F1-Score
Датасет №1	63.6	62.5	63.4	62.4
Датасет №2	43.1	46.8	43.5	44.0
Датасет №3	68.5	72.9	68.5	69.0
Датасет №4	70.5	75.3	70.5	71.7
Датасет №5	78.0	78.0	70.5	74.8

SVD-алгоритм продемонстрировал значительно более широкую область применимости по сравнению с методом яркости, успешно работая на всех пяти наборах данных. Лучшие результаты достигнуты на задачах детекции дыма, значение точности (ассурасу) для дыма равно 78,00%, для больших пожаров 70,56% и небольших источников огня 68,54%. На классификации болтов и гаек метод показал умеренное качество, точность равна 63,64%, незначительно превосходя метод яркости, что связано с цветом объектов и похожей формы, требующей большого количества сингулярных чисел. Низкие результаты зафиксированы на цветной задаче с фломастерами, а именно 43,14%, где одинаковая форма объектов также требует больше информации для метода в виде количества сингулярных чисел.

2.3 Тестирование базовой свёрточной нейронной сети

Базовая свёрточная нейронная сеть, реализованная на PyTorch с архитектурой из четырёх свёрточных блоков и последующих полносвязных слоёв, прошла экспериментальную проверку на всех пяти наборах данных. Как и предполагалось, нейросетевой подход продемонстрировал существенно более высокую точность классификации по сравнению с методом яркости и SVD-алгоритмом практически на всех наборах, особенно на тех, где ключевым

признаком является цвет, то есть фломастеры, или сложная текстура, а именно огонь. Благодаря способности автоматически извлекать иерархические признаки из цветных RGB-изображений, базовая CNN показала стабильно высокие результаты в диапазоне 85–86% на трёх из пяти наборов данных. В таблице 3 представлена информация о всех метриках качества базовой свёрточной нейронной сети для каждого из пяти наборов данных.

Таблица 3 — Значение метрик для CNN, %

	Accuracy	Precision	Recall	F1-Score
Датасет №1	86.3	86.1	83.9	84.8
Датасет №2	86.2	86.8	86.7	86.1
Датасет №3	85.3	95.4	63.6	76.3
Датасет №4	85.9	83.8	89.5	84.8
Датасет №5	70.0	66.6	84.6	74.5

Свёрточная нейронная сеть подтвердила свой статус наиболее точного алгоритма на задачах, где объекты имеют стабильную форму и цвет. Для наборов данных с болтами и гайками — 86,36%, набор данных с фломастерами — 86,27%, обширные пожары — 85,98%. На небольших источниках огня сеть показала высокую точность (precision), равную 95,45%, но столкнулась с проблемой низкой полноты (recall), равной 63,64%, что снизило общее значение F1-меры (F1-score) до 76,36%. Наиболее сложным оказался набор с дымом, где точность (accuracy) составила 70,00%, уступив даже SVD-методу. В среднем по всем пяти наборам базовая CNN значительно превосходит метод яркости и SVD-алгоритм.

2.4 Тестирование дообученной модели MobileNetV3

Дообученная модель MobileNetV3, представляющая собой лёгкую свёрточную нейронную сеть, оптимизированную для работы на мобильных и встраиваемых устройствах, прошла экспериментальную проверку на всех пяти

наборах данных. Как и предполагалось, MobileNetV3 продемонстрировала результаты, сопоставимые с базовой CNN на большинстве наборов. Благодаря предварительному обучению на ImageNet и последующему дообучению на целевых данных, модель показывает высокую точность классификации при значительно меньшем количестве параметров, что делает её оптимальным выбором для развёртывания на Raspberry Pi 4. В таблице 4 представлены сводные метрики качества дообученной модели MobileNetV3 для каждого из пяти наборов данных.

Таблица 4 — Значение метрик для MobileNetV3, %

	Accuracy	Precision	Recall	F1-Score
Датасет №1	95.4	98.7	92.8	94.7
Датасет №2	86.2	86.8	86.7	86.1
Датасет №3	78.6	79.1	81.1	78.3
Датасет №4	85.9	84.0	90.0	84.9
Датасет №5	66.0	62.1	88.4	73.0

Дообученная модель MobileNetV3 подтвердила свою эффективность как лёгкая альтернатива базовой свёрточной нейронной сети. Таким образом, MobileNetV3 является оптимальным выбором для задач, где критически важна производительность и экономия вычислительных ресурсов, при допустимом незначительном снижении точности на некоторых типах объектов.

2.5 Сравнительный анализ качества и скорости

После тестирования каждого из четырёх алгоритмов классификации на пяти наборах данных по метрикам точности и на трёх вычислительных платформах по метрикам скорости, был проведён комплексный сравнительный анализ. Целью данного анализа является выявление сильных и слабых сторон каждого алгоритма, определение областей их оптимального применения и формулирование рекомендаций по выбору алгоритма в

зависимости от конкретных условий эксплуатации горизонтального конвейера. На рисунке 15 представлен пример работы алгоритмов на разных тестовых изображениях для набора данных с огнём в домашних условиях. Визуализация демонстрирует формат вывода данных каждого из алгоритмов, которые передаются в веб-интерфейс и являются идентичными для любого из набора данных.



Рисунок 15 — Пример работы алгоритма

На рисунке 16 представлено графическое сравнение F1-меры (F1-score) всех четырёх алгоритмов по каждому из пяти наборов данных. F1-мера выбрана в качестве основной метрики для сравнения, поскольку он является гармоническим средним точности (precision) и полноты (recall) и наиболее объективно отражает баланс между этими двумя показателями. На датасете с изображениями болтов и гаек лидером является MobileNetV3 с F1-мерой 96,30%, значительно опережая базовую CNN (84,83%), SVD (62,40%) и метод яркости (59,00%). На датасете с изображениями фломастеров метод яркости и SVD оказались практически неприменимы из-за отсутствия цветовой информации. Их F1-мера составили около 44% и 44% соответственно, что лишь незначительно превышает случайное угадывание для трёх классов (33%). Напротив, базовая CNN и MobileNetV3 показали практически

идентичные результаты с F1-мерой около 86%, что подтверждает их способность эффективно использовать цветовую информацию.




Рисунок 16 — Сравнение F1-score алгоритмов по датасетам

Однако на наборе данных для классификации дыма ситуация принципиально иная. SVD неожиданно показал лучший результат среди всех алгоритмов — F1-мера 75,00%, опередив базовую CNN (74,58%) и MobileNetV3 (73,02%). Это важное наблюдение, свидетельствующее о том, что для задач детекции дыма, характеризующихся аморфностью и полупрозрачностью объектов, спектральные признаки, извлекаемые сингулярным разложением, могут быть более информативными, чем глубокие нейросетевые представления. Метод яркости, как и ожидалось, неприменим.

В целом, по сумме всех пяти наборов данных, базовая CNN и MobileNetV3 демонстрируют наиболее высокое и стабильное качество классификации, с незначительным преимуществом MobileNetV3. SVD-метод занимает промежуточное положение, показывая хорошие результаты на огне и дыме, но проваливаясь на цветных объектах. Метод яркости применим

только в узком классе задач с контролируемыми условиями и геометрически различными объектами.

В таблице 5 представлены результаты измерения времени обработки одного кадра в секундах для каждого алгоритма на трёх вычислительных платформах: персональном компьютере (AMD Ryzen 7 5700U, 16 ГБ ОЗУ), одноплатном компьютере Raspberry Pi 4 Model B и сверхкомпактной платформе Raspberry Pi Zero W. Прочерк в таблице означает невозможность запуска алгоритма на данной платформе из-за недостатка оперативной памяти или неподдерживаемой архитектуры процессора.

Таблица 5 — Скорость работы алгоритмов, сек

	ПК	Raspberry PI 4B	Raspberry PI Zero
Метод яркости	3	4	16
SVD	8	14	19
CNN	2	3	—
MobileNetV3	2	3	—

Персональный компьютер ожидаемо показывает наилучшую производительность среди всех платформ благодаря мощному 8-ядерному процессору и 16 ГБ оперативной памяти. На нём метод яркости обрабатывает кадр за 3 секунды, SVD — за 8 секунд, а обе нейросетевые модели всего за 2 секунды.

Raspberry Pi 4 Model B показывает следующие результаты: метод яркости требует 4 секунды на кадр, SVD 14 секунд, нейросети по 3 секунды. Увеличение времени по сравнению с ПК составляет от 25% для нейросетей до 75% для SVD. Важно отметить, что нейросетевые модели на Raspberry Pi 4 работают практически одинаково быстро, что делает их предпочтительным выбором благодаря значительно более высокой точности по сравнению с

методом яркости. SVD занимает 14 секунд, что уже может быть критично для работы в реальном времени при высокой скорости конвейера.

Raspberry Pi Zero W демонстрирует крайне низкую производительность на всех алгоритмах, которые вообще способен запустить. Нейросетевые модели CNN и MobileNetV3 не могут быть запущены на Raspberry Pi Zero W из-за отсутствия поддержки необходимых инструкций ARM-процессором. Таким образом, Raspberry Pi Zero W следует признать непригодным для использования в информационной системе. Более наглядное сравнение производительности показано на рисунке 17.




Рисунок 17 — Сравнение производительности вычислительных узлов

По критерию точности классификации наилучшие результаты в среднем по пяти датасетам показывают базовая CNN и MobileNetV3. По критерию скорости обе нейросетевые модели работают одинаково быстро, что делает их предпочтительным выбором для большинства сценариев. SVD-метод занимает промежуточное положение по точности, но проигрывает нейросетям в скорости. Метод яркости является самым быстрым после нейросетей, но на сложных сценах он полностью неприменим. Raspberry Pi Zero W не рекомендуется к использованию в системе из-за неприемлемо низкой производительности и невозможности запуска нейросетевых моделей.

ЗАКЛЮЧЕНИЕ

В рамках данной научно-исследовательской работы на тему «Информационная система классификации предметов на горизонтальном конвейере» была разработана и реализована информационная система, предназначенная для автоматического распознавания объектов, перемещающихся по конвейерной ленте. В ходе работы были решены все поставленные задачи: проведён анализ четырёх методов классификации изображений, разработана архитектура системы, реализованы алгоритмы обработки потока изображений, выполнено экспериментальное тестирование на пяти наборах данных с оценкой точности и производительности на трёх вычислительных платформах.

Метод яркости показал ограниченную применимость. Он эффективен только на контролируемых наборах с геометрически различными объектами, но полностью неприменим на цветных объектах и сложных сценах. Производительность метода на Raspberry Pi 4 составляет 4 секунды на кадр, что приемлемо для медленных конвейеров.

SVD-метод, реализованный на Julia, продемонстрировал более широкую область применимости, работая на всех пяти наборах. Производительность SVD на Raspberry Pi 4, составляющая 14 секунд на кадр, является основным ограничением для использования в реальном времени.

Базовая свёрточная нейронная сеть подтвердила статус наиболее точного алгоритма в среднем по всем наборам. Скорость обработки на Raspberry Pi 4 составляет 3 секунды на кадр, это лучший показатель среди всех алгоритмов на данной платформе.

MobileNetV3 показала более высокий результат, иногда превосходя базовую CNN по метрикам качества благодаря эффективному использованию предобученных признаков ImageNet. По скорости работы MobileNetV3 сопоставима с базовой CNN.

Raspberry Pi Zero W признан непригодным для использования в системе: метод яркости работает за 16 секунд на кадр, SVD за 19 секунд, а нейросетевые модели вовсе не запускаются из-за ограничений архитектуры процессора.

Для промышленного внедрения информационной системы на горизонтальном конвейере рекомендуется использовать Raspberry Pi 4 Model B как оптимальную платформу по соотношению производительности, энергопотребления и стоимости. А алгоритмами для распознавания объектов должны стать нейросетевые модели, которые обошли по показателям классические методы компьютерного зрения.

Таким образом, цель научно-исследовательской работы — разработка и программная реализация информационной системы для классификации предметов на горизонтальном конвейере, а также сравнение четырёх алгоритмов распознавания на данных разной сложности для выбора наиболее стабильного решения — достигнута в полном объёме.

СПИСОК ИСПОЛЬЗУЕМЫХ ИСТОЧНИКОВ

- [1] Документация ArduinoIDE. [Электронный ресурс] — URL: <https://docs.arduino.cc/software/ide/> (дата обращения: 02.10.2024)
- [2] Документация Python. [Электронный курс] – URL: <https://docs.python.org/3/> (дата обращения: 26.09.2025)
- [3] Документация NodeMCU. [Электронный ресурс] — URL: <https://nodemcu.readthedocs.io/en/release/> (дата обращения: 08.10.2024)
- [4] Документация OVM2640 Camera. [Электронный ресурс] — URL: <https://www.ovt.com/products/ovm2640> (дата обращения: 03.10.2024)
- [5] Документация Julia. [Электронный ресурс] — URL: <https://docs.julialang.org/en/v1/> (дата обращения: 26.09.2025)
- [6] LinearAlgebra в языке Julia. [Электронный ресурс] — URL: <https://docs.julialang.org/en/v1/stdlib/LinearAlgebra/> (дата обращения: 04.10.2025)
- [7] В. В. Воеводин, — "Численные методы алгебры. Теория и алгоритмы". 1977
- [8] Дж. Голуб, Ч. Ван Лоун, — «Матричные вычисления». 1999
- [9] Мосин В. Г., Козловский В. Н. — Понижение размерности данных методом SVD на примере данных о потреблении контента. Известия Тульского государственного университета. 2024.
- [10] Ричард О. Дуда, Дэвид Г. Сторк, Питер Э. Харт, — «Классификация образов». 2000 — Richard O. Duda, David G. Stork, Peter E. Hart, — «Pattern Classification». 2000