



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ _____ «Информатика и системы управления»

КАФЕДРА _____ «Теоретическая информатика и компьютерные технологии»

Домашнее задание №2

«Построение вероятностной модели (обобщённый парадокс
Монти Холла)»
по курсу «Моделирование»

Студент: Аригин М.А.

Группа: ИУ9-82Б

Преподаватель: Домрачева А.Б.

Москва 2026

1 Постановка задачи

За одной из N дверей находится приз, за остальными дверями пусто. Игрок выбирает одну дверь равновероятно. Ведущий, не открывая выбранную дверь и не открывая дверь с призом, открывает ровно K пустых дверей (число K удовлетворяет условию $1 \leq K \leq N - 2$). После этого игрок с вероятностью s сохраняет первоначальный выбор и с вероятностью $1 - s$ меняет его, равновероятно выбирая одну из оставшихся закрытых дверей, отличную от текущего выбора.

Цель работы:

- описать эксперимент через введение событий A , B и **формулу Байеса** для апостериорных вероятностей положения приза;
- по полученным вероятностям вывести $P(W)$ для стратегий «остаться», «сменить», смешанной стратегии с параметром s и (при необходимости) байесовски оптимального решения на финальном шаге;
- реализовать модель программно и сопоставить теоретические вероятности с частотами метода Монте-Карло при разных значениях s и разным числе прогонов n ;
- для классического случая $N = 3$, $K = 1$ проверить согласованность симуляции с известными значениями парадокса Монти Холла;
- для $N = 3, \dots, 10$ и $K = 1, \dots, N - 2$ сравнить аналитику с Монте-Карло на полной сетке (в отчёте — при $s = 0,5$).

Входные параметры модели: N , K , вероятность сохранения выбора $s \in [0, 1]$, число независимых прогонов симуляции n .

Выходные данные: теоретическая вероятность выигрыша (из байесовской модели и формул для стратегии), оценка по симуляции $\hat{p}$, величина $|\hat{p} - p_{\text{теор}}|$ и (при необходимости) расстояние между эмпирической и теоретической функциями распределения индикатора успеха на $\{0, 1\}$.

2 Построение математической модели

2.1 Формализация задачи

Рассматривается **стохастическая (вероятностная) модель** дискретного случайного эксперимента. Основной аппарат — **условные вероятности и формула Байеса**: по наблюдаемому действию ведущего (событию B) пересчитываются апостериорные вероятности положения приза, после чего для выбранной стратегии на завершающем этапе вычисляется $P(W)$.

Проверка адекватности программной реализации сводится к сравнению **частоты успеха** $\hat{p}$ в длинной серии независимых прогонов с теоретическим значением $p_{\text{теор}}$, полученным из той же байесовской постановки и формул стратегии (см. (4)). Дополнительно анализируется, как при росте n уменьшается типичное отклонение $|\hat{p} - p_{\text{теор}}|$ и как меняются результаты при варьировании s .

2.2 Предположения

- приз равновероятно находится за любой из N дверей;
- первый выбор игрока равновероятен;
- ведущий выбирает набор из K открываемых пустых дверей равновероятно среди всех допустимых наборов (двери с призом и изначально выбранная игроком не открываются);
- при смене выбора игрок равновероятно берёт одну из закрытых дверей, отличных от текущей.

2.3 Байесовская модель через события A и B и стратегия Трикса

Введём события:

- A — приз находится за первоначально выбранной игроком дверью;
- B — ведущий открыл ровно K пустых дверей, не открывая дверь с призом и текущий выбор игрока, и выбрал открываемые двери равновероятно среди всех допустимых наборов.

Априори $P(A) = 1/N$, $P(\bar{A}) = (N - 1)/N$.

Если событие A истинно, то среди остальных $N - 1$ дверей все пусты и ведущий выбирает K дверей из $N - 1$ равновероятно, поэтому

$$P(B | A) = \frac{1}{C_{N-1}^K}.$$

Если A ложно, то среди остальных дверей есть одна дверь с призом, поэтому ведущий может выбрать только среди $N - 2$ пустых дверей:

$$P(B | \bar{A}) = \frac{1}{C_{N-2}^K}.$$

Тогда по формуле Байеса получаем апостериорную вероятность того, что игрок угадал с первого раза:

$$P(A | B) = \frac{P(B | A)P(A)}{P(B | A)P(A) + P(B | \bar{A})P(\bar{A})}. \quad (1)$$

После открытия K пустых дверей остаётся $N - 1 - K$ альтернативных закрытых дверей (кроме текущей). По симметрии каждая из них имеет одинаковую апостериорную вероятность

$$P(\text{приз за фиксированной альтернативной дверью} | B) = \frac{1 - P(A | B)}{N - 1 - K}.$$

Рациональная (байесовская) стратегия на финальном шаге — выбрать дверь с большей апостериорной вероятностью. В частности, если

$$\frac{1 - P(A | B)}{N - 1 - K} > P(A | B),$$

то выгодно **менять** выбор; иначе выгодно **оставаться**.

Стратегия Трикса — это частный случай стратегии игрока: **всегда менять** выбор на финальном шаге. В обозначениях работы это соответствует $s = 0$ и совпадает с «переключением» в классическом парадоксе Монти Холла.

2.3.1 Вероятность выигрыша

Обозначим через W событие «игрок выиграл». При стратегии «всегда оставаться» ($s = 1$) выигрыш тогда и только тогда, когда первый выбор совпал с призом:

$$P(W \mid \text{остаться}) = \frac{1}{N}. \quad (2)$$

При стратегии «всегда менять» ($s = 0$) разобьём по полной вероятности на случаи «первый выбор верный» и «первый выбор неверен». Если игрок сразу угадал приз (вероятность $1/N$), после открытия K пустых среди остальных дверей все ещё закрытые альтернативы пусты, и смена ведёт к проигрышу. Если первый выбор неверен (вероятность $(N - 1)/N$), приз находится среди $N - 1$ остальных дверей; ведущий открывает K пустых из них, остаётся $N - 1 - K$ закрытых «чужих» дверей, ровно одна из которых с призом. Игрок равновероятно выбирает одну из этих $N - 1 - K$ дверей, откуда

$$P(W \mid \text{сменить}) = \frac{N - 1}{N} \cdot \frac{1}{N - 1 - K} = \frac{N - 1}{N(N - 1 - K)}. \quad (3)$$

Смешанная стратегия с вероятностью s сохранить выбор даёт

$$P(W) = s \cdot \frac{1}{N} + (1 - s) \cdot \frac{N - 1}{N(N - 1 - K)}. \quad (4)$$

Классический парадокс Монти Холла соответствует $N = 3$, $K = 1$: $P(W \mid s = 1) = 1/3$, $P(W \mid s = 0) = 2/3$. Эти же значения получаются из (2)–(4) и согласуются с качественным выводом по апостериорным вероятностям после действия ведущего.

На рис. 1 схематически показаны априорное ветвление по A и $\bar{A}$, условные вероятности наблюдения B в виде $1/C_{N-1}^K$ и $1/C_{N-2}^K$, формула Байеса и итоговые вероятности победы/поражения при чистых стратегиях; смешанная стратегия (4) — выпуклая комбинация крайних случаев.




Рисунок 1 Схема байесовской вероятностной модели: ветвление по A и $\bar{A}$, наблюдение B , пересчёт $P(A | B)$, затем исходы победы/поражения при чистых стратегиях.

3 Решение вычислительных задач

3.1 Метод Монте-Карло

Для фиксированных N, K , s независимо моделируется большое число n партий; оценка вероятности выигрыша — выборочная доля $\hat{p} = (\text{число побед})/n$. Теоретическое значение $p_{\text{теор}}$ берётся из той же постановки, что и аналитика: для смешанной стратегии — по (4), для «всегда оставаться» и «всегда менять» — как частные случаи.

3.2 Согласование с классическим случаем

Теоретические вероятности $p_{\text{теор}}$ для $N = 3$, $K = 1$ совпадают с (4) при $s = 1$ и $s = 0$ (то есть с $1/3$ и $2/3$). Симуляция сравнивается с этими значениями напрямую: $|\hat{p} - p_{\text{теор}}|$ и

$$D_n = \sup_x |F_n(x) - F(x)| = |\hat{p} - p_{\text{теор}}|$$

для индикатора успеха (ступенчатая F на $\{0, 1\}$). Величина $D_{\text{кр}} \approx k_{0,05}/\sqrt{n}$, $k_{0,05} = 1,36$, взята из формулы Колмогорова для *непрерывного* закона и для индикатора служит лишь грубым ориентиром по масштабу возможного отклонения при большом n (буквальная интерпретация критерия здесь неприменима).

3.3 Сеточный эксперимент по (N, K)

Для каждой пары (N, K) при фиксированном s (в программе по умолчанию $s = 0,5$) вычисляется $p_{\text{теор}}$ по (4) и оценка $\hat{p}$ по n симуляциям.

3.4 Варьирование s и n

Дополнительно фиксируются $N = 7$, $K = 3$ и перебираются: (1) набор значений $s \in \{0, 0,25, 0,5, 0,75, 1\}$ при $n = 50000$; (2) набор объёмов $n \in \{10, 100, 1000, 10000, 50000, 100000\}$ при $s = 0,5$. Цель — показать чувствительность $\hat{p}$ к малым n и к выбору смешанной стратегии при неизменной структуре байесовской постановки.

4 Практическая реализация

Listing 1: Модель

```
1 from __future__ import annotations
2 import argparse
3 import json
4 import math
5 import os
6 from dataclasses import dataclass
7 import numpy as np
```

```

8
9 def theoretical_win_prob(N: int, K: int, prob_stay: float) -> float:
10     if N < 3 or K < 1 or K > N - 2:
11         raise ValueError('require N>=3 and 1<=K<=N-2')
12     if not 0.0 <= prob_stay <= 1.0:
13         raise ValueError('prob_stay must be in [0,1]')
14     p_stay = 1.0 / N
15     p_switch = (N - 1) / (N * (N - 1 - K))
16     return prob_stay * p_stay + (1.0 - prob_stay) * p_switch
17
18 def posterior_choice_has_prize(N: int, K: int) -> float:
19     if N < 3 or K < 1 or K > N - 2:
20         raise ValueError('require N>=3 and 1<=K<=N-2')
21     c1 = math.comb(N - 1, K)
22     c2 = math.comb(N - 2, K)
23     num = 1.0 / N * (1.0 / c1)
24     den = num + (N - 1) / N * (1.0 / c2)
25     return num / den
26
27 def theoretical_win_prob_bayes_opt(N: int, K: int) -> float:
28     p_choice = posterior_choice_has_prize(N, K)
29     p_alt = (1.0 - p_choice) / (N - 1 - K)
30     return 1.0 - p_choice if p_alt > p_choice else p_choice
31
32 def run_monte_carlo(N: int, K: int, prob_stay: float, n_trials: int, seed: int |
33     ↪ None=42) -> tuple[np.ndarray, float]:
34     rng = np.random.default_rng(seed)
35     prize = rng.integers(0, N, size=n_trials)
36     choice = rng.integers(0, N, size=n_trials)
37     stay = rng.random(n_trials) < prob_stay
38     wins = np.zeros(n_trials, dtype=np.int8)
39     for i in range(n_trials):
40         c_open = [d for d in range(N) if d != choice[i] and d != prize[i]]
41         idx = rng.choice(len(c_open), size=K, replace=False)
42         opened = {c_open[int(j)] for j in idx}
43         closed = [d for d in range(N) if d not in opened]
44         if stay[i]:
45             final_door = int(choice[i])
46         else:
47             alt = [d for d in closed if d != choice[i]]
48             final_door = int(choice[i]) if not alt else int(rng.choice(alt))
49         wins[i] = 1 if final_door == prize[i] else 0
50     return (wins, float(wins.mean()))
51
52 def run_monte_carlo_strategy(N: int, K: int, n_trials: int, strategy: str, prob_stay:
53     ↪ float=0.5, seed: int | None=42) -> tuple[np.ndarray, float]:
54     strategy = strategy.lower().strip()

```

```

53     if strategy not in {'stay', 'switch', 'mixed', 'bayes'}:
54         raise ValueError('strategy must be one of: stay, switch, mixed, bayes')
55     if strategy == 'stay':
56         return run_monte_carlo(N, K, prob_stay=1.0, n_trials=n_trials, seed=seed)
57     if strategy == 'switch':
58         return run_monte_carlo(N, K, prob_stay=0.0, n_trials=n_trials, seed=seed)
59     if strategy == 'mixed':
60         return run_monte_carlo(N, K, prob_stay=prob_stay, n_trials=n_trials,
        ↪ seed=seed)
61     p_choice = posterior_choice_has_prize(N, K)
62     p_alt = (1.0 - p_choice) / (N - 1 - K)
63     do_switch = p_alt > p_choice
64     return run_monte_carlo(N, K, prob_stay=0.0 if do_switch else 1.0,
        ↪ n_trials=n_trials, seed=seed)
65
66 def cdf_distance_bernoulli(p_hat: float, p0: float) -> float:
67     return abs(p_hat - p0)
68
69 def ks_critical_approx(alpha: float, n: int) -> float:
70     k_table = {0.1: 1.23, 0.05: 1.36, 0.02: 1.52, 0.01: 1.63}
71     if alpha not in k_table:
72         raise ValueError(f'alpha must be one of {list(k_table)}')
73     return k_table[alpha] / math.sqrt(n)
74
75 @dataclass
76 class AdequacyRow:
77     strategy: str
78     n: int
79     wins: int
80     p_hat: float
81     p_theory_bayes: float
82     abs_diff: float
83     D_n: float
84     D_crit_005: float
85
86 def adequacy_monty_hall_classic(n_trials: int=200000, seed: int=42) ->
        ↪ list[AdequacyRow]:
87     rows: list[AdequacyRow] = []
88     for name, s, p0 in [('stay (s=1)', 1.0, theoretical_win_prob(3, 1, 1.0)), ('switch
        ↪ (s=0)', 0.0, theoretical_win_prob(3, 1, 0.0))]:
89         wins_arr, _ = run_monte_carlo(3, 1, s, n_trials, seed=seed + hash(name) %
        ↪ 10000)
90         k = int(wins_arr.sum())
91         p_hat = k / n_trials
92         D_n = cdf_distance_bernoulli(p_hat, p0)
93         D_cr = ks_critical_approx(0.05, n_trials)

```

```

94         rows.append(AdequacyRow(strategy=name, n=n_trials, wins=k, p_hat=p_hat,
    ↪ p_theory_bayes=p0, abs_diff=abs(p_hat - p0), D_n=D_n, D_crit_005=D_cr))
95     return rows
96
97 def grid_experiment(n_trials: int, prob_stay: float, seed: int) -> list[dict]:
98     out = []
99     for N in range(3, 11):
100         for K in range(1, N - 1):
101             if K > N - 2:
102                 continue
103             p_th = theoretical_win_prob(N, K, prob_stay)
104             _, p_mc = run_monte_carlo(N, K, prob_stay, n_trials, seed=seed + N * 100 +
    ↪ K)
105             out.append({'N': N, 'K': K, 'p_theory': p_th, 'p_mc': p_mc, 'abs_diff':
    ↪ abs(p_th - p_mc)})
106     return out
107
108 def sweep_n_trials(N: int, K: int, prob_stay: float, n_list: list[int], seed: int) ->
    ↪ list[dict]:
109     p_theory = theoretical_win_prob(N, K, prob_stay)
110     out = []
111     for n in n_list:
112         _, p_mc = run_monte_carlo(N, K, prob_stay, n, seed=seed + n)
113         out.append({'N': N, 'K': K, 'prob_stay': prob_stay, 'n_trials': n, 'p_theory':
    ↪ p_theory, 'p_mc': p_mc, 'abs_diff': abs(p_theory - p_mc)})
114     return out
115
116 def sweep_prob_stay(N: int, K: int, s_list: list[float], n_trials: int, seed: int) ->
    ↪ list[dict]:
117     out = []
118     for s in s_list:
119         p_th = theoretical_win_prob(N, K, s)
120         _, p_mc = run_monte_carlo(N, K, s, n_trials, seed=seed + int(s * 10000))
121         out.append({'N': N, 'K': K, 'prob_stay': s, 'p_theory': p_th, 'p_mc': p_mc,
    ↪ 'abs_diff': abs(p_th - p_mc)})
122     return out
123
124 def plot_figures(out_dir: str, seed: int=42) -> None:
125     import matplotlib.pyplot as plt
126     os.makedirs(out_dir, exist_ok=True)
127     N = 7
128     Kmax = N - 2
129     s_vals = np.linspace(0, 1, 101)
130     plt.figure(figsize=(7, 4.5))
131     for K in range(1, Kmax + 1):
132         ys = [theoretical_win_prob(N, K, float(s)) for s in s_vals]
133         plt.plot(s_vals, ys, label=f'K={K}')

```

```

134 plt.xlabel('stay probability $s$')
135 plt.ylabel('$P(\mathrm{win})$')
136 plt.title(f'Theory: $N={N}$, mixed strategy')
137 plt.legend()
138 plt.grid(True, alpha=0.3)
139 plt.tight_layout()
140 plt.savefig(os.path.join(out_dir, 'hw2_prob_vs_switch.png'), dpi=150)
141 plt.close()
142 n_mc = 80000
143 prob_stay = 0.5
144 Ks = list(range(1, N - 1))
145 p_th = [theoretical_win_prob(N, K, prob_stay) for K in Ks]
146 p_mc = []
147 for K in Ks:
148     _, ph = run_monte_carlo(N, K, prob_stay, n_mc, seed=seed + K)
149     p_mc.append(ph)
150 plt.figure(figsize=(7, 4.5))
151 plt.plot(Ks, p_th, 'o-', label='analytic')
152 plt.plot(Ks, p_mc, 's--', label=f'Monte Carlo ($n={n\_mc}$)')
153 plt.xlabel('$K$')
154 plt.ylabel('$P(\mathrm{win})$')
155 plt.title(f'$N={N}$, $s={prob\_stay}$')
156 plt.legend()
157 plt.grid(True, alpha=0.3)
158 plt.tight_layout()
159 plt.savefig(os.path.join(out_dir, 'hw2_theory_vs_mc_N7.png'), dpi=150)
160 plt.close()
161
162 def main() -> None:
163     p = argparse.ArgumentParser()
164     p.add_argument('--n-trials', type=int, default=200000)
165     p.add_argument('--seed', type=int, default=42)
166     p.add_argument('--json-out', type=str, default='hw2_results.json')
167     p.add_argument('--plots', action='store_true')
168     p.add_argument('--strategy', type=str, default='mixed',
169         ↪ help='stay|switch|mixed|bayes (default: mixed)')
169     p.add_argument('--prob-stay', type=float, default=0.5, help='used only for
170         ↪ strategy=mixed')
170     args = p.parse_args()
171     rows = adequacy_monty_hall_classic(n_trials=args.n_trials, seed=args.seed)
172     grid_n = min(args.n_trials, 50000)
173     grid = grid_experiment(n_trials=grid_n, prob_stay=args.prob_stay, seed=args.seed)
174     n_sweep_list = [10, 100, 1000, 10000, 50000, 100000]
175     sweep_n = sweep_n_trials(N=7, K=3, prob_stay=0.5, n_list=n_sweep_list,
176         ↪ seed=args.seed)
176     s_sweep_list = [0.0, 0.25, 0.5, 0.75, 1.0]

```

```

177 sweep_s = sweep_prob_stay(N=7, K=3, s_list=s_sweep_list, n_trials=50000,
    ↪ seed=args.seed)
178 payload = {'adequacy_classic': [r.__dict__ for r in rows], 'grid_mixed_s0.5':
    ↪ grid, 'sweep_n_trials_N7_K3_s0.5': sweep_n, 'sweep_prob_stay_N7_K3_n50000':
    ↪ sweep_s, 'posterior_P_A_given_B_N3_K1': posterior_choice_has_prize(3, 1),
    ↪ 'n_trials_adequacy': args.n_trials, 'n_trials_grid': grid_n, 'strategy':
    ↪ args.strategy, 'prob_stay': args.prob_stay}
179 with open(args.json_out, 'w', encoding='utf-8') as f:
180     json.dump(payload, f, ensure_ascii=False, indent=2)
181 print('=== Adequacy (N=3, K=1), Bayes-theory vs MC ===')
182 for r in rows:
183     print(f'{r.strategy}: wins={r.wins}/{r.n}, p_hat={r.p_hat:.6f},
    ↪ p_theory={r.p_theory_bayes:.6f}, |diff|={r.abs_diff:.6f}, D_n={r.D_n:.6f},
    ↪ D_cr(0.05)~{r.D_crit_005:.6f}')
184 if args.plots:
185     plot_figures('images', seed=args.seed)
186     print('Plots saved to images/')
187 print(f'\nJSON: {args.json_out}')
188 if __name__ == '__main__':
189     main()

```

5 Результаты

5.1 Классический Монти Холл, $n = 200000$

Стратегия	Побед	$\hat{p}$	$p_{\text{теор}}$ (из (4))	$ \hat{p} - p_{\text{теор}} $	$D_{\text{кр}}$ (ориентир)
остаться ($s = 1$)	66709	0,33355	1/3	0,00021	0,00304
сменить ($s = 0$)	133152	0,66576	2/3	0,00091	0,00304

Таблица 1: Сопоставление симуляции с теорией при $N = 3$, $K = 1$ (теория — та же, что следует из постановки и (4))

Отклонения $|\hat{p} - p_{\text{теор}}|$ имеют порядок 10^{-3} – 10^{-4} и существенно меньше ориентира $D_{\text{кр}} \approx 0,00304$ при $n = 200000$.

5.2 Графики

На рис. 2 изображена теоретическая вероятность выигрыша $P(W)$ как функция s для $N = 7$ и различных K , вычисленная по формуле смешанной стратегии (4). Кривая соответствует тому же $P(W)$, что следует из байесовской по-

становки (апостериорные вероятности и выбор на финальном шаге). На рис. 3 — сопоставление этой аналитики с Монте-Карло при $s = 0,5$.




Рисунок 2 Теоретическая $P(W)$ как функция s при $N = 7$ (подписи осей на графике на английском)




Рисунок 3 $N = 7, s = 0,5$: аналитика и Монте-Карло ($n = 80000$ на каждое K ; подписи на графике на английском)

5.3 Варьирование числа прогонов n при $N = 7, K = 3, s = 0,5$

Теоретически $p_{\text{теор}} = 3/14 \approx 0,2143$. При малых n оценка $\hat{p}$ может заметно отличаться от $p_{\text{теор}}$ из-за случайных флуктуаций; при росте n отклонение в среднем уменьшается (см. табл. 2).

n	$\hat{p}$	$p_{\text{теор}}$	$ \hat{p} - p_{\text{теор}} $
10	0,10	0,2143	0,1143
100	0,20	0,2143	0,0143
1000	0,209	0,2143	0,0053
10000	0,2148	0,2143	0,0005
50000	0,2130	0,2143	0,0013
100000	0,2159	0,2143	0,0016

Таблица 2: Согласованность оценки $\hat{p}$ с теорией в зависимости от объёма выборки (один и тот же seed в программе)

5.4 Варьирование вероятности сохранения выбора s при $N = 7, K = 3, n = 50000$

s	$p_{\text{теор}}$	$\hat{p}$	$ \hat{p} - p_{\text{теор}} $
0	5/18	0,2891	0,0034
0,25	1/4	0,2481	0,0019
0,5	3/14	0,2130	0,0013
0,75	5/28	0,1769	0,0017
1	1/7	0,1429	0,0001

Таблица 3: Смешанная стратегия: разные соотношения «остаться — сменить» при фиксированном n

5.5 Полная сетка (N, K) при $s = 0,5, n = 50000$

N	K	$p_{\text{теор}}$	$p_{\text{МК}}$	$ p_{\text{теор}} - p_{\text{МК}} $
3	1	0,50000	0,49918	0,00082
4	1	0,31250	0,31224	0,00026
4	2	0,50000	0,49804	0,00196
5	1	0,23333	0,22968	0,00365
5	2	0,30000	0,30170	0,00170
5	3	0,50000	0,49848	0,00152
6	1	0,18750	0,18476	0,00274
6	2	0,22222	0,22110	0,00112
6	3	0,29167	0,29476	0,00309
6	4	0,50000	0,49790	0,00210
7	1	0,15714	0,15914	0,00200
7	2	0,17857	0,17838	0,00019
7	3	0,21429	0,21700	0,00271
7	4	0,28571	0,28698	0,00127
7	5	0,50000	0,50312	0,00312
8	1	0,13542	0,13494	0,00048
8	2	0,15000	0,15114	0,00114
8	3	0,17188	0,16840	0,00348
8	4	0,20833	0,21094	0,00261
8	5	0,28125	0,27920	0,00205
8	6	0,50000	0,49706	0,00294
9	1	0,11905	0,11878	0,00027
9	2	0,12963	0,12938	0,00025
9	3	0,14444	0,14416	0,00028
9	4	0,16667	0,16500	0,00167
9	5	0,20370	0,20400	0,00030
9	6	0,27778	0,27824	0,00046

N	K	$p_{\text{теор}}$	$p_{\text{МК}}$	$ \Delta $
9	7	0,50000	0,50078	0,00078
10	1	0,10625	0,10478	0,00147
10	2	0,11429	0,11420	0,00009
10	3	0,12500	0,12562	0,00062
10	4	0,14000	0,14038	0,00038
10	5	0,16250	0,16398	0,00148
10	6	0,20000	0,19676	0,00324
10	7	0,27500	0,27554	0,00054
10	8	0,50000	0,50026	0,00026

6 Анализ модели и проверка качества

После получения численных результатов необходимо проанализировать согласованность байесовской аналитики (формулы (1), (4)), программной реализации и данных Монте-Карло, а также проверить качество модели на граничных режимах.

6.1 Анализ результатов сравнения теории и эксперимента

Классический случай ($N = 3$, $K = 1$). По табл. 1 оценки $\hat{p}$ для стратегий «остаться» и «сменить» близки к $p_{\text{теор}}$, вычисленным из (4). При большом n типичный масштаб случайной ошибки оценки $\hat{p}$ задаётся соотношением

$$\sigma_{\hat{p}} \approx \sqrt{\frac{p(1-p)}{n}}$$

(частотная интерпретация: разброс выборочной доли при независимых повторениях). При $p \approx 1/3$ или $2/3$ и $n = 200000$ величина $\sigma_{\hat{p}}$ порядка 10^{-3} , что согласуется с наблюдаемыми $|\hat{p} - p_{\text{теор}}|$.

Влияние объёма n (табл. 2). При $n = 10$ и $n = 100$ отклонение $\hat{p}$ от $p_{\text{теор}}$ может быть заметным: для малых выборок одна и та же стохастическая модель даёт большой разброс частоты успехов. При $n \gtrsim 10^4$ оценка стабилизируется около $p_{\text{теор}}$; это согласуется с ожидаемым уменьшением $\sigma_{\hat{p}}$ при росте n .

Влияние доли s (табл. 3). При фиксированных N , K величина $p_{\text{теор}}$ по (4) меняется линейно по s между значениями (2) и (3). Эксперимент при разных s показывает, что симуляция воспроизводит эту линейную закономерность: наи-

большие $|\hat{p} - p_{\text{теор}}|$ в таблице остаются в пределах нескольких тысячных при $n = 50000$.

Сетка (N, K) при $s = 0,5$. В длинной таблице раздела «Результаты» для каждой пары (N, K) сопоставлены $p_{\text{теор}}$ по (4) и оценка $p_{\text{МК}}$ по $n = 50000$ прогонов.

- Во всех 36 ячейках сетки абсолютное отклонение $|\Delta| = |p_{\text{теор}} - p_{\text{МК}}|$ не превосходит 0,004; для большинства пар оно меньше 0,003.
- Наибольшие расхождения встречаются в отдельных точках (например, при малых N и малых K), что соответствует большей относительной дисперсии $\hat{p}$ при малых $p_{\text{теор}}$ при том же n .
- При фиксированном N и росте K теоретическая вероятность (4) при $s = 0,5$ монотонно возрастает от значений порядка $1/N$ до $1/2$ при $K = N - 2$; кривые на рис. 2 иллюстрируют аналогичную зависимость от s для $N = 7$.
- При $K = N - 2$ и $s = 0,5$ имеем $p_{\text{теор}} = 1/2$; строки таблицы с $K = N - 2$ показывают $p_{\text{МК}}$ около 0,5.

Графическое сопоставление. На рис. 3 для $N = 7$, $s = 0,5$ точки Монте-Карло лежат вблизи теоретической кривой по K без систематического смещения.

Показатель (полная сетка, $n = 50000$)	Значение
Число пар (N, K)	36
$\max p_{\text{теор}} - p_{\text{МК}} $	$< 0,004$
Типичный порядок $ \Delta $	10^{-3}

Таблица 5: Сводка отклонений аналитики и Монте-Карло на полной сетке

6.2 Проверка качества модели

1. Соответствие постановке задачи.

- Приз задаётся равновероятно по дверям; первый выбор игрока — равновероятный.
- Ведущий открывает ровно K пустых дверей среди допустимых; набор из K дверей выбирается равновероятно — в согласии с определением события B и формулами $P(B | A)$, $P(B | \bar{A})$.

- На финальном шаге с вероятностью s выбор сохраняется, с вероятностью $1 - s$ — переход к равновероятно выбранной другой закрытой двери.
- Логика симуляции согласована со схемой байесовской модели (рис. 1): сначала реализуются $A/\bar{A}$ и действие ведущего (B), затем — финальное решение игрока.

2. Граничные режимы.

- $N = 3, K = 1$: см. табл. 1.
- $s = 1$: $P(W) = 1/N$; $s = 0$: формула (3); при $K = N - 2$ получается $P(W) = (N - 1)/N$ при стратегии «сменить».
- Допустимые K не выходят за пределы $1 \leq K \leq N - 2$.

3. Ограничения. Модель не описывает произвольную (не равномерную) стратегию ведущего; при её изменении меняются $P(B | A)$, $P(B | \bar{A})$ и апостериорные вероятности.

7 Выводы

- Сформулирована байесовская модель через события A, B и формулу (1); получены явные выражения для $P(W)$ при стратегиях «остаться», «сменить» и смешанной стратегии (4); определена стратегия Трикса ($s = 0$).
- Реализована программная модель на Python; для $N = 3, K = 1$ частоты Монте-Карло согласуются с теоретическими $p_{\text{теор}}$ из той же постановки.
- Выполнено сравнение аналитики с Монте-Карло на сетке $N = 3, \dots, 10, K = 1, \dots, N - 2$ при $s = 0,5$; дополнительно исследованы разные s и объёмы n .