

Домрачева Анна Борисовна, annd70@mail.ru, @K_D0mrachev.

1 09.02

1.1 Решение инженерных задач на ЭВМ

Математическая модель — формализация (описание на языке формул) исследуемого объекта (процесса) реального мира. **Математическое моделирование** — метод исследования объектов и процессов реального мира с помощью их приближённых описаний посредством формул.

Построение математической модели подразумевает формализацию, в то время как *создание* математической модели предполагает проведение полного комплекса работ.

Этапы создания математической модели:

- построение математической модели — формализация конкретного объекта (процесса) реального мира;
- постановка, исследование, решение набора соответствующих вычислительных задач;
- проверка качества модели на практике, модификация модели.

Требования к модели: математическая модель — компромисс между бесконечной сложностью изучаемого явления и желаемой простотой его описания. Модель должна быть достаточно полной, чтобы оказываться полезной для изучения свойств явления, но достаточно простой, чтобы быть реализованной достаточно просто на ЭВМ.

2 12.02

- Полнота модели.
- Точность модели. Под точностью модели подразумевается вектор погрешностей для решения всех вычислительных задач, её определяющих. В ряде случаев приходится решать задачу нелинейного программирования, оптимизировать полученные точности с учётом накладываемых ограничений (пример: потеря спутника Фобоса).

объект → натурный эксперимент

физическая модель → полунатурный эксперимент

математическая модель → вычислительный эксперимент

Натурный эксперимент необходим для подтверждения адекватности мат. модели, может быть дорогим или продолжительным. Часто для подтверждения адекватности используется **полунатурный** эксперимент, где объект заменяется своей физической моделью, — дешевле, но точность ниже. Имеет значение уровень исследования.

Вычислительный эксперимент оказывается самым дешёвым, позволяет ускорять, замедлять процесс, управлять точностью модели, при этом проверка адекватности такой модели требует натурального или полунатурного эксперимента.

Основные противоречия моделирования: вычислительная модель может быть недорогой, при этом требуется натурный или полунатурный эксперимент для подтверждения её

адекватности. Для разрешения этого противоречия используют различные подходы, в том числе сравнения с модельными аналогами из других предметных областей.

2.1 Классификация моделей

На верхнем уровне классификации различают аналитическую и имитационную модели. **Аналитическая модель** учитывает все физико-химические процессы, протекающие в исследуемой системе, влияющие на решение задачи. **Имитационная модель** — модель более высокого уровня абстракции, имитирует поведение исследуемой системы на ЦВМ при заданных исходных данных в заданный или формируемый период времени.

- имитация — без цели (?) (имитировать голос);
- симуляция — с целью (?) (симулировать болезнь);
- эмуляция — техническое (эмулятор DOS).

Различают также **гипотетические модели**, в основе которых заложена гипотеза, ещё не подтверждённая на практике.

Статическая модель описывает явления в предположении, что процесс завершён. **Динамическая модель** описывает, как протекает явление, т.е. изменение соотношений системы во времени, в динамике.

Стохастическая модель предполагает, что входные данные преобразуются в выходные на основе случайных функций; входные данные также носят случайный характер.

Феноменологическая модель строится по результатам эксперимента (*браж в партии лампочек*).

Вероятностная модель (решение основной задачи теории вероятностей). **Статистическая модель** (решение основной задачи математической статистики).

Необходимо выбрать уровень исследования.

- простая статическая модель;
- простая динамическая модель;
- структурно-сложная система;
- сложная система;
- сложная система, меняющая поведение во времени;
- гибридная система.

TODO: схема

На втором этапе создания математической модели необходимо выделить основные вычислительные задачи и классифицировать их по типу:

1. **прямая задача:** по заданным входным данным $\vec{x}$ при фиксированном значении параметра p требуется найти решение $\vec{y}$ (возможно, неединственное); как правило, строят математическую модель, пригодную для описания близких по природе явлений, отличающихся параметрами;
2. **обратная задача:** по заданному вектору выходных данных при фиксированных значениях p требуется найти $\vec{x}$;

3. **задача идентификации** — задача выбора среди всевозможных моделей той, которая наилучшим образом описывает исследуемую систему (пример с деконволюцией). В узком смысле это задача выбора из заданного параметрического семейства модели с конкретными значениями, обеспечивающих лучшее решение;

Перечисленные типы задач относятся к классу **вычислительных**, для решения которых используются численные методы. Позволяют свести решение к набору арифметических операций над входными данными.

TODO: корректность задачи по Адамару (непрерывность, etc.)

Далее модифицируется или выбирается численный метод из группы (прямые, аппроксимации, итерационные, Монте-Карло) (выбираются по точности или сохранению ресурсов).

Для подтверждения адекватности модели необходимо верифицировать результат, убедиться, что полученных данных и заявленной точности достаточно для принятия управленческого решения.

В моделировании задачи классифицируются на экономические, инженерные и научные. **Экономические задачи** не предполагают применение численных методов, а базируются на решении линейных уравнений и систем. **Инженерные задачи** — всё, что характеризуется большим объёмом вычислений с применением численных методов. При этом объём вычислений конечен. В **научных** задачах объём вычислений не ограничен, такие задачи могут иметь отрицательный результат.

Если задача не имеет решения, переопределяют наборы входных данных и параметров, в ряде случаев неизвестные переносятся в параметры и оцениваются в рамках другого эксперимента.

Решение инженерной задачи:

1. Постановка задачи.
2. Выбор или построение мат. модели.
3. Постановка вычислительных задач.
4. Предварительный, предмашинный, анализ свойств вычислительных задач.
5. Выбор и построение численного метода.
6. Алгоритмизация и программирование.
7. Отладка программы, валидация, верификация результатов.
8. Счёт по программе.
9. Анализ и интерпретация результатов.
10. Выводы, использование результатов, коррекция мат. модели.

Методика построения динамической аналитической модели.

- Рисуются графическая схема, обозначающая процесс.
- На схеме обозначаются, уточняются начальные, конечные входные данные. Выделяются переменные, которые могут выполнять роль выходных данных и параметров.
- Определяются физико-химические воздействия на объект, влияющие на решение задачи, по возможности фиксируется на схеме.
- Оценивается возможность упрощения модели

- Формулируется на языке формул общие уравнения, равенства, неравенства, описывающие процессы, связывающие входные и выходные данные. Такое уравнение суммирует все определённые на предыдущем этапе воздействия.
- На этом этапе проводится проверка размерности уравнений (одинаковые единицы измерения). Проверяется соответствие единиц измерения величин.
- На следующем шаге повторно конкретизируется описания воздействий, могут быть переопределены входные, выходные данные, набор параметров, а также переоценена возможность упрощения модели, чтобы построенная модель позволила оценить все неизвестные.
- Если модель признается неадекватной процессу реального мира или объекта, то она должна быть модифицирована.

3 17.02

3.1 Имитационное моделирование

Имитационная модель позволяет имитировать поведение реальной системы на ЦВМ при заданных исходных данных без учёта физико-химических воздействий на исследуемую систему.

Имитация — численный метод проведения на ЦВМ экспериментов с математической моделью в заданный или формируемый период времени (когда нельзя сразу получить конечный результат).

Пример структурно-сложной модели — "Катюша" с несколькими одновременно запускаемыми ракетами.

Система называется **сложной**, если одновременно в ней функционируют несколько компонент, причём функционирование компонент взаимосвязано. Декомпозиция системы на компоненты производится с учётом структуры проектируемого или изучаемого объекта. Если взаимодействие компонент мало влияет на решение задачи, им можно пренебречь и рассматривать совокупность нескольких простых динамических систем, описываемых совокупностью обыкновенных дифференциальных уравнений.

Если взаимодействием пренебречь нельзя, то рассматривается **структурно-сложная** динамическая система.

В основе таких моделей лежит элемент-блок со скрытой от внешнего наблюдателя внутренней структурой. Видимыми в этом случае являются специальные переменные, называемые *контактными*. Так, выходные данные одного блока могут оказываться входными данными для другого блока. Будем называть такие связи функциональными за счёт инкапсуляции свойств конкретной компоненты в соответствующем ей блоке. Блок может менять схему своего функционирования, параметры, что не приведёт к изменению структуры модели. В общем случае компоненты могут описывать неоднотипные компоненты — главное, чтобы изменение или появление их в процессе вычислительного эксперимента не меняло функциональные связи описываемой системы. Таким образом, имея набор компонент с достаточно простыми законами поведения, можно сконструировать любую математическую модель. Недостатком является ограничение на сложность и работа за не всегда приемлемое время.

Отличают **сложные динамические системы**, меняющие своё поведение во времени. Т.е. система имеет несколько качественно различных *последовательно* меняющихся друг

друга поведений. Смена режима функционирования иллюстрируется **временной диаграммой**, см. [рис. 3.1](#). При переключении режимов функционирования (*стояла машина на месте, набрала скорость 60 км/ч*) реализуется **переходный процесс**, также воздействующий на исследуемую систему. В ряде случаев можно исключить рассмотрение переходного процесса из решения задачи, вынося его в дополнительную, прикладную задачу. Поскольку в каждом из дискретных состояний элементарный блок ведёт себя как некоторая непрерывная система, то в целом поведение является дискретно-непрерывным или гибридным. Гибридная карта состояний представляет собой простую 'и очень наглядную форму визуального представления смены поведений.

Объединяя структурно сложные системы и гибридные мы получаем **структурно-сложные гибридные системы**. Главная особенность — параллельное функционирование нескольких гибридных систем.




Рис. 3.1: Иллюстрации к лекции 17.02 (1)

4 19.02

Если число неизвестных в модели больше числа уравнений, нужно параметризовать какие-то переменные или поставить дополнительные задачи для вычисления переменных или упростить модель. Нужна проверка размерности. Моделирование всегда начинается с рисунка.

4.1 Модельное время как способ организации имитационной модели

Реальное время — аналоговое (непрерывное) время протекания процессов и изменения состояния объектов в реальном мире. Измеряется в секундах, минутах, т.д.

Вычислительное время — аналоговое время вычисления (проведения вычислительного эксперимента) на ЦВМ. Измеряется в нано-, миллисекундах, т.д. (если ≈ 60 с., ожидание считается "долгим" (*стоит подумать о распараллеливании задачи?*)).

Модельное время — дискретное время, измеряемое в единицах реального времени, используемое для синхронизации (внутренней и внешней) имитационной модели.

В имитационном моделировании рассматривают два подхода: выбор модельного времени (синхронизация) с постоянным шагом и выбор модельного времени с переменным шагом.

Постоянный шаг: разбиение на n одинаковых отрезков, называемых **квантами времени**.

Если в одном кванте времени для разных компонент оказалось ≤ 1 событий, система начинает расчёт, причём моделирование нового состояния для каждой компоненты происходит независимо от времени его изменения в реальном мире. В результате изменённые состояния характеризуются новым набором переменных, которые выкладываются в специальный массив, называемый **информационным полем**, см рис. 4.1.

Если ≥ 2 событий для хотя бы одной любой компоненты оказались инициированы в одном кванте модельного времени, соответствующий промежуток делится пополам. При необходимости — ещё пополам, чтобы в одном кванте времени для этой компоненты оказалось по одному событию.

Если для всех компонент системы в пределах кванта времени не происходит изменения состояния, этот квант времени не моделируется.

Таким образом, шаг модельного времени оказывается непостоянным, и говорят о выборе модельного времени с **постоянно-переменным шагом**.

Чисто переменный шаг, как правило, не используется (?).

Методика построения имитационной модели

0. Постановка задачи (т.е. есть набор входных данных).
1. Декомпозиция системы на отдельные компоненты.
2. Выделение режимов функционирования системы.
3. Анализ взаимосвязей компонент и переходных процессов между режимами функционирования с целью представления исходной системы в виде набора простых динамических систем.
4. Анализ гибридной карты системы и построение информационного поля модели (для обеспечения взаимодействия). Определение переменной модельного времени.
5. Формализация.
6. Преобразование формального описания в имитационную модель.
7. Программирование, отладка; валидация, верификация модели; проверка адекватности модели; при необходимости — модификация.

Пункты 1–3 — концептуальное проектирование.

4.2 Организация квазипараллелизма в имитационной модели

Организация квазипараллелизма необходима при моделировании в реальном масштабе времени, а также при организации последовательных расчётов для компонент, функционирующих параллельно в реальном мире.

Подходы к организации квазипараллелизма:

1. **Имитация активностями** (организация активностями). Под активностью понимается кортеж вида $Act_{ij} = \{Al_{ij}, \tau_{ij}\}$. Al_{ij} — алгоритм, соответствующий TODO; τ_{ij} — дискретное значение модельного времени, соответствующее наступлению состояния




Рис. 4.1: Иллюстрации к лекции 19.02 (1)

- j для компоненты i . Как правило, применяется для систем с небольшим количеством компонент и, соответственно, их состояний; обеспечивает высокую точность моделирования. Прост в организации.
- Событийный подход** (организация событиями). $s_{ij} \in S_i = \{s_{ij}^*, \tau_{ij}\}$; в этом случае под s_{ij} подразумевается событие j компоненты i , а s_{ij}^* — его упрощённая формализация. s_{ij}^* отличается от алгоритма, т.к. является глобальной переменной, принимающей счётное количество значений. Применяется при составлении расписаний (занятий, поездов, т.д.), если не требуется для решения задачи более подробное описание состояний системы. Достоинства: компактность, простота реализации, вычислений нет — только присваивание значений; недостаток — узкая специализация.
 - Транзактный подход** (организация транзактами). $T_i = \{D_i, \sum_k \tau_{ij}^k\}$ (j -я операция для i -й заявки). D_i — дисциплина обработки заявки (система массового обслуживания; сколько очередей, сколько устройств: количество мастеров, окон регистрации, официантов). Транзакт — заявка, определяемая дисциплиной обслуживания; коррекция модельного времени зависит от суммы реального времени, отводимого на ожидание, обработку и деинициацию заявки.
 - Процессный подход** (организация процессами). (объекты описываются очень примитивно; процессы выходят на первую очередь). $p_i = \{p_i^*, \sum_k \tau_{ij}^k\}$, где p_i^* — приближённое описание процесса, ... — величина модельного времени.
 - Агрегатный подход**. $A_i(A_{i-1}, \Theta_i)$ — условное обозначение агрегата; A_0 — сотрудники, $i = 1, \dots, n$. См. [рис. 4.2](#). Часть процедур выполняется последовательно, часть — параллельно. Θ_i — модельное время параллельной работы звеньев агрегата.




Рис. 4.2: Иллюстрации к лекции 19.02 (2)

В зарубежной литературе подходы 1 и 2 объединяют в дискретно-событийный подход; подходы 3 и 4 — в агентный подход.

5 26.02

1. Внешняя и внутренняя синхронизация компонент модели.
2. Синхронизация моментов появления информации для передачи её другим компонентам в системе.
3. Описание поведения компонент при появлении конфликтных ситуаций в модели.
4. Уточнение состава исходной информации для имитации.
5. Организация окончания имитации.
6. Реализация контроля за ходом имитации.
7. Организация сбора статистики.
8. Разработка документации модели.

Переход от формального описания к имитационной модели осуществляется на основе декомпозиции сложной системы на основные части — компоненты. Каждой компоненте ставим в соответствие временную координату — модельное время. Добавление операторов преобразования модельного времени к алгоритму или описанию состояния компоненты более или менее подробному превращает непосредственно описание в имитационную модель. Если требуется дополнительная декомпозиция компонент на несколько более мелких, дробится и интервал модельного времени, и непосредственно алгоритм. Т.к. для активностей

и агрегатов процедура разделения алгоритмов (добавления алгоритмов) и изменения временных координат происходит на этапе формализации, подобная синхронизация не нужна. При организации другими способами (событиями, процессами, транзактами) функция возлагается на ПМ (программу моделирования).

Внутренняя синхронизация компонент обеспечивается с помощью семафоров — глобальных переменных, значение которых либо запрещает, либо разрешает активизацию имитатора компоненты в модельном времени. В случае запрета активизации все компоненты модели выстраиваются в очередь. Обслуживание производится согласно приоритетам. Сброс семафора приводит к активации составляющих его компонент.

Кроме транзактного подхода, другие виды организации вырабатывают управляющие сигналы.

При процессном способе (кроме семафоров) необходимо установить операторы взаимодействия между процессами.

Внешняя синхронизация реализуется, как правило, через операторы синхронизации компонент в дискретном времени. Различают два вида операторов:

1. оператор немедленного перевода процесса в ждущее состояние;
2. оператор ... в ждущее состояние до выполнения некоторого условия.

... операторами алгоритм функционирования компоненты делится на части. В момент перехода в новое состояние происходит коррекция модельного времени.

Важно, чтобы результаты функционирования в пределах некоторого кванта времени появились в информационном поле не ранее, но и не позднее некоторого момента времени.

Формально при изменении состоянии системы компоненты получают сведения об измененном состоянии мгновенно. В случае программной реализации это происходит в течение всего кванта модельного времени, которое может быть более или менее протяжённым (лучше, если согласуется с работой в реальном времени). Так осуществляется синхронизация модели управления информацией: используют рабочий массив, доступный только для данного процесса, и оператор условного ожидания некоторого момента времени. До наступления этого момента в рабочий массив (информационное поле) переписываются показатели нового состояния всех компонент системы. При наступлении этого момента сформированный рабочий массив становится доступен всем компонентам системы для считывания обновлённой информации.

5.1 Отражение конфликтных ситуаций модели

Синхронизация процессов друг с другом осуществляется за счёт операторов запуска и останова процессов.

Между приостановом и запуском исключается одновременное обращение разных компонент к одному и тому же ресурсу, обработка проводится последовательно: либо по приоритету, либо по порядковому номеру.

5.2 Уточнение исходной информации при моделировании

При всех схемах моделирования разрабатывается отдельный блок задания начальных условий имитации. Реализуется однократно, в рамках этого блока устанавливается и режим моделирования.

... При имитации событий, событие — инициатор, при имитации процессов, процесс — инициатор. В функции инициатора входит установка каждого примитива модели (ак-

тивность, событие, транзакт, т.д.) в начальное состояние перед имитацией. Сохранение текущей информации о начальных условиях ... задаёт условия и действия, при которых начальные данные могут быть изменены. Действие инициатора аналогично конструктору.

Организация окончания имитации. Любому конструктору, иницирующему действие конкретной компоненты, ставится в соответствие деструктор, отражающий последовательность действий при окончании имитации. Так как имитационный эксперимент может многократно повторяться (в том числе с новыми данными), необходимо закрыть открытые файлы, деиницировать информационное поле, чтобы обеспечить начало нового имитационного эксперимента.

Контроль за ходом имитации. Реализуется соответствующий блок, чтобы принимать решение об окончании имитации. При длительной работе копируется состояние модели, работа с которой может прерываться и возобновляться.

Организация сбора статистики. Устанавливаются операторы сбора статистики (наблюдатели модели). Они фиксируют время жизни объекта в модели, количество обработанных объектов за заданное время, число отказов функционирования компоненты, число взаимодействий текущих компонент с другими компонентами и пр. Статистика позволяет диагностировать работоспособность системы, подтверждать адекватность модели при заданных начальных условиях и определённых ограничениях.

Результат этапа — описание имитационной модели, на основе которого она программируется посредством выбранных программных средств. Описание модели снижает затраты при изменении состава разработчиков системы, поддерживает диагностику модели при изменении входных данных и ограничений,

5.3 Система массового обслуживания

Объектами проектирования на системном уровне являются такие сложные системы, как предприятия, транспортные системы, вычислительные системы и сети, системы автоматизированного проектирования. В этих приложениях анализ функционирования систем связан с прохождением потока заявок. Примеры: детали, которые обрабатываются на разных станках; клиенты, которые обслуживаются на кассах.

Разработчиков подобных систем интересуют производительность, продолжительность обслуживания, количество потерянных клиентов, эффективность используемого оборудования.

Параметры заявок, поступающих на вход, являются случайными величинами и при проектировании могут быть известны законы их распределения и параметры этих распределений.

В качестве математического аппарата моделирования принимают теорию массового обслуживания; качестве моделей — системы массового обслуживания. В простейшем случае система массового обслуживания — это некоторое средство (устройство, прибор, канал, обслуживающий автомат) вместе с очередями заявок на входе.

Приборы все в совокупности рассматриваются как статические объекты системы массового случая. Каждый из них называется **каналом**.

С другой стороны, транзакты — сами заявки — рассматриваются как динамические объекты, на вход системы могут поступать транзакты с разными законами распределения (или имеющие один закон, но с разными параметрами). В СМО предполагается упрощение — состояние аппарата выражается булевой величиной: статус транзакта 0 — необработанный транзакт, 1 — обработанный транзакт. Состояния могут быть описаны дискретно с обозначениями от 0 до n .

Системы массового обслуживания подразделяются на **одно-** и **многофазные** (последовательная обработка на нескольких устройствах); **одно-** и **многоканальные** (параллельная обработка на нескольких устройствах).

В **СМО с отказами** (очередь конечной длины) заявка, поступившая в момент, когда все каналы заняты, получает отказ и покидает СМО, далее не обслуживается. В **СМО с очередями** (очередь бесконечной длины) заявка встаёт в очередь и ожидает обработки. Популярны беспriorитетные очереди: FIFO, LIFO, очередь со случайным выбором заявки.

Приоритет — преимущественное право на обслуживание. Рассматриваются ограничения не только на длину очереди, но и на время ожидания. В приоритетных ... выделяется своя очередь.

Заявка из очереди с низким приоритетом обслуживается, если очередь пуста. Если есть заявки с более высоким приоритетом, ожидается их исполнение. Приоритеты заявок:

- абсолютный — прерывает обработку предыдущей заявки;
- относительный — не предполагает прерывания обработки предыдущей заявки, может быть выполнена первой после неё;
- динамический — ... может меняться во время нахождения заявки в СМО; отмены обслуживания начатой заявки нет.

В **открытой** СМО, в отличие от **закрытой** (замкнутой), характеристики потока заявок не зависят от того, в каком состоянии находится сама СМО.

На [рис. 5.1](#) изображён пример схемы СМО.




Рис. 5.1: Иллюстрации к лекции 26.02 (1)

Исследование поведения СМО (определение временных зависимостей входных и выходных переменных) называют **имитационным моделированием СМО**. Имитационное моделирование производится путём воспроизведения событий, происходящих одновременно или последовательно в модельном времени. Под событием будем понимать факт изменения любой фазовой переменной.

Имитационное моделирование СМО — альтернатива **аналитическому моделированию СМО**, заключающемуся в получении формул, применяемых для расчёта выходных параметров СМО с последующей подстановкой значений аргументов в эти формулы. Аналитические модели удобны в использовании, имеют типовые решения, позволяют выявить общие закономерности, однако для сложных СМО аналитические модели если и можно получить, то только с принятием упрощающих допущений и обобщений, что не всегда позволяет оценить адекватность модели. Поэтому в этих областях аналитическое моделирование используется редко, и основным инструментом остаётся имитационное моделирование.

СМО характеризуется правилом выбора одного из возможных направлений движения заявок — это формулируется в дисциплине обработки заявки.

При наличии точек разветвления потоков соединить их несложно, разъединить сложно. Управление ими становится более сложной задачей — требуется определить дисциплину маршрутизации заявок или синтез расписания.

Т.о. для организации маршрутизации заявок можно интегрировать в модель ... основанную на организации событий модель. Такая организация называется **дискретно-событийной**.

6 03.03

6.1 Аналитические модели СМО

Аналитические модели СМО можно получить только при довольно строгих допущениях. К числу типичных допущений относятся следующие:

1. В СМО используются беспriorитетные дисциплины, обслуживание типа FIFO.
2. Времена обслуживания заявок выбираются в соответствии с показательным (экспоненциальным) законом распределения: $F(x) = 1 - e^{-\lambda x}$, $f(x) = \lambda e^{-\lambda x}$, где λ — параметр показательного распределения. В этом случае поток заявок называется **пуассоновским**, т.к. для этого потока вероятность появления k заявок за временной интервал Δt определяется законом Пуассона.
3. Поток заявок обладает свойствами *стационарности* (имеет тренд), *ординарности* (невозможно появление двух заявок на входе СМО одновременно), *отсутствием последействия* (если для двух любых непересекающихся участков времени число попадающих событий не зависит от того, сколько событий попало на другой, говорим о входном потоке без последействия; в большинстве случаев СМО отображают процесс с конечным числом состояний и с отсутствием последействия).

Дискретной марковской цепью называют случайный марковский процесс, при котором смена дискретных состояний происходит в определённые моменты времени, при этом состояние системы будет зависеть от того, в каком она находится сейчас, но не зависеть от её состояния в прошлом. Смена дискретных состояний происходит в случайные моменты времени.

Пример применения марковской модели. Курсанты выполняют учебную стрельбу по мишени. Пусть состояние s_0 — мишень не повреждена в результате выстрела, s_1 — мишень повреждена, s_3 — мишень уничтожена. Необходимо выявить количество патронов, в среднем достаточное курсанту для уничтожения мишени.

На [рис. 6.1](#) изображена матрица вероятностей переходов из одного состояния в другое. Например, вероятность перехода из состояния s_0 в состояние s_1 составляет 0.7. Очевидно, сумма вероятностей в ряду матрицы равняется единице.

Марковскую модель удобно представлять графом; вершины графа соответствуют начальному и последующим состояниям, дуги — переходам, а вероятности переходов интерпретируются как веса дуг.

Для решения задачи необходимо сгенерировать последовательности состояний — «цепочки», — которые действительно могут возникнуть при проведении натурного эксперимента. Количество переходов в цепочке — количество патронов, израсходованных курсантом для уничтожения мишени. Таким образом, необходимо вычислять «нарастающее

среднее» количества патронов, пока не достигнем стабилизации (например, следующие три значения нарастающего среднего попадают в заданный «коридор отклонения»).

Соответственно рис. 6.1, накопительное среднее вычисляется так:

1. $\frac{3}{1} = 3;$
2. $\frac{3+5}{2} = 4;$
3. $\frac{3+5+4}{3} = 4;$
4. $\frac{3+5+4+8}{4} = 5;$
5. $\frac{3+5+4+8+4}{5} = 4.8;$
6. $\frac{3+5+4+8+4+5}{6} = 4.8(3);$

Таким образом, в среднем курсанту для уничтожения мишени достаточно пяти патронов.

Каким образом генерируются цепочки? Для каждого состояния s_i , $i = 0, 1, 2$ разбиваем отрезок $[0, 1]$ частичными суммами вероятностей перехода из состояния s_i . Например, отрезок для состояния s_0 будет разбит точками 0.2 и $0.2 + 0.7 = 0.9$ ($0.2 + 0.7 + 0.1$ равняется единице). Далее генерируем «случайное» число на отрезке $[0, 1]$ и добавляем в строящуюся цепочку состояние, к которому относится число — например, если случайное число, сгенерированное для разбиения отрезка $[0, 1]$ состояния s_0 , попало в промежуток $[0.2, 0.9)$, то добавляем в цепочку состояние s_1 .

Построенная модель является статической аналитической (не феноменологической).




Рис. 6.1: Иллюстрации к лекции 03.03 (1)

Таким образом,

1. марковские цепи характеризуют процесс;
2. старт — с начального состояния s_0 ;
3. строится матрица переходов из одного состояний в другое.

Интенсивность перехода из одного из состояния i в состояние j :

$$V_{ij} = \lim_{t_1 \rightarrow 0} \frac{p_{ij}}{t_1}$$

Здесь p_{ij} — вероятность перехода из состояния s_i в состояние s_j за время t_1 . Если переходные вероятности p_{ij} не зависят от времени, марковская цепь называется **однородной**; в противном случае — **неоднородной**. Если N — число состояний, то

$$\sum_N V_{ij} = 0, \quad i, j = 1, \dots, N.$$

При $i = j$ интенсивность перехода $V_{ij} = 0$. Четвёртое условие, накладываемое на описание марковской модели:

$$\sum_{i \neq j}^N V_{ij} + \sum_{i=1}^N V_{ii} = 0$$

Большинство выходных параметров СМО можно определить, используя информацию о состояниях СМО в установившихся режимах и будущих режимах. Информация имеет вероятностную природу, т.е. можно описать вероятностный переход из состояния в состояние, используя приращение времени и вероятностей перейти к описанию перехода к дифференциальному уравнению — **уравнению Колмогорова** (он и сделал эти модели аналитическими). См. [рис. 6.2](#), [рис. 6.3](#), [рис. 6.4](#).

За вычетом — вероятность возврата из других состояний в текущее состояние.

В конце [рис. 6.4](#) фраза «где P_j — финальные вероятности».

ДЗ: не игнорировать этап математического моделирования. Обязательно начинаем со схемы. Можно нарисовать граф переходов. Концептуальное описание: что есть транзакт, ... Если устройство — банковское окно, то описать, сколько задержка обработка заявки. Учесть нехватку / переизбыток данных.

7 05.03

7.1 Стохастическое моделирование

Стохастические модели делятся на статистические и вероятностные.

В основе вероятностных моделей лежит решение задачи теории вероятностей, в основе статистических лежит решение задач математической статистики. Возможно построение вероятностно-статистических моделей. Отдельно выделяется класс феноменологических моделей.

Испытание — комплекс организационно-правовых мероприятий, направленных на апробацию математической модели. **Эксперимент** — получение количественных и качественных оценок показателей, необходимых для апробации модели. **Опыт** — однотипные повторяющиеся действия в рамках эксперимента, обеспечивающие сбор статистики данных эксперимента.




Рис. 6.2: Иллюстрации к лекции 03.03 (2)




Рис. 6.3: Иллюстрации к лекции 03.03 (3)

Серия опытов позволяет получить количественные или качественные характеристики требуемого показателя в условиях эндогенных (внутренних) и (или) экзогенных (внешних) воздействий системы.




Рис. 6.4: Иллюстрации к лекции 03.03 (4)

Говоря о представительной выборке, первична модель; говоря о больших данных, первичны данные. Представительная выборка обычно от 20 до 100 элементов.

Выделяют единственную задачу теории вероятностей — оценку вероятности того или иного события. При статистическом моделировании рассматривают три задачи:

1. точечные оценки параметров модели;
2. построение доверительных интервалов, в которые попадает оцениваемый параметр;
3. проверка статистических гипотез относительно распределений или значений требуемых параметров.

Здесь и далее под статистическими гипотезами будем понимать утверждения относительно закона распределения некоторой случайной величины x , являющейся требуемым параметром.

7.2 Точечное оценивание

Это оценка параметра, требуемая для апробации созданной модели. Часто используют метод максимального правдоподобия или метод моментов.

Метод моментов. $\mu(x)$, $f(x, \Theta)$, $F(x, \Theta)$. Выборочное среднее:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i,$$

где $(x_1, \dots, x_n)$ — элементы выборки, независимой повторной, принадлежащей некоторой генеральной совокупности X .

$$\mu(x) = \int_{-\infty}^{\infty} x f(x) dx$$

$$\mu(x) = \frac{1}{n} \sum_{i=1}^n x_i$$

Слева — теоретическое, справа — эмпирическое значение.

$$\begin{cases} \mu_1(x, \Theta_1) = \frac{1}{n_1} \sum_{i=1}^{n_1} x_i^{(1)} \\ \dots \\ \mu_2(x, \Theta_2) = \frac{1}{n_2} \sum_{i=1}^{n_2} x_i^{(2)} \end{cases}$$

Модифицированный метод моментов.

Пример. Время работы лампочек в форсированном режиме:

$$\xi_1 : 12, 25, 45, 56, 78, 95, 103, 112, 114, 119, \bar{\xi}_1 = 75.9 \quad (7.1)$$

Время работы лампочек в нормальном режиме:

$$\xi_2 : 25, 52, 95, 119, 150, 172, 206, 225, 230, 235, 250, 262, \bar{\xi}_2 \approx 168.4 \quad (7.2)$$

(Объекты разные (10 и 12 значений соответственно), не измеряемые одновременно). Нужно построить модель, которая по входным данным позволит прогнозировать по работе лампочки в форсированном режиме работу в нормальном режиме. $\xi_2 = \varphi(\xi_1)$ — такая функция в принципе существует? **Нельзя не наблюдаемые одновременно величины представлять на одном графике.**

Рассмотрим наблюдаемые одновременно величины (например, рост и вес ребёнка, рис. 7.1). Если облако точек выстроено вдоль тренда, тогда есть функциональная зависимость. Если есть отклонение, тоже можем говорить о тренде, стохастической зависимости, в предельном случае — тоже можно использовать понятие функциональной зависимости. Если облако слишком расплывчатое, то можно говорить о стохастической зависимости, но не функциональной.

Пусть $F(\xi_1) = 1 - e^{-\lambda_1 \xi_1}$ — функция распределения времени работы лампочек в форсированном режиме, и пусть $F(\xi_2) = 1 - e^{-\lambda_2 \xi_2}$ — функция распределения времени работы лампочек в нормальном режиме. Предположим, что $\xi_2 = \varphi(\xi_1)$ (имеется стохастическая зависимость ξ_2 от ξ_1 в предельном случае); тогда можем приравнять $F(\varphi(\xi_1))$ и $F(\xi_2)$:

$$1 - e^{-\lambda_1 \xi_1} = 1 - e^{-\lambda_2 \xi_2}$$

$$\lambda_1 \xi_1 = \lambda_2 \xi_2$$

$$\xi_2 = \frac{\lambda_1}{\lambda_2} \xi_1$$

$$\hat{k} = \frac{\lambda_1}{\lambda_2}, \quad \xi_2 = \hat{k} \xi_1$$

На рис. 7.2 изображены эмпирические функции распределения времени работы лампочек в форсированном и нормальном режимах. Как строилась, например, первая ФР? В




Рис. 7.1: Иллюстрации к лекции 05.03 (1)




Рис. 7.2: Иллюстрации к лекции 05.03 (2)

выборке 7.1 три значения (12, 25, 45) меньше 50, поэтому для x от 0 до 50 вероятность — 0.3; от 0 до 100 значений 6 (12, 25, 45, 56, 78, 95), поэтому вероятность для x от 50 до 100 — 0.6, и т.д.

Найдём оценку $\hat{k}$ для $\xi_2 = k\xi_1$. Т.к. $M(\xi_2) = M(k\xi_1)$, $\hat{k} = \frac{\bar{\xi}_2}{\bar{\xi}_1}$. Таким образом, $k \approx 2.2$.

Рассмотрим выборку $\xi_2^p = 2.2\xi_1$:

$$\xi_2^p : 26.4, 55, 99, 123.2, 171.6, 209, 226.6, 246.4, 250.8, 261.8, \quad \bar{\xi}_2^p \approx 167$$

Функция распределения ξ_2^p изображена на рис. 7.3 (примерно экспоненциальная). Нанеся на этот же график ФР для ξ_2 , посчитаем разницу двух ФР: если $\max_x |F(x) - \hat{F}(x)| \leq \epsilon$ (критерий согласия), то ок.

Полученный результат допускает применение модели $\xi_2 = k\xi_1$ для дальнейшего анализа; при этом следует отметить, что объём выборок не очень велик, а ϵ выбран произвольно. Критерий согласия необходим для подтверждения или опровержения статистической гипотезы.

Мы рассмотрели случай линейной зависимости, но зависимость может быть и более




Рис. 7.3: Иллюстрации к лекции 05.03 (3)

сложной. Если параметра 2 (добавляется Θ_2), можно взять второй момент:

$$\begin{cases} \mu_1(x, \Theta_1, \Theta_2) = \frac{1}{n} \sum_{i=1}^n x_i \\ \dots \\ \mu_2(x, \Theta_1, \Theta_2) = \frac{1}{n} \sum_{i=1}^n (\bar{x} - x_i)^2 \end{cases}$$

Предположим, время работы лампочек имеет распределение Вейбулла $F(x) = 1 - e^{-ax^b}$; тогда $\xi_2 = a\xi_1^b$. Найдём оценки $\hat{a}$, $\hat{b}$.

$$\ln \xi_2 = \ln a + b \ln \xi_1$$

$$\begin{cases} M(\ln \xi_2) = M(\ln a) + M(b \ln \xi_1) \\ D(\ln \xi_2) = D(\ln a) + D(b \ln \xi_1) \end{cases}$$

$$\begin{cases} M(\ln \xi_2) = \ln a + bM(\ln \xi_1) \\ D(\ln \xi_2) = b^2 D(\ln \xi_1) \end{cases}$$

$$\begin{cases} b = \sqrt{\frac{D(\ln \xi_2)}{D(\ln \xi_1)}} \\ a = e^{M(\ln \xi_2) - bM(\ln \xi_1)} \end{cases}$$

Оценки ММ не очень эффективны в сравнении с ММП.

8 12.03

Мат. статистика, как и теория вероятностей, занимается изучением мат. моделей случайных явлений и (или) экспериментов. Задача теории вероятностей является прямой (в своей постановке), выделенные задачи мат. статистики (точное оценивание, проверка гипотез,

доверительное оценивание) трактуются как обратные задачи теории вероятностей. Феноменологические модели рассматривают как задачу идентификации, когда известны входные и выходные данные (результаты экспериментов); в ряде случаев вид модели можно обосновать или подобрать эвристически.

Пример.

$$\begin{aligned}\xi_0 &= \varphi_{01}(\xi_1) = e^{-\lambda \xi_1} \\ \xi_1 &= \varphi_{12}(\xi_2) = 1 - \alpha \xi_2^\beta \\ \xi_0 &= e^{-\lambda(1-\alpha \xi_2^\beta)} \\ \ln \xi_0 &= -\lambda + \gamma \xi_2^\beta \\ \xi_2 &= \left(\frac{\lambda + \ln \xi_0}{\gamma} \right)^{\frac{1}{\beta}}\end{aligned}$$

... Если нет никакой информации о системе, говорят об идентификации в широком смысле.

8.1 Задача интервального оценивания

Предполагается, что оценивается интервал, куда попадает оцениваемый параметр. Оценивается вероятность $P(a \in [a_-, a_-])$. $P\{a_- \leq a \leq a_-\} = \gamma$, γ — коэффициент доверия. Построенный случайный интервал накрывает истинное значение с вероятностью P . Вероятности γ выбираются близко к единице, из такого ряда: 0.9, 0.95, 0.99, 0.995, 0.999.

8.2 Задача проверки стат. гипотез

В мат. статистике используется, как правило, выборочная терминология, основанная на «урновой» схеме.

Урна содержит N значений $X_1, \dots, X_N$ — генеральная совокупность.

Из указанной генеральной совокупности случайным образом выбирается n значений: $x_1, \dots, x_n$, $n \leq N$. Второй набор чисел — выборка объёма n из генеральной совокупности. Выборка может производиться с возвращением и без возвращения. Если выборка с возвращением, то случайные величины независимы. Говорят, что выборка — независимая, повторная, случайная объёма n из генеральной совокупности объёма N . При $n \rightarrow \infty$ терминология сохраняется. $x^1, \dots, x^n$ — вариационный ряд (расположение элементов выборки по возрастанию).

Выборочное среднее:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Эмпирическая дисперсия (смещённая):

$$s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2;$$

s — выборочное (эмпирическое) среднеквадратическое отклонение. Размах (разность самого большого и маленького значений):

$$R = x^n - x^1.$$

r -й начальный момент:

$$\mu_r^0 = \left(\frac{1}{n} \sum_{i=1}^n x_i^r \right)^{\frac{1}{r}}.$$

r -й центральный момент:

$$\mu_r = \left(\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^r \right)^{\frac{1}{r}}.$$

Эмпирическая функция распределения:

$$\hat{F}(x) = \begin{cases} 0, & x \leq x_i, \\ \frac{j}{n}, & x_j < x < x_{j+1} \\ 1, & x \geq x_{j+1} \end{cases}$$

Пусть имеется некоторая случайная величина $\xi : x, F(x, \Theta), f(x, \Theta)$. Θ может быть многомерным параметром. Истинное значение Θ неизвестно, требуется оценить по результатам n повторных независимых наблюдений значение этого параметра.

Есть выборка объёма n из генеральной совокупности объёма N . Совокупность распределений $F(x, \Theta)$ при разных значениях Θ называют **параметрическим семейством** ... Любая функция от результатов наблюдений $\tau = \tau(x_1, \dots, x_n)$ называется **статистикой** эксперимента.

Задача построения точечной оценки параметра сводится к нахождению такой функции от результатов наблюдений: $\hat{\Theta} = \Theta(x_1, \dots, x_n)$ — статистика (случайная величина), которая в некотором смысле близка к значению неизвестного истинного параметра Θ .

8.3 Свойства оценок

Оценка $\hat{\Theta}$ называется **несмещенной оценкой** параметра Θ , если её мат. ожидание совпадает с истинным значением параметра: $M\hat{\Theta} = \Theta$.

Оценка $\hat{\Theta}$ является **асимптотически несмещенной**, если $\lim_{n \rightarrow N} M\hat{\Theta} = \Theta$ — для ГС объёма N . Для ГС бесконечного объёма $\lim_{n \rightarrow \infty} M\hat{\Theta} = \Theta$.

Объём выборки также влияет на состоятельность оценок. Оценка $\hat{\Theta}_n$ называется **состоятельной оценкой** параметра Θ , если при $n \rightarrow \infty$ она сходится по вероятности к истинному значению параметра: $\lim_{n \rightarrow \infty} P\{|\hat{\Theta}_n - \Theta| > \varepsilon\} = 0, \forall \varepsilon > 0, \forall \Theta$.

Теорема 8.1. Пусть $\hat{\Theta}_n$ — асимптотически несмещённая оценка параметра Θ , и предел $\lim_{n \rightarrow \infty} s^2(\hat{\Theta}) = 0$. Тогда эта оценка состоятельная.

Если выполнено $s_{(1)}^2 = M(\hat{\Theta}^{(1)} - \Theta) < M(\hat{\Theta}^{(2)} - \Theta) = s_{(2)}^2$, то оценка $\hat{\Theta}_1$ эффективнее оценки $\hat{\Theta}_2$.

8.4 Доверительное оценивание

Пусть $x_1, \dots, x_n$ — независимая случайная повторная выборка из ГС с $F(x, \Theta), f(x, \Theta)$. Предположим, что для Θ на основе выборки построен интервал $\hat{\Theta} \in [\Theta_-, \Theta_+]$. $P\{\Theta_- \leq \Theta \leq \Theta_+\} = \gamma$ — **доверительный интервал** для Θ с **коэффициентом доверия** γ .

$\tau = \tau(x_1, \dots, x_n, \Theta)$ — **центральная статистика**. Пусть имеется статистика τ . Предположим, что она описывается монотонно убывающей функцией. **Квантилем** уровня α ФР $F(t)$ называется величина $K(\alpha)$, см [рис. 8.1](#). $P\{t \leq k\} = F(k) = \alpha$. Зафиксируем $t_1 = K(\varepsilon_1)$, $t_2 = K(1 - \varepsilon_2)$. $P\{t_1 \leq \tau(x_1, \dots, x_n) \leq t_2\} = 1 - \varepsilon_2 - \varepsilon_1$. Если $\varepsilon_1 = \varepsilon_2 = \varepsilon$, то $\varepsilon = \frac{1 - \gamma}{2}$.




Рис. 8.1: Иллюстрации к лекции 12.03 (1)

Если исходная функция монотонно убывающая, то

$$\tau = \tau(x_1, \dots, x_n, \Theta_-) = t_1$$

$$\tau = \tau(x_1, \dots, x_n, \Theta_-) = t_2$$

Если функция монотонно возрастающая — аналогично, t_1 и t_2 меняются местами.

9 17.03

Пример 9.1 (Оценка доверительного интервала для параметров нормального распределения). μ — мат. ожидание, σ^2 — дисперсия. Предположим, что дисперсия известна. Введём $T = \left(\frac{\bar{X} - \mu}{\sigma}\right)\sqrt{n}$ — эта статистика имеет стандартное нормальное распределение ($\mu_T = 0, \sigma_T = 1$) и является монотонно убывающей функцией. Выбираем

$$\text{квантиль } \varepsilon = \frac{1 - \gamma}{2}.$$

$$\begin{cases} \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} = t_2 = u_{1-\varepsilon} \\ \frac{\bar{X} - \mu_-}{\frac{\sigma}{\sqrt{n}}} = t_1 = u_{\varepsilon} \end{cases}$$

$$\hat{\mu}_-, \hat{\mu}^-, \hat{\mu} \in [\mu_-, \mu^-]$$

9.1 Статистические критерии. Критерии согласия

Статистической гипотезой H называют любое утверждение относительно функции распределения $F(x)$ некоторой случайной величины x , касающейся типа функции распределения, значения её параметров и т.д. Гипотезу H проверяют путём сопоставления выдвинутых предположений с результатами эксперимента, который в статистике представляет собой n независимых наблюдений над случайной величиной x , т.е. выборку случайных величин $x_1, \dots, x_n$ из некоторой генеральной совокупности X . Гипотезу называют **простой**, если её условию удовлетворяет единственная функция распределения $F(x)$; в противном случае гипотеза **сложная**. Гипотеза, справедливость которой проверяется в ходе эксперимента, называется **основной** или **нулевой** — H_0 или H_O ; **альтернативная** гипотеза — H_1 или H_A .

Статистическую гипотезу проверяют с помощью статистических критериев. В зависимости от того, какие отклонения от H_0 возможны, формулируют альтернативные гипотезы. **Статистический критерий** — это совокупность правил, позволяющих по полученной выборке принять H_0 или отвергнуть H_1 .

Общий принцип построения статистических критериев.

1. Задают статистику — функцию $T = T(x_1, \dots, x_n)$.
2. Все возможные значения статистики разбивают на два подмножества: T_0 — множество принятия решений H_0 , и $T_{кр}$ — критическое множество (множество, где принимается альтернативная гипотеза). Множество, отделяющее основную и альтернативную гипотезы, называется **зоной индифферентности** (см. рис. 9.1).
3. Если конкретное значение статистики попадает в T_0 , то принимают H_0 ; если в $T_{кр}$, то H_0 отвергают в пользу H_1 . Если значение попадает в зону индифферентности, то требуется дополнительное исследование — мы не можем принять ни основную, ни альтернативную гипотезу.

Критерий может быть односторонним и двусторонним (см. рис. 9.2).

Если критерий таков, что критическими являются как малые, так и большие значения его статистики, то он называется **двусторонним**; в противном случае критерий **односторонний**. Выбор одностороннего или двустороннего критерия определяется видом альтернативной гипотезы.

В силу того, что статистика T — случайная величина, событие $\in T_{кр}$ может произойти как при справедливости H_0 , так и при справедливости H_1 , в силу чего возможны ошибки первого и второго рода. **Ошибка первого рода** — верна H_0 , но принимается H_1 ; **ошибка второго рода** — верна H_1 , но принимается H_0 .

Пример 9.2. Больные и здоровые люди. H_0 — человек болен; H_1 — человек здоров. Ошибка первого рода — больного человека мы считаем здоровым. Ошибка второго




Рис. 9.1: Иллюстрации к лекции 17.03 (1)

рода — наоборот. Мы делаем ставку на основную гипотезу.

Вероятность ошибки первого рода: $P\{T(x_1, \dots, x_n) \in T_{кр} \mid H_0\} = \alpha$ — размер критического множества (размер критерия). *Лучше минимизировать размер крит. области.* Вероятность $P\{T(x_1, \dots, x_n) \in T_0 \mid H_1\} = \beta$ — **уровень значимости**. $\beta = 1 - \gamma$, $\gamma = 1 - \beta$ — **мощность критерия** (используется чаще, эту величину желательно максимизировать; это не коэффициент доверия).

9.2 Критерий согласия

Критериями согласия называют критерии, в которых гипотеза определяет закон распределения полностью или с точностью до небольшого числа параметров. Пусть имеется выборка объёма n . Теоретическая функция распределения, которой подчиняется ген. совокупность, $G(x)$, а гипотетическая — $F(x)$; эмпирическая — $F_n(x)$. Тогда гипотеза о том, что истинное распределение есть $F(x)$...

$$H_0 : G(\cdot) = F(\cdot)$$

$$\lim_{n \rightarrow \infty} F_n(x) \rightarrow G(x)$$

9.2.1 Статистика Колмогорова

Статистика критерия:

$$D_n = \sup_x |G(x) - F_n(x)|.$$




Рис. 9.2: Иллюстрации к лекции 17.03 (2)

Сам критерий — условие:

$$\sup_x |G(x) - F_n(x)| \leq D_\beta.$$

10 19.03

В ЛР2 снимали баллы за отсутствие описания данных, отсутствие разделения выборки на рабочую и контрольную. Второе — не то же самое, что разделение в машинном обучении выборки на train и test, поскольку в первом случае — представительная выборка, во втором — большие данные. В машинном обучении по закону больших чисел у полученных наборов будут близкие выборочные функции. Для представительной выборки нужно было построить вариационный ряд по столбцу **Glucose** и чередованием значений разделить исходные данные на две выборки. Например, выборка

0, 0, 0, 125, 127, 130, 131, 135, 138, 140,

разбивается на выборки

0, 0, 127, 131, 138

и

0, 125, 130, 135, 140.

Дальше она говорит о построении расчётной выборочной ФР и её сравнении с выборочной ФР.

11 20.03

О задаче с Лукьяненко. Построить модель игры. Это стохастическая вероятностная модель, основанная на парадоксе Монте Холла.

Пример. На заводе производят лампочки. 10% лампочек отбраковали, 90% отправили в продажу. Из этих 10% действительно брак — 20%, нормальных — 80%. Найти вероятность, что выбранная случайно отправленная в продажу лампочка без дефекта. Событие A — обнаружена хорошая лампочка, событие B — обнаружен брак. $0.9 + 0.1 \cdot 0.8 = 0.98$. $P(A|B) = \frac{P(AB)}{P(B)} = \frac{0.9}{0.98} \approx 0.92$, см. [рис. 11.1](#).

ДЗ2: описать с помощью формулы Байеса (она — модель), выбрать правильно события A , B . Изменение — стратегия, что он всё время отказывается или он может менять. Попробовать разные соотношения вероятностей меняет он или нет. Разное количество испытаний (?). На выполнение ровно 2 недели. Колесо не открывается, поэтому анализируем только 2 случая. Мат. ожидание 0.5. Количество испытаний — 10, 100, т.д. Тестирование — стратегия Трикса (всё время менять).

Что-то там о таблицах. $\beta = 0.1$, $\gamma = 0.9$; $\beta = 0.05$, $\gamma = 0.95$; $\beta = 0.01$, $\gamma = 0.99$.

$$D_\beta \approx \frac{k_\alpha}{\sqrt{n}}, \quad \alpha — \text{уровень значимости.}$$

$$k_{0.1} = 1.23$$

$$k_{0.05} = 1.36 \text{ (популярный)}$$

$$k_{0.02} = 1.52$$

$$k_{0.01} = 1.63$$

Если гипотеза отвергается: $F_n \rightarrow F(x)$, $F(x) \neq G(x)$. Применительно к нашим данным (ЛР2) $n = 133$, $\sqrt{n} \approx 11.53$; $\frac{1.36}{11.53} \approx 0.12$. Т.е. для $n = 133$ $D_\beta \approx 0.12$, для $n = 250$ $D_\beta \approx 0.09$.

$n_1 = 133$, $n_2 = 250$. Двухвыборочный критерий К.-С. (для нормировки умножаем на D): $\sqrt{\frac{n_1 n_2}{n_1 + n_2}} \approx 0.0075$ — не применима для больших объёмов $\approx$ до 100 элементов.

Критерий ω^2 :

$$\omega^2 = \int_{-\infty}^{\infty} (F_n(x) - G(x))^2 \varphi(F(x)) dF(x)$$

Критерий Крамера–Мизеса:

$$\varphi(F(x)) = 1$$

Критерий Андерсена–Дарлингса:

$$\varphi(F(x)) = \frac{1}{x(1-x)}$$




Рис. 11.1: Иллюстрации к лекции 20.03 (1)

К.-М. чувствительнее К.-С., для типичных значений; А.-Д. различает на хвостах.

Статистический критерий для проверки гипотезы H называют **состоятельным** против альтернативы H' , если вероятность отвергнуть H_0 с его помощью, когда на самом деле верна H_1 , стремится к 0 при неограниченном увеличении объёма наблюдений. Состоятельность критериев К.-С., ω^2 означает, что любое отличие распределения выборки от теоретического будет обнаружено, если наблюдения будут продолжаться достаточно долго.

Более сложной задачей оказывается проверка сложной гипотезы: например, подтверждение адекватности оценок параметров $\hat{\Theta}_1, \dots, \hat{\Theta}_n$ — в этом случае рассматриваются функции $F_n(x, \bar{\Theta})$, $G(x, \bar{\Theta})$, и проверка ведётся на основе таких модифицированных статистик.

11.1 Методы многомерного статистического анализа

Каждый элемент выборки может содержать наблюдения более чем над одной случайной переменной. Если переменные являются случайными, то говорят о **множественной регрессии**

$$y = a_0 + a_1x_1 + \dots + a_nx_n,$$

где a_i , $i = 0, \dots, n$, — коэффициенты регрессии. Справа независимые переменные. В других методах многомерного анализа случайные величины могут анализироваться как случайный вектор с многомерным распределением.

Многомерный анализ — анализ множественных результатов измерений свойств случайной выборки, в рамках которого используется *комплекс* методов для решения задач.


11.1.1 Временной ряд

Совокупность последовательных измерений значений переменной процесса, произведённых через определённые — чаще равные — значения параметра (чаще время). Если измеряемые значения являются многомерными, то и временной ряд — многомерный.


Задачи, решаемые с помощью ВР:

- моделирование процессов, представленных ВР;
- исследование структуры ВР (тренд, (квази)периодические колебания, лаги);
- прогнозирование будущего развития такого процесса;
- исследование взаимодействия между различными ВР.

Для решения этих и других задач используются методы корреляционного анализа (обнаружение лагов, периодических колебаний (?)), спектрального анализа (обнаружение квазипериодических колебаний, см. [рис. 11.2а](#)), сглаживание, фильтрация, *что-то про метод скользящего окна, авторегрессии*.



(а) Пример квазипериодических колебаний



(b) Демонстрация метода главных компонент

Рис. 11.2: Иллюстрации к лекции 20.03 (2, 3)

При исследовании сложных объектов невозможно непосредственно исследовать какую-то величину (*например, температура внутри ядерного реактора*). Для измерения доступны величины, в той или иной степени определяющие нужную, при этом, когда влияние неизвестного фактора проявляется в нескольких измеряемых признаках, эти признаки могут обнаруживать достаточно тесную связь между собой, что позволяет снизить число факторов, а, следовательно, и размерность модели — для этого применяют методы факторного анализа.

Пример:

$$y = a_0 + a_1x_1 + a_2x_2 + a_3x_3 + a_4x_4$$


$$\begin{aligned}x_1 &= \varphi_1(x_2) \\x_2 &= \varphi_2(x_3) \\x_3 &= \varphi_3(x_4) \\ \text{т.е. } x_1 &= \varphi(x_4)\end{aligned}$$

Выбор новых признаков, являющихся линейными комбинациями прежних и «вбирающих» в себя большую часть изменчивости наблюдаемых данных, заключённых в первоначальных наблюдениях, реализует также **одно-, двухфакторный дисперсионный анализ**. Иногда рассматривают как инструмент факторного анализа. Также как и **метод главных компонент**, предполагающий поворот системы координат таким образом, чтобы главным осям соответствовали признаки (факторы), наиболее информативные с точки зрения решения задачи, см. [рис. 11.2b](#).


Дискриминатный анализ позволяет строить функцию измеряемых характеристик, значения которых объясняет разделение отрезков, наборов данных на группы. Мы предлагаем дискриминирующую функцию. Желательно, чтобы таких функций было немного. Особую роль играет **линейный дискриминантный анализ**, в котором классифицирующие признаки выбираются как линейные функции от первичных признаков, см. [рис. 11.3a](#).

Если требуется разбить изучаемую совокупность объектов на группы схожих, используют методы **кластерного анализа**, разделяя их на иерархические (а те — на агломеративные — объединяющие — и дивизивные, см. [рис. 11.3b](#)) и неиерархические.

Различают также **причинно-следственный анализ** компонентов — тоже позволяет уменьшить число переменных которые в наибольшей степени влияют на изменчивость выборочных значений (пример: выявление свойств личности, повлиявших на поведение человека в данной ситуации). Вариантом такого подхода является **метод шкалирования** — используются не сами оценки ..., а результат их сравнения (пример: плохо формализуемая характеристика «красивый человек»).



(a) Демонстрация линейного дискриминантного анализа



(b) Демонстрация иерархических методов кластерного анализа

Рис. 11.3: Иллюстрации к лекции 20.03 (4, 5)

12 23.03

12.1 Корреляционный анализ

Писать «предположим стохастическую зависимость между случайными величинами» бессмысленно, поскольку такая зависимость так или иначе существует между произвольными случайными величинами.

Корреляция — мера степени и направления связи между значениями двух переменных (измеренными в количественной шкале). Проверка гипотез о связях между переменными с применением коэффициентов корреляции (можно называть их коэффициентами связи, взаимосвязи).

Направление связи определяется прямым или обратным соотношением значений двух переменных: если возрастание значений одной переменной соответствует возрастанию значений другой переменной, то связь называется **прямой (положительной)**; если возрастание значения одной переменной соответствуют убыванию значений другой переменной, то взаимосвязь **обратная (отрицательная)**. Показателем направления связи, как правило, является знак коэффициента корреляции (в общем случае это необязательно коэффициент корреляции Пирсона).

В ряде случаев связь является **односторонней** (при описании переменная y слева, зависящая от переменных $x_1, \dots, x_n$ справа). В другом случае говорят о взаимной связи двух переменных — обычно это описывается неявно (например, $F(x, y) = 0$).

Функциональная зависимость — это закон, ставящий в соответствие каждому действительному числу $x \in X$ действительное число $y \in Y$. **Стохастическая зависимость** — при которой значению величины $x \in X$ может соответствовать множество значений величины $y \in Y$; зависимость носит вероятностный характер, т.е. СВ $y \in Y$ принимает значение с некоторой вероятностью.

Понятия «стохастической связи» и «случайной связи» синонимичны. Термин «стохастическая связь» впервые был введён Чепровым в 1926-м году, и он сегодня является общепринятым в данной сфере.

По отношению к событиям функциональная зависимость причинна: наступление одного события влечёт наступление другого. Стохастическая связь причинной не является; одно событие изменяет вероятность наступления другого (и не всегда вызывает появления события).

Функциональная зависимость является предельным случаем тесной стохастической зависимости. Другой крайний случай — полная независимость величины y от величины x .

Совокупность характеристик стохастической связи делят на две группы:

1. характеристики, позволяющие дифференцировать линейную и нелинейную зависимости;
2. характеристики степени тесноты связи.

...

- полный, частный, сводный коэффициент корреляции;
- обычная, взаимная, нормированная, взаимная нормированная функция корреляции;

- обычная, взаимная моментная функция;
- коэффициент коллигации;
- функция коллигации;
- функция регрессии;
- ранговый коэффициент корреляции Спирмена, Кендалла.

13 26.03

Здесь должно быть определение коэффициента корреляции.

Коэффициент корреляции Пирсона:

$$r_{xy} = \frac{\sigma_{xy}}{\sigma_x \sigma_y},$$

$$\sigma_{xy} = \sqrt{(x - \bar{x})(y - \bar{y})},$$

$$\sigma_x = \sqrt{(x - \bar{x})^2} = |x - \bar{x}|,$$

$$\sigma_y = \sqrt{(y - \bar{y})^2} = |y - \bar{y}|.$$

Коэффициент корреляции Пирсона применяется в случае, если стохастическая зависимость между СВ тесна и может быть описана линейной функцией. Альтернативой являются **ранговые корреляторы** — количественная мера корреляции, измеренная в ранговой шкале.

Коэффициент ранговой корреляции Спирмена:

$$d_i = \Sigma_i (R_i - S_i)^2;$$

$$\rho_s = 1 - \frac{6d_i}{n(n^2 - 1)},$$

$$\sqrt{n-1}\rho_s \sim \mathcal{N}(0, 1), \quad \text{см. рис. 13.1.}$$




Рис. 13.1: Иллюстрации к лекции 26.03 (1)

Пример 13.1.

Определим корреляцию между средним баллом студента и баллами ЕГЭ. Введём обозначения:

- O — средняя оценка студента;
- $E = \frac{\text{Баллы ЕГЭ}}{300} \cdot 100\%$;
- r_O — ранг оценок;
- r_E — ранг баллов ЕГЭ.

Ранги оценок r_O :

- 1, если $2 \leq O < 3$;
- 2, если $3 \leq O < 4$;
- 3, если $4 \leq O \leq 5$.

Ранги баллов ЕГЭ:

- 2, если $0 \leq E < 60$;
- 3, если $60 \leq E < 70$;
- 4, если $70 \leq E < 85$;
- 5, если $85 \leq E \leq 100$.

Студент	Оценки	Баллы ЕГЭ	O	E	r_O	r_E	$ r_O - r_E $
Т	4, 4, 5	247	4.33	82.33	3	2	1
С	2, 3, 2	223	2.33	74.33	1	2	1
Б	5, 5, 5, 5, 5	286	5.0	95.33	3	3	0
М	3, 4, 5	287	4.00	95.66	2	3	1
Г	5, 5, 5	292	5.00	97.33	3	3	0
Ж	4, 3, 3, 4	250	3.50	83.33	2	2	0

Таким образом, $d_i = 1 + 1 + 0 + 1 + 0 + 0 = 3$. Получаем

$$\rho_s = 1 - \frac{6 \cdot 3}{6(6^2 - 1)} = 0.91428;$$

$$\sqrt{5}\rho_s \approx 2.044.$$

В статистических таблицах необходимо найти границу критической области в зависимости от числа элементов.

Недостатком коэффициента Спирмена является его низкая чувствительность. Более чувствительным является **коэффициент Кендалла** — у него множество различных определений, мы рассмотрим следующее:

$$\tau = \frac{4p}{n(n-1)} - 1, \quad -1 \leq \tau \leq 1.$$

где p — число совпадений рангов (или несовпадений?).

13.1 Коэффициент контингенции Пирсона

Коэффициент контингенции Пирсона — дихотомическая мера корреляции, подходящая для двух переменных, измеренных в ранговой шкале (например, старше старше или моложе пятидесяти лет). Рассмотрим таблицу сопряжённости:

	A	$\bar{A}$
B	a	b
$\bar{B}$	c	d

Например, A — «зарплата в семье важна», $\bar{A}$ — «зарплата в семье не важна»; B — мнение мужчин, $\bar{B}$ — мнение женщин. Здесь a, b, c, d — частоты.

Коэффициент контингенции:

$$k_{\text{кон}} = \frac{ad - bc}{\sqrt{(a+b)(c+d)(a+c)(b+d)}}.$$

Коэффициент ассоциации:

$$k_{\text{асс}} = \frac{ad - bc}{ad + bc}.$$

Коэффициент коллигации:

$$k_{\text{кол}} = \frac{\sqrt{ad} - \sqrt{bc}}{\sqrt{ad} + \sqrt{bc}}.$$

Как правило, если работают с каким-нибудь одним из указанных коэффициентов, то работают со всеми тремя.

Для коэффициентов должно выполняться соотношение $k_{\text{асс}} > k_{\text{кол}} > k_{\text{кон}}$.

13.2 Кластерный анализ

Различают понятия классификации и кластеризации. **Кластеризация** — обучение без учителя; различают иерархический и неиерархический подходы в кластеризации.

Иерархический подход основан на построении дерева, называемого **дендрограммой**, см. рис. 13.2.




Рис. 13.2: Пример дендрограммы.

Неиерархические методы часто характеризуются как неустойчивые, при этом дают быстрые результаты и имеют хорошую сходимость. Преимущество такого подхода —

независимость от числа исходных объектов и конечного числа кластеров (например, разделение абитуриентов на поступивших и не поступивших). Кластеры для неиерархических методов характеризуются такими показателями, как

- центр кластера (выборочное среднее, $(\bar{x}, \bar{y}, \bar{z})$);
- радиус кластера (расстояние от центра кластера до самого удаленного его объекта).

Проблемой кластеризации является возникновение спорных точек, которые не относятся ни к одному из кластеров. Иногда спорные точки директивно прикрепляют к какому-либо кластеру.

Дальше обсуждали *манхэттенское расстояние*, см. рис. 13.3, *метрику Минковского*, метрику Канберры, см. рис. 13.4.



Рис. 13.3: Манхэттенское расстояние.

$p=1$ | расстояние квадратов
 $p=2$ | евклидово расстояние
 $p \rightarrow \infty$ | расстояние Чебышёва; $\max_{i,j} |x_{ij} - \bar{x}|$

$$d_{ij} = \sqrt[p]{\sum_{i=1}^n (x_{ij} - \bar{x})^p}$$

Рис. 13.4: Расстояние Минковского как обобщение манхэттенского расстояния, евклидова расстояния, **расстояния Чебышёва**.