



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ _____ «Информатика и системы управления»

КАФЕДРА _____ «Теоретическая информатика и компьютерные технологии»

Лабораторная работа №2

«Оценивание функций связи между ненаблюдаемыми
одновременно параметрами»
по курсу «Моделирование»

Студент: Аригин М.А.

Группа: ИУ9-82Б

Преподаватель: Домрачева А.Б.

Москва 2026

1 Постановка задачи

В работе исследуется зависимость между уровнями глюкозы в крови у пациентов с разными исходами заболевания диабетом. Имеется датасет с 768 наблюдениями, содержащий медицинские показатели пациентов.

Цель работы — проверить гипотезу о возможности описания стохастической зависимости между уровнями глюкозы для пациентов с разными исходами заболевания с помощью двупараметрической степенной функции связи. Для оценки параметров используются методы моментов, наименьших квадратов и нелинейного метода наименьших квадратов с последующим выбором наилучшего метода. Проверка гипотезы выполняется с помощью критерия Колмогорова-Смирнова.

Входные данные:

- Датасет с 768 наблюдениями
- Столбец Glucose — уровень глюкозы (мг/дл)
- Столбец Outcome — исход заболевания (0 или 1)

2 Построение математической модели

В данной работе рассматривается задача оценки стохастической зависимости между уровнями глюкозы у пациентов с разными исходами заболевания. Ключевая особенность задачи заключается в том, что величины ξ_0 (уровень глюкозы при Outcome = 0) и ξ_1 (уровень глюкозы при Outcome = 1) не наблюдаются одновременно для одного и того же пациента — это данные из разных групп пациентов. Поэтому классический подход построения функциональной зависимости по парным наблюдениям здесь неприменим.

2.1 Формализация задачи

Пусть ξ_0 — случайная величина, представляющая уровень глюкозы для пациентов с одним диагнозом (Outcome = 0), а ξ_1 — случайная величина для

пациентов с иным исходом (Outcome = 1). Предполагается, что существует стохастическая зависимость, которую можно описать функцией:

$$\xi_1 = \varphi(\xi_0) = \alpha \cdot \xi_0^\beta,$$

где $\alpha > 0$ и β — неизвестные параметры модели.

В предельном случае, когда стохастическая зависимость может быть описана функцией, функции распределения должны совпадать:

$$F(\varphi(\xi_0)) = F(\xi_1).$$

Это означает, что распределение преобразованных значений $\varphi(\xi_0) = \alpha \cdot \xi_0^\beta$ должно совпадать с распределением ξ_1 .

2.2 Методы оценки параметров

Для оценки параметров α и β используются три метода, из которых выбирается наилучший по критерию Колмогорова-Смирнова.

Метод моментов: После логарифмирования $\ln \xi_1 = \ln \alpha + \beta \ln \xi_0$ параметры оцениваются через выборочные моменты:

$$\hat{\beta} = \sqrt{\frac{D[\ln \xi_1]}{D[\ln \xi_0]}}, \quad \hat{\alpha} = \exp \left(\mathbb{E}[\ln \xi_1] - \hat{\beta} \cdot \mathbb{E}[\ln \xi_0] \right),$$

где $\mathbb{E}[\cdot]$ и $D[\cdot]$ — выборочное среднее и дисперсия соответственно.

Метод наименьших квадратов (OLS): Используется квантильное сопоставление распределений. Для квантилей $Q_{\xi_0}(p)$ и $Q_{\xi_1}(p)$ строится линейная регрессия $\ln Q_{\xi_1} = \ln \alpha + \beta \ln Q_{\xi_0}$ методом наименьших квадратов.

Нелинейный метод наименьших квадратов (NLS): Параметры находятся минимизацией суммы квадратов ошибок между квантилями:

$$(\hat{\alpha}, \hat{\beta}) = \arg \min_{\alpha, \beta} \sum_{i=1}^n (Q_{\xi_1}(p_i) - \alpha \cdot Q_{\xi_0}(p_i)^\beta)^2,$$

где p_i — уровни квантилей.

Выбор наилучшего метода производится по минимальной статистике Колмогорова-Смирнова на контрольной выборке.

2.3 Схема модели




Рисунок 1 Схема построения стохастической модели зависимости

2.4 Критерий Колмогорова-Смирнова

Для проверки гипотезы о соответствии распределений $F(\xi_1)$ и $F(\varphi(\xi_0))$ используется критерий Колмогорова-Смирнова. Статистика критерия вычисляется как максимальное отклонение между эмпирическими функциями распределения:

$$D_n = \sup_x |F(\xi_1)(x) - F(\varphi(\xi_0))(x)|.$$

Критическое значение для уровня значимости $\alpha = 0.05$:

$$K_\alpha = \sqrt{-\frac{1}{2} \ln \left(\frac{1-\alpha}{2} \right)}.$$

Гипотеза о соответствии распределений принимается, если $D_n < K_\alpha$, и отвергается в противном случае. Этот критерий также используется для выбора наилучшего метода оценки параметров — выбирается метод с минимальной статистикой D_n .

3 Решение вычислительных задач

После формализации математической модели необходимо решить вычислительные задачи для оценки параметров и проверки гипотезы.

3.1 Оценка параметров модели

Для оценки параметров α и β используются три метода на рабочей выборке. Поскольку величины ξ_0 и ξ_1 имеют разные размеры и не являются парными наблюдениями, используется квантильное сопоставление распределений.

Метод моментов: Вычисляются выборочные средние и дисперсии логарифмированных значений:

$$\mathbb{E}[\ln \xi_0] = \frac{1}{n_0} \sum_{i=1}^{n_0} \ln \xi_0^{(i)}, \quad D[\ln \xi_0] = \frac{1}{n_0} \sum_{i=1}^{n_0} (\ln \xi_0^{(i)} - \mathbb{E}[\ln \xi_0])^2,$$

аналогично для ξ_1 . Параметры оцениваются как:

$$\hat{\beta} = \sqrt{\frac{D[\ln \xi_1]}{D[\ln \xi_0]}}, \quad \hat{\alpha} = \exp \left(\mathbb{E}[\ln \xi_1] - \hat{\beta} \cdot \mathbb{E}[\ln \xi_0] \right).$$

Метод наименьших квадратов (OLS): Для квантилей $Q_{\xi_0}(p_i)$ и $Q_{\xi_1}(p_i)$ строится линейная регрессия $\ln Q_{\xi_1} = \ln \alpha + \beta \ln Q_{\xi_0}$ методом наименьших

квадратов, минимизируя:

$$\sum_{i=1}^n (\ln Q_{\xi_1}(p_i) - \ln \alpha - \beta \ln Q_{\xi_0}(p_i))^2.$$

Нелинейный метод наименьших квадратов (NLS): Параметры находятся прямой минимизацией:

$$(\hat{\alpha}, \hat{\beta}) = \arg \min_{\alpha, \beta} \sum_{i=1}^n (Q_{\xi_1}(p_i) - \alpha \cdot Q_{\xi_0}(p_i)^\beta)^2.$$

Выбор наилучшего метода производится по минимальной статистике Колмогорова-Смирнова на контрольной выборке.

3.2 Вычисление эмпирических функций распределения

Для контрольной выборки вычисляются эмпирические функции распределения. Для выборки $\{x^{(1)}, \dots, x^{(n)}\}$ функция распределения определяется как:

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{\{x^{(i)} \leq x\}},$$

где $\mathbf{1}_{\{\cdot\}}$ — индикаторная функция. Вычисляются три функции:

- $F(\xi_0^{\text{test}})$ — для контрольной выборки ξ_0
- $F(\xi_1^{\text{test}})$ — для контрольной выборки ξ_1
- $F(\varphi(\xi_0^{\text{test}}))$ — для преобразованных значений $\varphi(\xi_0^{\text{test}}) = \hat{\alpha} \cdot (\xi_0^{\text{test}})^\beta$

Для визуализации функции вычисляются на равномерной сетке с шагом $\Delta = 0.2$ в диапазоне от минимума до максимума выборки.

3.3 Вычисление статистики Колмогорова-Смирнова

Для сравнения функций распределения $F(\xi_1^{\text{test}})$ и $F(\varphi(\xi_0^{\text{test}}))$ они интерполируются на общей сетке значений. Статистика критерия вычисляется как:

$$D_n = \max_x |F(\xi_1^{\text{test}})(x) - F(\varphi(\xi_0^{\text{test}}))(x)|.$$

Критическое значение для уровня значимости $\alpha = 0.05$:

$$K_{\alpha} = \sqrt{-\frac{1}{2} \ln \left(\frac{1 - \alpha}{2} \right)}.$$

Гипотеза о соответствии распределений принимается при $D_n < K_{\alpha}$.

4 Практическая реализация

Listing 1: Основной модуль анализа зависимости между уровнями глюкозы

```
1 import pandas as pd
2 import numpy as np
3 import matplotlib.pyplot as plt
4 from sklearn.model_selection import train_test_split
5 from scipy.interpolate import interp1d
6
7 # Загрузка данных
8 df = pd.read_csv('diabetes.csv')
9
10 # Разделение данных по Outcome
11 xi0 = df[df['Outcome'] == 0]['Glucose'].values
12 xi1 = df[df['Outcome'] == 1]['Glucose'].values
13
14 # Корректировка данных для возможности логарифмирования
15 xi0_corrected = xi0 + 1
16 xi1_corrected = xi1 + 1
17
18 # Разделение на рабочие и контрольные выборки
19 xi0_train, xi0_test = train_test_split(
20     xi0_corrected, test_size=0.2, random_state=42
21 )
22 xi1_train, xi1_test = train_test_split(
23     xi1_corrected, test_size=0.2, random_state=42
24 )
25
26 def moment_method(sample_x, sample_y):
27     """Оценка параметров методом моментов"""
28     log_x = np.log(sample_x)
29     log_y = np.log(sample_y)
30
31     E_log_x = np.mean(log_x)
32     E_log_y = np.mean(log_y)
33     D_log_x = np.var(log_x, ddof=0)
34     D_log_y = np.var(log_y, ddof=0)
```

```

35
36     beta = np.sqrt(D_log_y / D_log_x)
37     ln_alpha = E_log_y - beta * E_log_x
38     alpha = np.exp(ln_alpha)
39
40     return alpha, beta
41
42 def ols_method(sample_x, sample_y):
43     """Оценка параметров методом наименьших квадратов"""
44     n_quantiles = min(len(sample_x), len(sample_y))
45     quantiles = np.linspace(0.01, 0.99, n_quantiles)
46
47     x_quantiles = np.quantile(sample_x, quantiles)
48     y_quantiles = np.quantile(sample_y, quantiles)
49
50     log_x = np.log(x_quantiles)
51     log_y = np.log(y_quantiles)
52
53     n = len(log_x)
54     sum_log_x = np.sum(log_x)
55     sum_log_y = np.sum(log_y)
56     sum_log_x_sq = np.sum(log_x ** 2)
57     sum_log_xy = np.sum(log_x * log_y)
58
59     denominator = n * sum_log_x_sq - sum_log_x ** 2
60     if abs(denominator) < 1e-10:
61         return moment_method(sample_x, sample_y)
62
63     beta = (n * sum_log_xy - sum_log_x * sum_log_y) / denominator
64     ln_alpha = (sum_log_y - beta * sum_log_x) / n
65     alpha = np.exp(ln_alpha)
66
67     return alpha, beta
68
69 def nls_method(sample_x, sample_y):
70     """Оценка параметров нелинейным методом наименьших квадратов"""
71     from scipy.optimize import minimize
72
73     n_quantiles = min(len(sample_x), len(sample_y))
74     quantiles = np.linspace(0.01, 0.99, n_quantiles)
75
76     x_quantiles = np.quantile(sample_x, quantiles)
77     y_quantiles = np.quantile(sample_y, quantiles)
78
79     def objective(params):
80         alpha, beta = params
81         y_pred = alpha * x_quantiles ** beta

```

```

82         return np.sum((y_quantiles - y_pred) ** 2)
83
84     try:
85         alpha_init, beta_init = ols_method(sample_x, sample_y)
86     except:
87         alpha_init, beta_init = moment_method(sample_x, sample_y)
88
89     result = minimize(objective, [alpha_init, beta_init], method='BFGS')
90     alpha, beta = result.x
91
92     return alpha, beta
93
94     # Оценка параметров тремя методами
95     alpha_mm, beta_mm = moment_method(xi0_train, xi1_train)
96     alpha_ols, beta_ols = ols_method(xi0_train, xi1_train)
97     alpha_nls, beta_nls = nls_method(xi0_train, xi1_train)
98
99     def empirical_distribution_function(sample):
100         """Построение эмпирической функции распределения"""
101         min_value = sample.min()
102         max_value = sample.max()
103         values = np.arange(min_value, max_value, 0.2)
104         probs = []
105
106         for value in values:
107             prob = np.sum(sample <= value) / len(sample)
108             probs.append(prob)
109
110         return values, np.array(probs)
111
112     def calculate_ks_statistic(sample_y, alpha, beta, sample_x):
113         """Вычисление статистики Колмогорова-Смирнова"""
114         phi_x = alpha * sample_x ** beta
115
116         y_sorted = np.sort(sample_y)
117         phi_sorted = np.sort(phi_x)
118
119         n_y = len(y_sorted)
120         n_phi = len(phi_sorted)
121
122         all_values = np.unique(np.concatenate([y_sorted, phi_sorted]))
123
124         F_y = np.array([np.sum(y_sorted <= val) / n_y for val in all_values])
125         F_phi = np.array([np.sum(phi_sorted <= val) / n_phi for val in all_values])
126
127         D = np.max(np.abs(F_y - F_phi))
128         return D

```

```

129
130 def calculate_mse(sample_x, sample_y, alpha, beta):
131     """Вычисление среднего квадрата ошибки"""
132     n_quantiles = min(len(sample_x), len(sample_y))
133     quantiles = np.linspace(0.01, 0.99, n_quantiles)
134
135     x_quantiles = np.quantile(sample_x, quantiles)
136     y_quantiles = np.quantile(sample_y, quantiles)
137
138     y_pred = alpha * x_quantiles ** beta
139     mse = np.mean((y_quantiles - y_pred) ** 2)
140     return mse
141
142 # Вычисление метрик для всех методов
143 ks_mm = calculate_ks_statistic(xi1_test, alpha_mm, beta_mm, xi0_test)
144 ks_ols = calculate_ks_statistic(xi1_test, alpha_ols, beta_ols, xi0_test)
145 ks_nls = calculate_ks_statistic(xi1_test, alpha_nls, beta_nls, xi0_test)
146
147 mse_mm = calculate_mse(xi0_test, xi1_test, alpha_mm, beta_mm)
148 mse_ols = calculate_mse(xi0_test, xi1_test, alpha_ols, beta_ols)
149 mse_nls = calculate_mse(xi0_test, xi1_test, alpha_nls, beta_nls)
150
151 # Выбор наилучшего метода
152 methods = [
153     ("Метод моментов", mse_mm, ks_mm, alpha_mm, beta_mm),
154     ("OLS", mse_ols, ks_ols, alpha_ols, beta_ols),
155     ("NLS", mse_nls, ks_nls, alpha_nls, beta_nls)
156 ]
157
158 best_method = min(methods, key=lambda x: x[2])
159 alpha, beta = best_method[3], best_method[4]
160
161 # Построение функций распределения для выбранного метода
162 values_xi0, probs_xi0 = empirical_distribution_function(xi0_test)
163 values_xi1, probs_xi1 = empirical_distribution_function(xi1_test)
164
165 phi_xi0 = alpha * xi0_test ** beta
166 values_phi, probs_phi = empirical_distribution_function(phi_xi0)
167
168 # Вычисление статистики Колмогорова-Смирнова
169 D_n = best_method[2]
170 alpha_level = 0.05
171 K_alpha = np.sqrt(-0.5 * np.log((1 - alpha_level) / 2))
172
173 print(f"Выбранный метод: {best_method[0]}")
174 print(f" = {alpha:.6f}, = {beta:.6f}")
175 print(f"Статистика Колмогорова-Смирнова: D_n = {D_n:.4f}")

```

```

176 print(f"Критическое значение: K_alpha = {K_alpha:.4f}")
177 print(f"Гипотеза { 'принимается' if D_n < K_alpha else 'отвергается' }")

```

5 Результаты

В результате выполнения программы были оценены параметры модели тремя методами. Наилучший метод выбран по минимальной статистике Колмогорова-Смирнова на контрольной выборке.




Рисунок 2 Сравнение методов оценки параметров

Метод	$\hat{\alpha}$	$\hat{\beta}$	MSE	D_n
Метод моментов	0.303030	1.306184	229.56	0.1100
OLS (квантили)	1.420479	0.979978	61.41	0.0993
NLS (квантили)	1.795230	0.930637	55.37	0.1204

Таблица 1: Сравнение методов оценки параметров




Рисунок 3 Функции распределения ξ_0 и ξ_1




Рисунок 4 Сравнение $F(\xi_1)$ и $F(\varphi(\xi_0))$

6 Анализ модели и проверка качества

На основе полученных результатов проведён анализ качества модели.

Анализ параметров модели:

Выбранный метод OLS дал следующие оценки параметров: $\hat{\alpha} = 1.420479$, $\hat{\beta} = 0.979978$.

Интерпретация параметров:

- Параметр $\hat{\alpha} = 1.420479$ определяет масштаб преобразования. Значение больше единицы указывает на то, что преобразованные значения $\varphi(\xi_0)$ в среднем выше исходных значений ξ_0 .
- Параметр $\hat{\beta} = 0.979978$ близок к единице, что означает почти линейную зависимость между уровнями глюкозы для пациентов с разными исходами заболевания. При $\hat{\beta} < 1$ зависимость замедляется с ростом ξ_0 , но в данном случае замедление незначительно.

Анализ функций распределения:

Сравнение функций распределения $F(\xi_1)$ и $F(\varphi(\xi_0))$ на графике показывает:

- Визуально кривые близки друг к другу в диапазоне значений от 75 до 200 мг/дл
- Максимальное расхождение наблюдается в области средних значений (около 120–150 мг/дл)
- В целом распределения совпадают по форме, что указывает на адекватность модели

Проверка гипотезы критерием Колмогорова-Смирнова:

Статистика критерия для выбранного метода OLS: $D_n = 0.0993$.

Критическое значение при уровне значимости $\alpha = 0.05$: $K_\alpha = 0.6101$.

Вывод о качестве модели:

Поскольку $D_n = 0.0993 < K_\alpha = 0.6101$, гипотеза о соответствии распределений принимается на уровне значимости 0.05. Это означает, что модель адекватно описывает стохастическую зависимость между уровнями глюкозы для разных исходов заболевания.

Ограничения модели:

- Модель предполагает степенную зависимость, что может быть упрощением реальной связи
- Объём выборки ограничен (768 наблюдений), что влияет на точность оценок
- Модель не учитывает другие факторы, влияющие на уровень глюкозы
- Разделение по Outcome может не отражать полную картину зависимости

7 Выводы

- Выполнена формализация задачи о стохастической зависимости между уровнями глюкозы для пациентов с разными исходами заболевания. Построена математическая модель на основе двупараметрической степенной функции связи $\xi_1 = \alpha \cdot \xi_0^\beta$, где ξ_0 и ξ_1 — уровни глюкозы для пациентов с разными диагнозами.
- Решены вычислительные задачи: оценка параметров тремя методами (моментов, OLS, NLS) с использованием квантильного сопоставления распределений, построение эмпирических функций распределения, вычисление статистики критерия Колмогорова-Смирнова для выбора наилучшего метода и проверки гипотезы.
- Проведён анализ качества модели. Выбран наилучший метод оценки параметров по минимальной статистике Колмогорова-Смирнова. Проверена гипотеза о соответствии распределений $F(\xi_1)$ и $F(\varphi(\xi_0))$ с использованием критерия Колмогорова-Смирнова.