

Вопросы по курсу «Моделирование» 8 семестр бакалавры

1. Математическое моделирование. Математическая модель. Испытания, эксперимент, опыт.
2. Решение инженерных задач на компьютере.
3. Натурный, полунатурный, вычислительный эксперименты.
4. Классификация математических моделей.
5. Классификация простых и сложных динамических систем. Простые и структурно-сложные динамические системы.
6. Классификация простых и сложных динамических систем. Системы, меняющие свое поведение во времени и гибридные сложные системы.
7. Организация квазипараллелизма в рамках последовательной архитектуры компьютера. Подход к имитации на основе активностей и событий.
8. Организация квазипараллелизма в рамках последовательной архитектуры компьютера. Подход к имитации на основе процессов и транзактов.
9. Организация квазипараллелизма в рамках последовательной архитектуры компьютера. Агрегатный подход к имитации.
10. Внешняя и внутренняя синхронизация имитационной модели. Модельное время.
11. Организация работы управляющей программы моделирования (УПМ).
12. Стохастическое моделирование. Основные понятия и определения. Выборочный метод. Генеральная совокупность.
13. Стохастическое моделирование. Основные понятия и определения. Точечные оценки параметров.
14. Стохастическое моделирование. Основные понятия и определения. Доверительное оценивание.
15. Стохастическое моделирование. Основные понятия и определения. Проверка статистических гипотез.
16. Моделирование случайных величин и векторов с заданными законами распределения.
17. Моделирование случайных величин и векторов с нормальным законом распределения.
18. Методы обращения и суперпозиции, их применение к моделированию скалярных случайных величин.
19. Общие методы моделирования случайных процессов.
20. Определение Марковского случайного процесса. Моделирование марковских случайных процессов.
21. Классификация инструментальных средств моделирования. История создания и особенности инструментальных средств моделирования.
22. Имитационные модели систем массового обслуживания. Среда имитационного моделирования GPSS.
23. Введение в анализ данных. Основные понятия, методы.
24. Анализ функциональных зависимостей между наблюдаемыми одновременно характеристиками объекта. Простая линейная регрессия и простой корреляционный анализ.
25. Анализ функциональных зависимостей между наблюдаемыми одновременно характеристиками объекта. Метод наименьших квадратов. Пример.
26. Подходы к оцениванию параметров зависимости между ненаблюдаемыми одновременно характеристиками объекта. Метод моментов. **Пример.**
27. Подходы к оцениванию параметров зависимости между ненаблюдаемыми одновременно характеристиками объекта. Метод максимального правдоподобия. **Пример.**
28. Дисперсионный анализ. Пример.
29. Анализ главных компонент. Пример.
30. Кластерный анализ. Пример.
31. Факторный анализ. Пример.
32. Дискриминантный анализ. Пример.
33. Анализ временных рядов. Основные задачи и методы.
34. Планирование эксперимента. История развития научного направления.
35. Планирование эксперимента. Факторные планы, дробные факторные планы.
36. Планирование эксперимента. Критерии оптимальности планов. Свойства планов.
37. Методика построения аналитической статической модели.
38. Методика построения аналитической динамической модели.
39. Методика построения имитационной модели систем массового обслуживания.
40. Методика построения имитационной стохастической модели.

1. Математическое моделирование. Математическая модель. Испытания, эксперимент, опыт.

1.1 Проблемы, возникающие при решении инженерных задач

- Проблема первая. Характеристики объектов испытаний, которые требуется определить в результате эксперимента, часто оказываются недоступными непосредственному измерению.
- Проблема вторая. Процессы функционирования объекта исследования часто имеют сложный динамический характер и подвержены существенным влияниям изменяющихся условий внешней среды.
- Проблема третья. При испытании сложных комплексов необходимо учитывать влияние испытательного, регистрирующего, управляющего оборудования (погрешность измерения).

Таким образом, эксперимент может оказаться продолжительным и дорогостоящим. В связи с этим необходим системный подход, предполагающий решение описанных выше проблем с обеспечением необходимой точности решения.

Математическое моделирование — метод исследования объектов и процессов реального мира с помощью их приближенных описаний с помощью формул (равенств, неравенств, уравнений, логических структур). Такое описание называют математическими моделями.

Математическая модель — формализация(мат.описание) процесса или объекта реального мира. Чаще всего представляется в виде системы уравнений, ограничения на переменные в которых лимитируются равенствами и неравенствами.

Мат. модель является альтернативной физической модели, которая предназначена для проведения натурных и полунатурных экспериментов. Для вычислительных экспериментов - мат. модель.

Процесс создания математической модели:

1. построение математической модели;
2. постановка исследования и решение вычислительных задач, реализующих модель;
3. проверка качества моделей на практике, модификация моделей.

1.2 Построение математической модели

Имея результаты эксперимента, можно установить связь между этими величинами, описываемую на языке математики. При выборе известной математической модели (модель должна быть достаточно полной для изучения свойств исследования или объекта и достаточно простой для реализации на ЭВМ) выбор учитываемых существенных и несущественных факторов носит исследовательский характер: как правило подтверждается характеристиками. В противном случае компромисс матмодели будет определен неверно.

Прежде чем использовать ту или иную известную матмодель необходимо определить тип модели: статическая или динамическая, аналитическая или имитационная, детерминированная или стохастическая, если стохастическая - то статистическая, вероятностная или феноменологическая.

Построение математической модели(по шагам)

1. анализируется возможность измерения известных согласно постановке задачи данных; строится схема объекта исследования в виде черного ящика с учетом количества компонент и изменения поведения системы во времени;
2. выбирается тип моделируемой системы (простая, структурно-сложная, сложная с изменяющимся поведением, гибридная, . . .). На схеме указываются все измеряемые переменные и параметры, указывается способ их получения;
3. определяется тип базовой вычислительной задачи (прямая, обратная, идентификационная);
4. указывается классифицирующие признаки модели (статическая или динамическая, аналитическая или имитационная, вероятностная или статистическая, . . .);
5. по результатам классификации с учетом опыта предметной области выбирается, модифицируется или строится матмодель.

План эксперимента – совокупность данных, определяющих количество, условия и порядок реализации опытов.

Опыт – воспроизведение исследуемого явления в конкретных условиях с последующей регистрацией результата. В условиях случайности в одних и тех же условиях проводятся параллельные (повторные) опыты в интересах получения статистически устойчивых результатов.

Активный эксперимент включает: систему воздействий, при которых воспроизводится функционирование объекта; регистрацию отклика объекта. Для него строится план эксперимента.

Подробнее про типы моделей в билете 4.

Про эксперимент смотреть в билет 3.

2. Решение инженерных задач на компьютере.

Основные этапы решения инженерной задачи. Вычислительный эксперимент.

- 1) Постановка задачи
- 2) выбор/построение мат. модели
- 3) постановка вычислительной задачи. получены в результате декомпозиции исходной задачи

Для каждой задачи:

- 4) предварительный предмашинный анализ свойств вычислительной задачи
- 5) выбор или построение(модификация) численного метода
- 6) алгоритмизация и программирование
- 7) отладка (тестирование)
- 8) отчет по программе
- 9) обработка интерпретации результатов
- 10) использование результатов коррекции мат модели, в случае признания модели неадекватной системе реального мира – возврат на этап 1/3/6

1) Задача формулируется на языке данной предметной области специалистом предметной области с учетом возможностей современной вычислительной техники. Имеется общая предварительная формулировка задачи. Формулируется(уточняется) цель исследования, определяются системы координат, входные и выходные данные, начальные и конечные условия.

2) если имеется готовая мат. модель, обычно она адаптируется(модифицируется) поставленной задаче, если нет – создается принципиально новая модель. определяет компромисс между полнотой описания объекта и сложностью модели. Если модель достаточно сложна, накопление ошибок при выполнении выч. задач оказывается значимым и может привести к неустойчивой работе алгоритма.

3) На основе ... проводят декомпозицию задачи на ряд подзадач, каждая из которых ставит в соответствие свою вычислительную задачу, решение которой легко формализовать. Классифицируют каждую задачу как прямую, обратную или задачу идентификации (в узком или широком смысле), определяют цель аналитического или численного исследования и алгоритмизируют его.

4) предварительный анализ свойств вычислительной задачи. анализируется корректность постановки по Адамару-Петровскому, изучаются упрощенные постановки задач, дающие возможность получить аналитическое решение либо исследуются качественные результаты задачи полученные на основе решения упрощенных задач

5) таким образом, решение инженерной задачи сводится к последовательному решению стандартных вычислительных задач, для которых разработаны численные методы, возможны ситуации, когда алгоритм необходимо адаптировать (модифицировать), либо создать новый метод. если имеется несколько методов решения, необходимо выбрать оптимальный.

6) алгоритмизация и программирование численный метод содержит схему решения, его формализацию, а разработка алгоритма и представление на ЯП – задача текущего этапа

7) поиск ошибок (в том числе синтаксических), отладка на тестовых задачах (имеющих известное решение), верификация, валидация и прочее – в соответствии с целью исследования

8) результаты выводятся в виде графиков, таблиц, диаграмм, удобных для восприятия или в виде формул на более высоком уровне абстракций. формулы позволяют компактно записать результат, но не информативны с точки зрения его получения. диаграммы зависимы от источника результата, способствуют быстрому принятию решений. наиболее часто при решении инженерной задачи результат демонстрируется в виде таблиц и графиков.

10) анализ с целью выявления некорректности модели, внедрение результатов. для последнего этапе часто используют результаты натурного эксперимента (т.е. с натурными, в том числе с физическими моделями объектов).

3. Натурный, полунатурный, вычислительный эксперименты.

Математическое моделирование разделяет научные, инженерные и экономические задачи. Классы задач различаются по:

- Временным затратам: научные не имеют ограничений по времени, в отличие от инженерных и экономических, которые конечны по времени и материальным затратам.
- По объемам вычислений: к экономическим задачам относятся вычислительно простые задачи, не требующие мощных вычислений. Инженерные задачи характеризуются широким спектром задач, но с типовыми алгоритмами решения. Научные задачи характеризуются неограниченным объемом вычислительных задач, для решения которых требуются мощные вычислители.
- По математической модели: экономические задачи не требуют прототипирования, в отличие от инженерных и научных задач.

Инженерные задачи используют типовые математические модели с привлечением известного математического аппарата. Научные задачи требуют модификации типовых моделей или разработки принципиально новых с привлечением современного математического аппарата

Для проведения эксперимента:

1. составляется план;
2. создается экспериментальная установка;
3. выполняются контрольные эксперименты;
4. проводятся серийные опыты;
5. обрабатываются полученные экспериментальные данные и их результаты.

Вычислительный эксперимент: проводится с использованием компьютера.

Достоинства: позволяет изменить время протекания эксперимента, установить зависимости между наблюдаемыми показателями и исследуемыми.

Недостатки: точность результатов решения задачи ниже точности результатов натурного эксперимента

Натурный эксперимент: эксперимент с реальными объектами и процессами. Физическая модель может быть использована в натурном эксперименте.

Достоинства: высокая точность решения задачи

Недостатки: такие эксперименты дорогостоящи

Полунатурный эксперимент: компромисс между вычислительным и натурным, так как использует физическую модель реального объекта или процесса.

Достоинства: дешевле натурного

Недостатки: снижается точность по сравнению с натурным

Подробнее по ним же:

Натурные эксперименты как правило дороги, часто продолжительны. Дешевой и быстродейственной альтернативой натурному эксперименту является **вычислительный эксперимент**, в основе которого лежит реализация математической модели на ЦВМ. Возникает коллизия: для построения модели необходимо провести натурный эксперимент (что бывает невозможно). С другой стороны матмодель строится как альтернатива натурному эксперименту. Эта коллизия считалась нерушимой до середины двадцатого века. Компромиссом является так называемый **полунатурный эксперимент**, где в качестве модели используются физическая модель объекта, доступные характеристики оцениваются экспериментально (н: число Маха в аэродинамической трубе), другие — программно.

4. Классификация математических моделей.

Существуют следующие классификации мат. моделей:

1) Статическая или динамическая

- **Статическая модель** — описывает явления в предположении, что процесс завершен;
- **Динамическая модель** — описывает явления или процессы реального мира при переходе от одного состояния к другому;

2) Аналитическая или имитационная

• **Имитационная модель** — представляет собой численный метод вычислительного эксперимента, позволяет имитировать поведение реальной системы на ЦВМ в заданный или формируемый период времени с определенным набором входных данных; при заданных исходных данных.

• **Аналитическая модель** - формализация явления или процесса реального мира, учитывающая физико-химические воздействия, протекающие в системе.

3) детерминированная или стохастическая

Детерминированная модель - такая модель, в которой преобразование входных данных в выходные основывается на вполне определенном детерминированном алгоритме.

Стохастическая модель - такая модель, входными и выходными данными которой являются случайные величины, а преобразование входных данных в выходные осуществляется посредством случайной функции (процесса).

4) если стохастическая - то статистическая, вероятностная или феноменологическая.

Если модель основана (базируется) на основной задаче теории вероятности, то речь идет о **вероятностной модели**

Если на одной из трех задач математической статистики — то о **статистической**.

Отдельно выделяют класс **феноменологических моделей**, построенных на результатах конкретного(уже оконченного) эксперимента.

Основная задача теории вероятности - поиск вероятности в схеме Бернулли

Основные задачи математической статистики:

- точечное оценивание параметров распределения характеристики объекта
- интервальное оценивание (построение доверительных интервалов) для параметров распределения

характеристики объекта

- проверка статистических гипотез

5. Классификация простых и сложных динамических систем. Простые и структурно-сложные динамические системы.

Классификация динамических систем

В системе могут изменяться два и более объектов, кроме того возможно взаимодействие (обмен данными) между объектами, что говорит о сложных структуре и поведении динамических систем. Необходимо учитывать взаимодействие компонент, появление новых, удаление имеющихся, изменения условий функционирования системы и ограничения наложенные на систему.

Различают простые динамические системы, структурно-сложные динамические системы, сложные динамические системы, меняющие поведение во времени, структурно-сложные гибридные системы.

Простые динамические системы

Определение: обычно понимается система, поведение которой задается совокупностью обыкновенных дифференциальных уравнений в форме Коши с достаточно гладкими правыми частями, обеспечивающими существование и единственность решения. Примерами объектов являются: современная баллистическая задача, задача с бассейном (в одну трубу вливается, в другую выливается) и др.

В ряде случаев система может быть представлена в виде нескольких простых динамических систем. Тогда такая система тоже считается просто динамической.

Структурно-сложные динамические системы

Большинство технических и природных систем являются более сложными, при наличии нескольких взаимодействующих компонент системы говорят о структурно-сложной динамической системе.

Структура современных моделей соответствует структуре изучаемого объекта, но функционирование каждой компоненты системы скрыто от наблюдателя. Известны только входные (в ряде случаев выходные) данные и структура системы. Модель представляется в виде черного ящика с указанием количества компонентов и схемы их взаимодействия. (при моделировании в данном случае обычно применяют объектно-ориентированный подход)

При моделировании работы каждой компоненты можно получать сведения об изменении их состояния в т.ч. с учетом взаимодействий. При параллельном функционировании компонент в системе требуется синхронизация такого взаимодействия.

6. Классификация простых и сложных динамических систем. Системы, меняющие свое поведение во времени и гибридные сложные системы.

Простая динамическая система

Простыми динамическими системами называются системы, поведение которых описывается системами линейных дифференциальных уравнений в форме Коши с достаточно гладкими правыми частями. Более сложной, чем модель Ньютона, является современная баллистическая задача, решение которой сводится к системе ДУ в частных производных.

Класс таких задач не велик, а решение хорошо известно. Предварительная подготовка решений обычно сводится к проверке совпадения числа неизвестных и числа уравнений в системе. Большинство систем на практике являются более сложными.

Сложные динамические системы, меняющие поведение во времени

Одной из черт сложного поведения системы является наличие у системы нескольких сменяющих друг друга состояний. Такие изменения можно представить блочной структурой и описывать как простую динамическую систему с определенными параметрами нагружения на разных уровнях. В случае периодической нагрузки это оправдано, но в случае стохастического изменения поведения описание оказывается сложным.

Непрерывное изменение поведения системы можно дискретизировать, понимая, что на границе блоков необходимо исследовать переходную функцию. В противном случае модель будет иметь значительную погрешность.

Погрешность моделирования — осознанное пренебрежение при построении матмодели.

Причинами разрывов функций может быть использование недостаточно гладких функций для описания дискретного блока. Такие системы называются гибридными (в принципе о таких можно говорить т.к. внутри каждого из дискретных состояний объект или система ведет себя как непрерывная компонента), и помимо описания разных стилей поведения системы требует исследования функций, формализующих это поведение.

Структурно-сложная гибридная система

Соединяет черты структурно-сложных и систем меняющих поведение во времени. Сложность моделирования делает почти невозможной использование аналитических моделей в силу чего такой класс систем предполагает построение имитационных моделей.

7. Организация квазипараллелизма в рамках последовательной архитектуры компьютера. Подход к имитации на основе активностей и событий.

Под квазипараллелизмом понимают организацию моделирования объектов или систем параллельно функционирующих в реальном мире на компьютерах последовательной архитектуры.

Различают способы организации:


1. активностями
2. событиями
3. транзактами
4. процессами
5. агрегатами

1, 2, 3 – Дискретно-событийный; 4, 5 – Агентный. Подходы 1-5 обеспечивают высокую точность моделирования для разных уровней исследования. Подходы 1-3 в задачах, где требуется невысокая точность решения, и качественным решением. Предлагается синергетический подход для решения таких задач – дискретно-событийный подход. Подходы 4-5 на синергетическом уровне формирует агентный подход моделирования.

Организация активности:

а) активностями

Вводится понятие активности которое объединяет для i -ой компоненты ее j -го состояния алгоритм обработки и квант модельного времени, в течение которого функционирует модель. Обозначение: $A_{ij} = \{A_{ij}, \Delta\tau_{ij}\}$. Таким образом, A_{ij} могут отличаться для i -ой компоненты. В случае выбора модельного времени с постоянным шагом применяется $\Delta\tau_j$.



Применение аналитическим моделей в реализации A_{ij} обеспечивает достаточно высокую точность расчетов, при этом модельное время позволяет обеспечить внешнюю и внутреннюю синхронизацию, в том числе обмен данными между компонентами.

б) событиями $C_{ij} = \{S_{ij}, \Delta\tau_{ij}\}$, где $\Delta\tau_{ij} \rightarrow \tau_{ij}^H$

Обозначение: $C_{ij} = \{S_{ij}, \Delta\tau_{ij}\}$, где $\Delta\tau_{ij} \rightarrow \tau_{ij}^H$. Вводится понятие события, где S_{ij} – наступление события, второй параметр – показатель модельного времени. Если, согласно условия задачи (описанию предметной области), расписание не меняется, то используется квант модельного времени посредством происходит синхронизации модели (внутреннюю и внешнюю). В предположении, что расписание может быть нарушено, квант модельного времени $\Delta\tau_{ij} = \tau_{ij}^H + \Delta\tau_{ij}^T$.

8. Организация квазипараллелизма в рамках последовательной архитектуры компьютера. Подход к имитации на основе процессов и транзактов.

Под квазипараллелизмом понимают организацию моделирования объектов или систем параллельно функционирующих в реальном мире на компьютерах последовательной архитектуры.

Различают способы организации:

6. активностями
7. событиями
8. транзактами
9. процессами
10. агрегатами

1, 2, 3 – Дискретно-событийный; 4, 5 – Агентный. Подходы 1-5 обеспечивают высокую точность моделирования для разных уровней исследования. Подходы 1-3 в задачах, где требуется невысокая точность решения, и качественным решением. Предлагается синергетический подход для решения таких задач – дискретно-событийный подход. Подходы 4-5 на синергетическом уровне формирует агентный подход моделирования.

Организация активности:

в) транзакциями

Вводится понятие транзакта – заявки на обслуживание. Транзакты имеют индивидуальный закон распределения. Для транзакта с конкретным законом распределения Закон распределения случайной величины (транзакта) может быть выбран из анализа предметной области. В ряде случаев распределение известно из анализа области исследования (в теории надежности – закон пуассона, распределение клиентов – нормальный закон). Если распределение неизвестно, необходимо провести натурный эксперимент, ошибка в выборе распределения приведет к ошибке модели (вычислительного эксперимента).

Однотипные объекты не всегда описываются одинаковыми законами распределения (отличаются параметрами), в силу чего статистические характеристики для каждого типа объекта на выходе также отличаются.

Генерация заявок осуществляется устройствами (станки, окошки регистратуры, ...). Поступающие заявки организуются в очереди и регламентируется семафором. Если семафор =1 будет выполнена первая вошедшая в очередь заявка, либо с высшим приоритетом. Под устройством понимают блоки обработки станки, рабочие станции, касса, окошко регистратуры. Различают простую дисциплину обработки (выполнена/не выполнена) , но может рассматриваться и многоблочная.

г) процессный подход

Вводится понятие процесса, являющееся неделимой единицей исследования – действие.

Взять направление – подпись зам дека – подпись зав кафе – сдача задания – оценка преподавателя – учет направления – возврат в деканат.

При процессной организации квазипараллелизма в качестве заявки выступает не объект, а запрос на действие. Рассматривается дисциплина обработки таких запросов, существующих в данное время, желаемое в результате оптимизации, получается внедряемое. Обработка может быть сведена к транзактному подходу, если считать транзактом запрос на действие.

9. Организация квазипараллелизма в рамках последовательной архитектуры компьютера. Агрегатный подход к имитации.

Под квазипараллелизмом понимают организацию моделирования объектов или систем параллельно функционирующих в реальном мире на компьютерах последовательной архитектуры.


Различают способы организации:

11. активностями
12. событиями
13. транзактами
14. процессами
15. агрегатами

1, 2, 3 – Дискретно-событийный; 4, 5 – Агентный. Подходы 1-5 обеспечивают высокую точность моделирования для разных уровней исследования. Подходы 1-3 в задачах, где требуется невысокая точность решения, и качественным решением. Предлагается синергетический подход для решения таких задач – дискретно-событийный подход. Подходы 4-5 на синергетическом уровне формирует агентный подход моделирования.

д) агрегатами

Агрегатный подход предполагает описание структурно-сложной и изменяющей поведение во времени гибридной системы, моделирование которой должно иметь достаточно высокую точность. В этом случае агрегат строится иерархически. Внутри агрегата оказывается параллельно-последовательная схема. Параллельно действующие – отдельный компонент. У иерархии может быть несколько уровней вложенности компонент, построение модели начинается с самого высокого.



Строится схема параллельного функционирования в реальном времени, на который выделяются компоненты. В соответствии с реальным устанавливаются моменты модельного времени, кванты модельного времени вычисляются по текущему значению модельного времени. В отличие от имитации активностями, где условия, наложенные на каждый алгоритм, оказываются автономными, в случае агрегатного описания имеет место как общие алгоритмы, так и общие наборы условий. Кроме того, для разных компонент, при совпадении алгоритма, условия могут отличаться. Таким образом, имеет место "пересечение условий".

Это не вызывает конфликтной ситуации в системе, данные, удовлетворяющие запросу, обрабатываются и одним и другим алгоритмом, результат обработки помещается в общее информационное поле.

10. Внешняя и внутренняя синхронизация имитационной модели. Модельное время.

Обмен данными между компонентами структурно-сложной динамической системой проходит через информационного поле (пространство) массив данных, каждая строка которого соответствует i -му компоненту системы а каждый столбец j -му состоянию в некоторый фиксированный момент времени, актуальная компонента (та от которой ждут данных) выгружает данные в информационное пространство, после чего эти данные становятся доступными другим компонентам. В ряде случаев процесс обмена синхронизируется посредством модельного времени. Если данные характеризующие компоненту не актуальны для других компонентов, то систему можно рассматривать как несколько простых динамических систем. (вычислительный эксперимент проводить как последовательно так и параллельно независимо от процессов в реальном времени.

Реальным временем — непрерывное время, в котором функционирует моделируемый объект (или система).

Вычислительное время — время вычислительного эксперимента, зависящее от архитектуры компьютера и технологических остановов.

Модельное время — дискретное время, в единицах реального времени, обеспечивающие синхронизацию вычислительных процессов (как внутреннюю, так и внешнюю). (модельное время дискретно, это отличие от реального, изменяются в одних единицах)

1) Выбор с переменным шагом

События моделируются на компьютере в соответствии с временем τ

– а) два и более событий подлежат описанию в один и тот же момент модельного времени независимо от того, какой процесс раньше развивается в реальном времени моделируется одна компонента затем другая, после этого происходит коррекция квантового времени

+ б) продолжительное время в реальной системе не возникает новых событий

2) Выбор с постоянным шагом

время дискретизируется одинаково то есть кванты времени одинаковы, причем одинаковы для всех компонент

+а) когда два и больше событий в один квант

–б) когда долго нет новых событий (простой)

3) с постоянно переменным шагом

+а) когда 2 и больше (делим квант пополам)

+б) когда долго нет событий (увеличивает квант в 2 раза)

Для каждой компоненты сложной системы, кроме алгоритма, требуется выбрать временную координату функционирования. Добавление операторов преобразования временной координаты может потребовать дополнительной декомпозиции системы.

Непосредственно синхронизация осуществляется с помощью семафоров глобальных переменных, значение которых либо разрешает, либо запрещает оптимизацию имитатора конкретной компоненты. В случае запрета компоненты записываются в очередь согласно приоритету. Сброс семафора приводит к активизации компоненты, если несколько заявок имеют один приоритет, то очередь устанавливается внутри приоритета.

Внутренняя синхронизация — внутренняя очередь.

Внешняя синхронизация — реализуется с целью ликвидации конфликтов, т.е. обращение разных заявок к одним и тем же ресурсам компьютера. Реализуется в модельном времени. Создаются специальные операторы синхронизации, напр, для немедленного перевода процесса в ждущее состояние или в ждущее состояние по условию. Такими операторами алгоритм функционирования имитационной модели разделяется на фрагменты в рамках которых реализуются действия запрещенные в другие моменты времени.

Синхронизация модели управления информацией. Чтобы результаты функционирования некоторого в некотором кванте времени появились в информационном пространстве не раньше и не позже известного момента времени используют этот вид синхронизации, т.е. создают массив, доступный только для данного процесса и оператора ожидания. При наступлении условий или заданного момента времени рабочий массив компоненты передает указатель на нужные данные в памяти.

Таким образом, алгоритм оказывается рассеян операторами синхронизации (в модельном времени). Именно в эти моменты обеспечивается обращение к УПМ.

11. Организация работы управляющей программы моделирования (УПМ).

Функции, как правило, возложены на управляющую программу моделирования (УПМ).

На этом этапе выполняется последовательность действий:

- внешняя и внутренняя синхронизация компонент модели;
- синхронизация моментов появления информации от одной компоненты модели к другой;
- описание поведения компонент при появлении конфликтных ситуаций в модели;
- уточнение состава исходной информации для имитации;
- организация окончания имитации;
- реализация контроля за ходом имитации;
- организация сбора статистики;
- уточнение состава документации на моделирование.

(по синхронизации ниже - копия с файлов домы, в прошлом билете - то что диктовала)

Внутренняя синхронизация компонент модели

Переход от формального описания к имитационной модели осуществляется на основе декомпозиции сложной системы на составные части.

Для каждой компоненты сложной системы кроме алгоритма требуется еще установить временную координату функционирования. Добавление операторов преобразования временной координаты компоненты модели является первым шагом превращения формального описания в ИМ.

Если требуется дополнительная декомпозиция компонент (активностей, подпрограмм обслуживания событий, процессов) на несколько более мелких, которые выполняются с меньшим интервалом времени, то декомпозиция требуется и для соответствующих алгоритмов. Для транзактного и агрегатного способов имитации такая процедура выполнена на этапе составления формального описания модели (изменение временных координат агрегатов или блоков модели унифицировано).

Внутренняя синхронизация компонент обеспечивается с помощью семафоров - глобальных переменных, значение которой либо разрешает, либо запрещает активизацию имитатора компоненты в модельном времени. В случае запрета активизации все компоненты модели выстраиваются в очередь на активизацию согласно их приоритетам. Сброс семафора приводит к активизации ожидающих его компонент. Установка - порождает очередь компонент на активизацию.

Для транзактного способа имитации сами очереди к блокам являются хорошим средством внутренней синхронизации. В случае агрегатного способа для имитации взаимодействия агрегатов на этапе формального описания используются управляющие и входные сигналы. При процессном способе кроме семафоров необходимы установка операторов взаимодействия процессов друг с другом, выбор дисциплин обслуживания очередей и пр.

Внешняя синхронизация компонент модели

Реализуется, как правило, выбранной системой моделирования. Используются операторы синхронизации компонент в системе дискретных событий. Используются операторы синхронизации

- немедленного перевода процесса в ждущее состояние;
- перевода процесса в ждущее состояние до выполнения некоторого условия и пр.

Таковыми операторами алгоритм функционирования компонент ИМ делится на части.

Для транзактного и агрегатного способов внешняя синхронизация также не требуется.

Синхронизация моментов появления информации

Важно, чтобы результаты функционирования некоторого кванта некоторого процесса появились в поле информации не ранее и не позже некоторого момента времени. Иначе существенно искажается динамика имитации взаимодействия компонент сложной системы.

Для этого используют рабочий массив, доступный только для данного процесса и оператор условного ожидания некоторого момента времени. При наступлении этого момента происходит перепись рабочего массива в общее поле информации процессов модели. Аналогично при имитации активностями или событиями. При прочих методах имитации такая синхронизация не обеспечивается.

После установки операторов внешней и внутренней синхронизации алгоритмы оказываются разделенными на кванты, в этих местах происходит обращение к управляющей программе.

Отражение конфликтных ситуаций в модели

Синхронизация процессов друг с другом с помощью операторов запуска и останова процессов. Обычно здесь работают системы приоритетов компонент ИМ.

Уточнение исходной информации при моделировании.

Разрабатывается блок задания начальных условий имитации. Реализуется однократно в модельном времени. В ходе задания начальных условий устанавливаются режимы моделирования.

При процессном способе имитации - специальный процесс инициатор. В функции инициатора входят установка каждого из процессов модели в начальное состояние перед началом имитации, выдача документальной информации о начальных условиях процесса имитации, задание и модификация процессов моделирования.

При имитации активностями выделяют активности-лидеры - устанавливают другие активности в начальное состояние.

Для событийного - специальное начальное состояние модели - начальное событие.

При транзактном - начальные значения параметров источников транзактов, состояния очередей, занятость блоков обслуживания транзактов, с которых необходимо начать имитацию.

При агрегатном реализует операторы задания начальных условий автоматически.

Организация окончания имитации

Аналогично реализуется блок окончания моделирования. Функции: отражает последовательность действий по контролю за моментами окончания имитации и начала обработки результатов моделирования, планирование очередного имитационного эксперимента.

Контроль за ходом имитации

Реализуется соответствующий блок, чтобы принимать решение об окончании имитации. При длительной работе в ОП копируется состояние модели, работа с которой может прерываться и возобновляться при появлении отказов в ЭВМ. При транзактном способе моделирования оперативный контроль не нужен, при агрегатном стандартизирован.

Организация сбора статистики

Устанавливаются операторы сбора статистики ("наблюдатели модели").

Можно фиксировать, например, время жизни объекта в модели.

Разрываются дополнительные интервалы функционирования процессов. Образованные операторами синхронизации.

Стандартная статистика: число взаимодействий компонент модели, число отказов функционирования компоненты системы и время, в течение которого она находилась в аварийном состоянии.

Иногда требуется вводить специальные процессы активности, фиксирующие статистическую информацию о моделируемом объекте.

Для агрегатного и транзактного способа имитации сбор статистики стандартизирован.

Документирование

Результат этапа - описание имитационной модели, готовое к программированию на выбранном языке моделирования.

При транзактном и агрегатном способе моделирования этот этап практически вырождается, при остальных - существенно увеличивается за счет введения дополнительных блоков и операторов моделирования.

12. Стохастическое моделирование. Основные понятия и определения. Выборочный метод. Генеральная совокупность.

При построении стохастических моделей обычно используется выборочная терминология. Пусть имеется конечный или бесконечный набор всех возможных значений некоторой случайной величины: $\xi : X = \{x_1, \dots, x_n, \dots\}$ (1), в котором элементы последовательности независимы. (1) называется генеральной совокупностью исследуемой случайной величины. Если из (1) случайным образом выбирается k элементов, то речь идет о выборке $x \subset X : \{x_1, \dots, x_k\}$

Выборочным средним называют величину $\bar{x} = \frac{1}{k} \sum_{i=1}^k x^{(i)}$ (3). Она является эмпирическим аналогом исследуемой

случайной величины. Другой характеристикой является выборочная дисперсия

$$\hat{S}^2 = \frac{1}{k} \sum_{i=1}^k (x^{(i)} - a)^2 \text{ - дисперсия: величина, характеризующая разброс } x^{(i)} \text{ относительно } \bar{x}.$$

$$\hat{\sigma} = \sqrt{\hat{S}^2} \text{ - среднее квадратическое отклонение.}$$

$$\hat{\mu}^l = \frac{1}{k} \sum_{i=1}^k (x^{(i)} - a)^l \text{ - момент } l\text{-ого порядка.}$$

Если $\bar{x} = a$, то это центральный момент l -ого порядка, если $a = 0$ - начальный момент l -ого порядка.

Копипаста отсюда: <http://www.statmethods.ru/konsalting/statistics-metody/106-teoriya-vyborochnykh-obsledovaniy.html>

Выборочный метод (method of sampling) – статистический метод исследования общих свойств совокупности каких-либо объектов на основе изучения свойств лишь части этих объектов. Совокупность исследуемых объектов, интересующих исследователя, называется генеральной совокупностью. А часть объектов, подлежащих изучению, называют выборочной совокупностью или выборкой.

Необходимость выборочного метода может быть вызвана объективными причинами:

- объект исследования очень обширный, например, исследование потребительских предпочтений на рынке продукта, прогноз результатов голосования на выборах и т.д.

- необходимость в сборе первичной информации в «пилотных» исследованиях.

Ключевые вопросы выборочного обследования:

- количественная характеристика выборки или определение минимального количества наблюдений (объема выборки) для проведения исследования;

- качественная характеристика выборки или способы и методы формирования выборочной совокупности.

Главная задача выборочного обследования – с минимальным объемом выборки получить как можно более точное описание интересующей генеральной совокупности на основе выборочных данных. Добиться этого можно только на основе репрезентативной выборки, т.е. выборки объективно отражающей свойства генеральной совокупности.

Точность результатов выборочных обследований достигается за счет использования сложных методов формирования выборки (кластерного отбора, задания расслоения, использования вероятностно-пропорционального отбора, простого случайного или случайного отбора, повторного или бесповторного отбора).

Минимальный объем выборки зависит от многих параметров исследования (оцениваемого показателя или системы показателей, способа и методов формирования выборки, вариации исследуемых данных, заданной надежности получаемых результатов, максимально допустимой ошибки в оценки показателей) и определяется на основе формул математической статистики или экспертным путем.

13. Стохастическое моделирование. Основные понятия и определения. Точечные оценки параметров.

Наиболее часто для построения точечных оценок используют метод моментов и метод максимального правдоподобия.

Метод моментов.

Пусть $x_1, x_2, \dots, x_n$ – независимая случайная повторная выборка из генеральной совокупности с плотностью распределения $f(x, \theta)$, зависящей от неизвестного параметра θ . В качестве оценки неизвестного параметра берется то его значение, при котором точное или “теоретическое” значение первого момента совпадает с его эмпирическим значением, найденным по результатам выборки. Найдем первый момент (математическое ожидание):

- теоретическое значение первого момента: $\mu_1 = \mu_1(\theta) = \int_{-\infty}^{\infty} xf(x)dx$.

- эмпирическое среднее: $\hat{\mu} = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$,

в качестве оценки $\hat{\theta}$ принимается решение следующего уравнения $\mu_1(\theta) = \bar{x}$

В случае нескольких неизвестных параметров они находятся из решения уравнений

(система) $\mu_1(\theta_1, \theta_2, \dots, \theta_l) = \hat{\mu}_1$

...

$\mu_l(\theta_1, \theta_2, \dots, \theta_l) = \hat{\mu}_l$, где $\mu_l(\theta_1, \theta_2, \dots, \theta_l) = \int_{-\infty}^{\infty} x^l f(x, \theta_1, \theta_2, \dots, \theta_l) dx$

- “теоретическое” знач. момента порядка r , а его эмпирическое знач. найденное по выборке: $\hat{\mu}_r = \frac{1}{n} \sum_{i=1}^n x_i^r$

Очевидно, при $l=2$ указанная система уравнений может быть записана в следующем эквивалентном виде:

(система) $\mu_1(\theta_1, \theta_2) = \bar{x}$, $D(\theta_1, \theta_2) = S^2$

$D(\theta_1, \theta_2)$ – точное или теоретическое значение дисперсии, а S^2 – эмпирическая дисперсия. Метод моментов дает состоятельные оценки, но недостаточно эффективные.

Метод максимального правдоподобия

Пусть $x_1, x_2, \dots, x_n$ – независимая случайная повторная выборка из генеральной совокупности с плотностью распределения $f(x, \theta)$, зависящей от неизвестного параметра θ . Совместная плотность распределения всех результатов выборки $f(x_1, \theta) \cdot \dots \cdot f(x_n, \theta) = L(x_1, x_2, \dots, x_n, \theta)$ называется функцией правдоподобия.

В качестве оценки $\hat{\theta} = \hat{\theta}(x_1, \dots, x_n)$ берется значение, при котором функция правдоподобия, рассматриваемая как функция от этого параметра при фиксированных результатах наблюдений $x_1, \dots, x_n$ обращается в максимум, то есть оценка максимального правдоподобия находится из соотношения $L(x_1, x_2, \dots, x_n, \hat{\theta}) = \max_{\theta} L(x_1, x_2, \dots, x_n, \theta)$

В ряде случаев удобно искать максимум не из самой функции, а из ее логарифма. Предполагается, что функция дифференцируема по θ и оценка максимального правдоподобия находится по формуле $\frac{\partial}{\partial \theta} \ln L(x_1, x_2, \dots, x_n, \hat{\theta}) = 0$.

уравнение правдоподобия (необходимое, но недостаточное условие максимума). Для многих распределений имеет единственное решение, которое и дает искомую оценку максимального правдоподобия. В случае нескольких неизвестных параметров необходимо решить систему уравнений относительно $\theta_1, \dots, \theta_l$ при фиксированных $x_1, \dots, x_n$:

(система) $\frac{\partial}{\partial \theta_1} \ln L(x_1, x_2, \dots, x_n, \theta_1, \theta_2, \dots, \theta_l) = 0 \quad \dots \quad \frac{\partial}{\partial \theta_l} \ln L(x_1, x_2, \dots, x_n, \theta_1, \theta_2, \dots, \theta_l) = 0$

Когда существует эффективная оценка, метод максимального правдоподобия дает эту оценку. В общем случае при довольно общих условиях метод максимального правдоподобия дает асимптотически несмещенные и асимптотически эффективные оценки при $n \rightarrow \infty$.

Пусть $x_1, \dots, x_n$ – независимая случайная повторная выборка из генеральной совокупности с функцией распределения $F(x, \theta)$ и плотностью распределения $f(x, \theta)$, зависящей от неизвестного параметра θ . Предположим, что для параметра θ на основе выборки построен интервал $[\theta_-, \theta^+]$, нижняя и верхняя граница которого являются

некоторыми функциями от выборки $\theta_- = \theta_-(x_1, \dots, x_n)$ и $\theta^+ = \theta^+(x_1, \dots, x_n)$. Интервал $[\theta_-, \theta^+]$ называется доверительным интервалом для параметра с коэффициентом доверия γ , если при всех возможных значениях θ : $P(\theta_- \leq \theta \leq \theta^+) = \gamma$

Доверительный интервал дает информацию не только о том, где находится истинное значение параметра, но и точности оценивания.

14. Стохастическое моделирование. Основные понятия и определения. Доверительное оценивание.

Одним из часто используемых для построения интервалов методов является метод, основанный на предварительном построении некоторой центральной статистики.

Центральной статистикой - называется любая функция, зависящая от параметра и от выборки

$$T = T(x_1, x_2, \dots, x_n, \theta)$$

Предположим, что такая центральная статистика является монотонной функцией параметра θ , например, монотонно убывающей.

Квантилем уровня α функции распределения $F(t)$ случайной величины T называется величина $K = K(\alpha)$, определяемая из условия $P(T \leq K) = F(K) = \alpha$.

Зададимся двумя малыми числами $\varepsilon_1, \varepsilon_2$ и определим величины t_1, t_2 из условий

$$P(T \leq t_1) = F(t_1) = \varepsilon_1$$

$$P(T > t_2) = 1 - F(t_2) = \varepsilon_2.$$

Очевидно, здесь $t_1 = K(\varepsilon_1), t_2 = K(1 - \varepsilon_2)$.

Тогда для центральной статистики будет выполняться равенство

$$P\{t_1 \leq T(x_1, x_2, \dots, x_n, \theta) \leq t_2\} = \gamma, \quad \gamma = 1 - \varepsilon_1 - \varepsilon_2$$

Далее нижняя и верхняя граница θ_- , θ^+ доверительного интервала определяются как соответственно

минимальное и максимальное значение среди всех θ , удовлетворяющих неравенствам $t_1 \leq T(x_1, x_2, \dots, x_n, \theta) \leq t_2$, откуда выполняется

$$P(\theta_- \leq \theta \leq \theta^+) = \gamma$$

В большинстве случаев статистика выбирается монотонно убывающей и зависящей от θ , тогда верхняя и нижняя граница доверительного интервала определяются из уравнений (система)

$$T(x_1, x_2, \dots, x_n, \theta_-) = t_2, \quad T(x_1, x_2, \dots, x_n, \theta^+) = t_1$$

Если центральная статистика монотонно возрастает по θ , то границы доверительного интервала находятся из уравнений

$$T(x_1, x_2, \dots, x_n, \theta_-) = t_1, \quad T(x_1, x_2, \dots, x_n, \theta^+) = t_2$$

При этом на практике чаще всего доверительный интервал строится симметричным образом, то есть

$$\varepsilon_1 = \varepsilon_2 = \varepsilon = (1 - \gamma)/2.$$

Пример. Доверительные интервалы для параметров нормального распределения.

При известной дисперсии для доверительного оценивания мат. ожидания в качестве исходной центральной статистики возьмем следующую

$$T = \left(\frac{\bar{x} - \mu}{\sigma} \right) \sqrt{n},$$

которая имеет стандартное нормальное распределение с параметрами 0,1 (монотонно убывает по μ). Соответственно имеется система

$$\left(\frac{\bar{x} - \mu_-}{\sigma} \right) \sqrt{n} = t_2 = u_{1-\varepsilon}, \quad \left(\frac{\bar{x} - \mu^+}{\sigma} \right) \sqrt{n} = t_1 = u_\varepsilon$$

где u_α – квантиль уровня α стандартного нормального закона, $\varepsilon = (1 - \gamma)/2$. Так как для нормального закона $u_\varepsilon = -u_{1-\varepsilon}$ получаем следующие нижние и верхние границы

$$\mu_- = \bar{x} - u_{1-\varepsilon} \left(\frac{\sigma}{\sqrt{n}} \right), \quad \mu^+ = \bar{x} + u_{1-\varepsilon} \left(\frac{\sigma}{\sqrt{n}} \right)$$

15. Стохастическое моделирование. Основные понятия и определения. Проверка статистических гипотез.

Статистической гипотезой H называют любое утверждение относительно функции распределения $F(x)$ некоторой СВ x , касающейся типа ФР, значения ее параметров и т.д.

Гипотезы H проверяют путем сопоставления выдвинутых предположений с результатами эксперимента, который в статистике представляет собой n независимых наблюдений над СВ x , то есть выборку $x_1, \dots, x_n$, где $x_i, i=1, \dots, n$ - независимые одинаково распределенные СВ, каждая с ФР $F(x)$.

Гипотезу называют **простой**, если ее условиям удовлетворяет единственная ФР $F(x)$, в противном случае - сложная. Гипотеза, справедливость которой проверяется в ходе эксперимента называется **основной** или **нулевой** гипотезой H_0 . В зависимости от того, какие отклонения от H_0 возможны, формулируют альтернативные (конкурирующие) гипотезы H_1 .

Статистические гипотезы проверяют с помощью статистических критериев.

Статистический критерий - совокупность правил, позволяющих по полученной выборке принять H_0 или отвергнуть H_1 .

Имеется общий принцип построения статистического критерия:

1. Задают некоторую функцию $S = S(x_1, \dots, x_n)$ от элементов выборки, называемую статистикой критерия.
2. Множество Ω всех возможных значений S разбивают на два подмножества - T_0 (множество принятия решений H_0) и $T_{кр}$ (критическое множество).
3. Если конкретное значение статистики попадает в T_0 , то гипотезу H_0 принимают, если $S(x_1, \dots, x_n) \in T_{кр}$, то гипотезу отвергают в пользу H_1 .

В силу того, что $S(x_1, x_2, \dots, x_n)$ - случайная величина, то событие $S(x_1, \dots, x_n) \in T_{кр}$ может произойти как при справедливости H_0 , так и при справедливости H_1 . В связи с этим возможны ошибки двух типов:

- **ошибка I рода** - верна H_0 , принимается $H_1 | S(x_1, \dots, x_n) \in T_{кр}$;
- **ошибка II рода** - верна H_1 , принимается $H_0 | S(x_1, \dots, x_n) \in T_0$.

Вероятность ошибки первого рода обозначается: $\alpha = P(S(x_1, x_2, \dots, x_n) \in T_{кр} | H_0)$

Также называют **размером критического множества $T_{кр}$** или **размером критерия**.

Вероятность ошибки второго рода обозначается: $\beta = P(S(x_1, x_2, \dots, x_n) \in T_0 | H_1)$

Вероятность $\gamma = 1 - \beta = P(S(x_1, x_2, \dots, x_n) \in T_{кр} | H_1)$, то есть вероятность правильно отвергнуть H_0 , называют **мощностью критерия**.

При фиксированном объеме выборки нельзя одновременно уменьшать ошибки первого и второго рода. На практике поступают следующим образом: фиксируют размер критерия α и из всех критериев α выбирают критерий с наименьшим β . Если критерий таков, что критическими являются как малые, так и большие значения его статистики, то критерий называется двусторонним, в противном случае - односторонним.

Выбор одностороннего или двустороннего критерия определяется видом альтернативной гипотезы. Множество, отделяющее основную и альтернативную гипотезы называется зоной индифферентности T_u (здесь u - нижний индекс). Если известен заранее закон распределения СВ, тем точнее могут быть статистические выводы. Но насколько предположения о законе распределения соответствуют экспериментальным данным?

Критериями согласия называют критерии, в которых гипотеза определяет закон распределения полностью, либо с точностью до небольшого числа параметров.

Пусть имеется выборка размера n . Теоретическая функция распределения, которой подчиняются распределения $G(x)$, а гипотетическая - $F(x)$, при том, что эмпирическая (выборочная) $F(x)$ n . Тогда гипотеза о том, что истинное распределение есть $F(x)$ записывается $H: G(\cdot) = F(\cdot)$.

Если гипотеза H верна, то $F_n(x) \rightarrow F(x)$, $n \rightarrow \infty$.

Статистика Колмогорова

Можно сравнивать $F_n(x)$, $F(x)$ в равномерной метрике, то есть рассмотреть величину $D_n = \sup_{-\infty < x < \infty} |F_n(x) - F(x)|$

Эту статистику называют статист. Колмогорова. Если гипотеза H неверна, то $F_n \rightarrow G$, $G \neq F$, в противном случае $F_n \rightarrow F$.

Алгоритм использования статистики Колмогорова

При малых n для статистики D_n при гипотезе H составлены процентные таблицы точек (до $n=35$). При средних и больших значениях n : $D_n(\beta) = \sqrt{-0.5 \ln(\beta)}$

На практике можно использовать простую формулу

$$D_n = \sup_{1 \leq k \leq n} \left| \frac{k}{n} - F(x_k), F(x_k) - \frac{k-1}{n} \right|.$$

Критерий ω^2 .

Другой популярный критерий основан на статистике ω^2 .

$$\omega_n^2 = \int_{-\infty}^{\infty} [F_n(x) - F(x)]^2 dF(x).$$

Для вычисления по реальной выборке используют формулу

$$n\omega_n^2 = \frac{1}{12n} + \sum_{i=1}^n \left[F(x_i) - \frac{2i-1}{2n} \right]^2.$$

Статистический критерий для проверки гипотезы H называют состоятельным против альтернативы H' , если вероятность отвергнуть H с его помощью, когда на самом деле верна H' , стремится к 1 при неограниченном увеличении объема наблюдений. Состоятельность критериев Колмогорова и 2 означает, что любое отличие распределения выборки от теоретического будет с их помощью обнаружено, если наблюдения будут продолжаться достаточно долго. Более сложной задачей оказывается проверка сложной гипотезы (например подтверждается наличие некоторого распределения при неизвестных параметрах). Пусть, например, $\hat{\theta}$ - оценка наибольшего правдоподобия вектора неизвестных параметров. Тогда можно ввести некоторую модифицированную статистику Колмогорова

$$\hat{D}_n = \sup_x |F(x) - F(x, \hat{\theta})| \text{ или}$$

модифицированную статистику $\hat{\omega}_n^2 = \int_{-\infty}^{\infty} [F(x) - F(x, \hat{\theta})]^2 dF(x, \hat{\theta})$

16. Моделирование случайных величин и векторов с заданными законами распределения.

При реализации математической модели на компьютере возникает необходимость генерации случайных величин, распределенных по заданному закону. Стандартный программный инструментарий, как правило, реализует закон равномерного распределения и Гауссовский закон (нормальный). при этом уместнее говорить о генерации псевдослучайных чисел, так как используется линейный конгруэнтный алгоритм, относящийся к классу алгебраических ГСЧ. ГСЧ можно классифицировать:

1. Физический. Примеры: монета, прибор, на выходе которого фиксируются аналоговые значения, человек и т.д.

2. Табличный. Таблицы составлены таким образом, что содержат независимые случайные числа от 0 до 9. Таблицы обходят слева направо сверху вниз (но можно и в другом порядке) и получают равномерно распределенные от 0 до 1 СВ. *Достоинства:* достаточно высокая точность генерации, априорно показана независимость получаемых значений. *Недостатки:* объем таблиц, сложность составления таблиц.

3. Алгебраический. Генерирует псевдослучайные числа, такие что каждое следующее зависит от предыдущего. Это приводит к образованию циклов. Такие ГСЧ просты в реализации, компактны, быстродействующие, но имеют короткий период закливания. Числа квазислучайны, так как между ними имеется зависимость, а также наличие периодов в их последовательности. Примеры алгебраических ГСЧ:

- $r_0 = abcd$ - четырехзначное число, $r_1 = r_0 * r_0 = efghijkl$ - его квадрат.
 $r_0' = ghij$ - средние 4 цифры квадрата r_0 . и т.д.

Недостатки: r_0 может стать равным 0, быстро закливается

- r_0, r_1 - четырехзначные числа, $r_2 = r_0 * r_1 = abcdefgh$, $r_2' = cdef$, $r_3 = r_1 * r_2' = ijklmnop$ и т.д.
- $r_0 = abcdefgh$ - восьмизначное число, $r_1 = cdefghab$, $r_2 = ghabcdef$, $r_0' = r_1 + r_2$ и т.д.
- Линейный конгруэнтный метод (Лемер, 1949 г):

$$X_{n+1} = (aX_n + c) \bmod m, m \geq 2, 0 \leq a, c < m, 0 \leq X_0 < M.$$

Лемер показал, что для некоторых наборов коэффициентов период закливания может быть достаточно большим, например, при $m=6075$, $a=106$, $c=1283$ это 2^{20} .

К универсальным методам генерации СВ относят:

- 1) Метод обращений - **см. билет 18** (методы обращения и суперпозиции, их применение к моделированию скалярных случайных величин)
- 2) Метод Неймана - **см. билет 17** (моделирование случайных величин и векторов с нормальным законом распределения)
- 3) Метод кусочного приближения функций. Нелинейная функция распределения разбивается на несколько фрагментов. При этом в каждом диапазоне изменения x , функцию описывает простое для генерации распределение (равномерное и т.д.). По точности такой подход уступает методу Неймана, но позволяет рассматривать функцию распределения при $x \in (-\infty, \infty)$.
- 4) Методы, основанные на алгебраических связях между распределениями. Если такую связь удастся установить, метод считается достаточно точным, но не для всех пар распределений зависимость удастся найти, что является ограничением на применимость метода. Пример: формула Мюллера - **см. билет 17** (моделирование случайных величин и векторов с нормальным законом распределения)

17. Моделирование случайных величин и векторов с нормальным законом распределения.

$$y = \exp(-(x - \mu)^2 / (2\sigma^2)) / (\sigma\sqrt{2\pi})$$

μ - математическое ожидание

σ - среднее квадратичное отклонение

Метод, основанный на центральной предельной теореме

Идея: сложить случайные числа (с любым законом распределения), нормализовать их и перевести в нужный диапазон нормального распределения.

Известно, что сумма нескольких независимых равномерно распределенных на интервале (0,1) случайных величин при достаточно общих предположениях имеет асимптотически нормальное распределение.

Оптимальным считается суммирование 6 или 12 случайных величин, вычислительно проще - 6. Так

делают, потому что закон распр. чисел $V = \sum_{i=1}^n r_i$ имеет параметры $\mu = n/2$, $\sigma = \sqrt{n/12}$ (мат.

ожидание суммы СВ равно сумме их мат. ожиданий, дисперсия независимых СВ равна сумме их дисперсий; r_i распределены равномерно на (0,1), их мат. ожидание равно $1/2$, а дисперсия равна $1/12$; если что, $D = \sigma^2$).

Метод является наиболее распространенным, однако дает нормальное распределение с параметрами $\mu = 3.0$, $\sigma = 0.5$

При этом традиционно используют стандартное Гауссово распределение с параметрами $\mu = 0.0$, $\sigma = 1.0$. Переход от нормального распределения с параметрами $\mu = 3.0$, $\sigma = 0.5$ осуществляется за счет масштабирования. Нормализация: $z = (V - \mu)/\sigma$ (теперь параметры нормального распределения стандартные - (0, 1)). Если нужно получить распределение с нестандартными параметрами (a, b): $x = zb + a$.

Метод Мюллера

Метод Мюллера устанавливает алгебраическую связь между нормальным и равномерным распределением. Пусть r_1, r_2 - случайные числа с нормальным распределением из [0,1]. Тогда $z = \mu + \sigma\sqrt{-2 \ln r_1} \cdot \sin(2\pi r_2)$ - формула, по которой получаются числа z по закону нормального распределения с соответствующими параметрами.

Метод Неймана

Является универсальным методом, поэтому годится и для генерации СВ с нормальным законом распределения.

Задаются интервал (a,b) и функция плотности распределения $f(x)$. Из случайных величин, равномерно распределенных в (0,1) выбираются пары (r_1, r_2) , которые преобразуются по формулам $r_1^* = a + (b - a)r_1$, $r_2^* = f_{\max} r_2$, где $f_{\max} = \max_{x \in [a,b]} f(x)$. Затем выбираются все такие числа r_2^* , что $r_2^* \leq f(r_1^*)$.

Метод вычислительно прост, достаточно точен. Имеет ограничение, так как использует усеченную плотность распределения.

18. Методы обращения и суперпозиции, их применение к моделированию скалярных случайных величин.
Метод обращений (метод обратной функции)

Пусть $\omega(y)$ - плотность распределения СВ y , $\Omega(y) = \int_{-\infty}^y \omega(t)dt$ - функция распределения СВ y .

Тогда для генерации СВ y с заданным законом распределения достаточно вычислить $y = \Omega^{-1}(x)$, где x - равномерно распределенная СВ из $[0,1]$.

Пример:

$$\omega(y) = \lambda e^{-\lambda y}, y \geq 0, \Omega(y) = 1 - e^{-\lambda y}, y \geq 0;$$

$$x = 1 - e^{-\lambda y} \Rightarrow y = -\ln(1 - x)/\lambda$$

Метод удобен, вычислительно прост, обладает высокой точностью. При этом не все функции позволяют построить такую удобную функцию распределения, в силу чего метод универсален, но используется для ограниченного числа функций.

Метод суперпозиции

Применим, если функция распределения $F(x)$ СВ ξ представима в виде $F(x) = \sum_{k=1}^m c_k F_k(x)$,

где $F_k(x)$ - функции распределения, $c_k > 0$ и $\sum_{i=1}^m c_i = 1$ при $x \rightarrow \infty$ (или $c_k(x) \geq 0, \int_{-\infty}^{\infty} p_i(x)dx = 1$

для непрерывной СВ).

Генерируется СВ η с распределением $(1 \ 2 \ \dots \ k \ \dots \ /n \ \dots \ c_1 \ c_2 \ \dots \ c_k)$ так, что

$P\{\eta = k\} = c_k$ (или СВ η с плотностью $c_i(x)$ в случае непрерывной СВ)

Метод суперпозиции можно понимать как метод кусочного приближения функций - см. билет 16 (моделирование случайных величин и векторов с заданными законами распределения)

19. Общие методы моделирования случайных процессов.

Так как случайные процессы представляют собой аналоговую функцию (случайную функцию), то для моделирования СП на ЦВМ необходима дискретизация СП. Таким образом, дискретные значения, полученные с некоторым шагом во времени можно считать случайным вектором.

В отличие от случайных векторов небольшой размерности, случайные процессы приводят задачу к большей размерности, что делает невозможным (точнее, крайне затруднительным) применение метода Неймана.

На примере стационарного СП с экспоненциальным законом распределения используют следующий рекуррентный алгоритм

$$\xi(t_n) = \rho_n \xi(t_{n-1}) + \sqrt{1 - \rho_n^2} x[n];$$
$$\rho_n = e^{-\omega(t_n - t_{n-1})}, \quad \omega = \pi / (2\Delta t), \quad x[n]$$

- последовательности независимых случайных нормальных величин со стандартным распределением (0,1).

То есть для моделирования СП не существует универсального подхода. Для генерации СП с заданным законом распределения подбирают рекуррентную функцию

$$\xi(t_n) = \Phi(\xi_{n-1}, \rho),$$


где параметр ρ зависит от закона распределения. Если СП - Марковский, то смотреть **билет 20**.

20. Определение Марковского случайного процесса. Моделирование марковских случайных процессов.

В большинстве случаев модели СМО отображают процессы с конечным множеством состояний и с отсутствием последействия. Дискретной марковской цепью называют случайный марковский процесс, при котором смена дискретных состояний происходит в определенные моменты времени, в отличие от непрерывных марковских процессов, при которых смена дискретных состояний происходит в случайные моменты времени.

Случайный процесс называется марковским процессом (или процессом без последействия), если для каждого момента времени t состояние системы в настоящем и не зависит от того, как она пришла в это состояние, а последовательность случайных событий с конечным числом исходов – марковской цепью.

Марковский процесс удобно задавать графом переходов из состояния S_i в состояние S_j с вероятностью перехода P_{ij} .



Вероятности переходов.

	S_1	S_2	S_3
S_1	0	0,6	0,4
S_2	0,7	0	0,3
S_3	0	0	1

Рисунок - 7 Граф перехода и соответствующая ему таблица переходов.

Рассматривают два варианта описания марковских процессов – с дискретным и непрерывным временем.

В первом случае переход из одного состояния в другое происходит в заранее известные моменты времени – такты (1, 2, 3, 4, ...). Переход осуществляется на каждом такте, то есть исследователя интересует только последовательность состояний, которую проходит случайный процесс в своем развитии, и не интересует, когда конкретно происходил каждый из переходов.

Во втором случае последовательность состояний и моменты переходов оказываются значимы. Если вероятность перехода не зависит от времени, то марковскую цепь называют однородной.

Округление ресурсного значения всегда происходит в большую сторону (n : патронов, снарядов должно быть в среднем 4 для полного поражения цели). Если вероятность перехода в новое состояние также не зависит от номера шага, говорят об однородной марковской цепи в дискретном времени.

21. Классификация инструментальных средств моделирования. История создания и особенности инструментальных средств моделирования.

Первые инструментальные средства моделирования появились в 50-ые годы XX века и могут быть разделены на 3 группы:

1. Специализированные языки программирования
2. Пакеты символьных вычислений
3. Системы моделирования сложных систем (СС)

FORTRAN - язык для математических инженерных расчетов. Имел богатую библиотеку точных и приближенных методов, являлся языком международного общения математиков. В 1995 г библиотека FORTRAN была выкуплена у правообладателя канадским университетом Торонто как организацией. На базе библиотеки был создан пакет символьных вычислений MAPLE. FORTRAN как язык научных расчетов уступил C.

После 1995 г наступила эра пакетов символьных вычислений: MAPLE, MATHCAD, MATLAB, Wolfram и т.д. С 1992 г технологии символьных вычислений хорошо отработаны. В настоящее время доминирующим является средство MathWorks, собравшее преимущества каждого пакета моделирования и добавившее ожидаемые.

Самой первой системой моделирования считается GPSS. За счет компактности и простоты GPSS без значительных изменений существует до сих пор. GPSS моделирует СМО, это ограничивает круг задач, решаемых с помощью GPSS.

SIMULINK (60-ые гг) - система имитационного моделирования. Выходит за рамки СМО, решает задачи идентификации, оптимизации, планирования эксперимента и т.д.

Среди пакетов символьных вычислений MATLAB выделяется мощной библиотекой графической визуализации.

SIMULINK выделяется своей универсальностью среди систем моделирования.

Объединение достоинств и устранения недостатков этих средств компанией MathWorks давало хороший, но не отличный результат. По аналогии с ООП разработчики MathWorks предложили технологию ООМ. Решения MathWorks представляют собой технологию проектирования, позволяющую представить модель в виде многокомпонентной системы с типовыми связями. Это позволяет создавать модели для обработки звука, изображений, имитации управленческих приложений и т.д.

Для захвата рынка разработчики MathWorks реализовали несколько функций, которые заявлялись разработчиками других систем, но так и не были реализованы:

1. Взаимодействие с другими языками программирования (например C)
2. Работа в реальном времени: модуль параллельного программирования с языком распараллеливания реализует технология CUDA
3. Возможность получать выходные данные непосредственно с датчиков

22. Имитационные модели систем массового обслуживания. Среда имитационного моделирования GPSS.

СМО (системы массового обслуживания) - системы, функционирование которых заключается в обработке большого числа заявок. Система с накопителем — СМО с ожиданием, система с потерями — СМО с отказами.

Заявка — транзакт, очередь — канал обслуживания заявки, устройство — то/кто обслуживает заявки, приоритетное обслуживание.

Пропускная способность СМО: характеризуется средним временем нахождения в системе и интенсивностью выходного потока заявок. Задержка — время проведенное заявкой в ожидании обслуживания. Интенсивность входного потока (λ) — среднее число заявок поступающее в СМО в единицу времени (в генераторе — распределения Пуассона). Если источник входного потока расположен вне системы то СМО — открытая, а если заявка снова возвращается в поток — закрытая.

Анализ зависимости между характером потока заявок, числом каналов из производительности и эффективностью обслуживания — есть предмет исследований СМО. На базе дискретно-событийной имитации была создана парадигма моделирования, названная системной динамикой. Для решения вполне детерминированных задач стали использоваться описания СМО. Обобщил подход к теории Колмогоров. К основным принципам системной динамики:

- динамику поведения сколь угодно сложного процесса можно свести к изменению значения некоторых уровней (режимов поведения системы), а сами изменения регулировать потоками заявок и скоростью этих потоков.

Все изменения в любой динамической системе обусловлены наличием обратной связи. Положительно обратная связь — сильный отклик - сильное воздействие. **Петля обратной связи** — замкнутая цепь последовательных воздействий элементов системы, т. е. системная динамика не исключает одновременного действия и положительной и отрицательной обратной связи, а также возникновения задержек в системе.

Выделяют два вида связи: прямая (обеспечивает передачу с выхода на вход другого), обратная (с выхода последующего на вход первого). Различают положительную (обратную и прямую) — увеличение значение на выходе одного блока приводит к увеличению на входе другого блока, отрицательную — увеличение значение на выходе одного блока приводит к уменьшению на входе другого блока.

Для описания имитационной модели на языке GPSS полезно представить ее в виде схемы, на которой отображаются элементы СМО - устройства, накопители, узлы и источники . Описание на языке GPSS есть совокупность операторов (блоков), характеризующих процессы обработки заявок.

Имеются операторы и для отображения возникновения заявок, задержки их в ОА, занятия памяти, выхода из СМО, изменения параметров заявок (например, приоритетов), вывода на печать накопленной информации, характеризующей загрузку устройств, заполненность очередей и т.п.

Каждый транзакт, присутствующий в модели, может иметь до 12 параметров. Существуют операторы, с помощью которых можно изменять значения любых параметров транзактов, и операторы, характер исполнения которых зависит от значений того или иного параметра обслуживаемого транзакта.

Пути продвижения заявок между ОА отображаются последовательностью операторов в описании модели на языке GPSS специальными операторами передачи управления (перехода). Для моделирования используется событийный метод. Соблюдение правильной временной последовательности имитации событий в СМО обеспечивается интерпретатором GPSSPC - программной системой, реализующий алгоритмы имитационного моделирования. обслуживающий аппарат — (ОА)

23. Введение в анализ данных. Основные понятия, методы.

Каждый объект выборки может содержать наблюдения более чем над одной случайной переменной, в этом случае говорят о множественной регрессии. В этом случае изучаются взаимоотношения между независимой переменной с одной стороны и совокупностью зависимых переменных с другой стороны. В ряде случаев все переменные анализируются одновременно как один случайный вектор, имеющий многомерное распределение, т.е. **многомерный анализ** — это анализ множественных результатов свойств случайной выборки, в рамках которой рассматриваются различные методологии решения широкого класса задач.

При исследовании сложных объектов и систем часто невозможно непосредственно измерить величины, определяющие свойства этих объектов (факторы), а иногда неизвестны содержание и смысл факторов. Для измерений доступны только величины в той или иной степени, зависящие от факторов.

При этом, когда влияние неизвестного фактора проявляется в нескольких измеряемых признаках, эти признаки могут обнаруживать тесную связь между собой (коррелированность), поэтому общее число факторов может быть гораздо меньшим, чем число измеряемых переменных, которое обычно выбирается исследователем произвольно.

Для обнаружения влияющих на измеряемые переменные факторов используются **методы факторного анализа (Factor Analysis)** - выделение из множества измеряемых характеристик объекта новых факторов, более адекватно отражающих свойства объекта- отличается от понятия One-way, To-way ANOVA - одно, двухфакторного анализа, где факторы заранее известны).

Выбор новых признаков, которые являются линейными комбинациями прежних и “вбирают” в себя большую часть общей изменчивости наблюдаемых данных, а поэтому передают большую часть информации, заключенной в первоначальных наблюдениях.

Обычно для этого используют **метод главных компонент**. Этот метод сводится к выбору новой ортогональной системы координат в пространстве наблюдений.

В качестве первой главной компоненты избирают направление, вдоль которого массив наблюдений имеет наибольший разброс, последующая главная компонента выбирается таким образом, чтобы разброс наблюдений вдоль нее был максимальным и она была бы ортогональна другим компонентам, выбранным до нее.

Причинно-следственный анализ компонентов и факторный анализ помогают уменьшить (до двух или трех) число учитываемых переменных, которые в наибольшей степени влияют на изменчивость выборочных значений (выявление свойств личности, которые повлияли на поведение человека в данной ситуации).

Пусть имеется совокупность объектов, разбитую на несколько групп (для каждого объекта можно сказать, к какой группе он относится). Пусть для каждого объекта имеется несколько количественных характеристик. Требуется найти группу, к которой принадлежит объект. Это позволит для новых объектов из этой же совокупности предсказывать группы, к которой они относятся.

Для решения этой задачи применяются методы **дискриминантного анализа**, которые позволяют строить функции измеряемых характеристик, значения которых и объясняют разбиение отрезков на группы. Желательно, чтобы этих функций (дискриминирующих признаков) было немного - в этом случае результаты легче истолковать. Особую роль играет линейный дискриминантный анализ, в котором классифицирующие признаки выбираются как линейные функции от первичных признаков. (Здоров пациент, либо болен)

Методы кластерного анализа позволяют разбить изучаемую совокупность объектов на группы схожих объектов, называемых кластерами.

Большинство методов кластеризации (группировки по иерархии) являются аггломеративными (объединительными) - они начинаются с создания элементарных кластеров, каждый из которых состоит из одного исходного наблюдения, а на каждом последующем шаге производится объединения нескольких кластеров в один.

Дерево объединения кластеров называется дендрограммой. Другие методы кластерного анализа называют дивизивными - позволяют разбивать объекты на кластеры непосредственно.

Методы кластерного анализа являются лишь вспомогательными для содержательного анализа, не дают какого либо способа для проверки статистической гипотезы об адекватности полученных классификаций.

Во многих областях исследования бывает затруднительно проводить непосредственное измерение интересующих исследователя характеристик объекта, но можно оценить другим путем степень сходства или различия между парами объектов. Тогда используются **методы многомерного шкалирования**. Пространство небольшой размерности, каждому оцениваемому объекту соответствует точка.

Часто в качестве исходных данных для шкалирования используются не сами оценки степени сходства объектов, а результаты их ранжирования (неметрические методы). (Оценки политических лидеров).

24. Анализ функциональных зависимостей между наблюдаемыми одновременно характеристиками объекта.

Простая линейная регрессия и простой корреляционный анализ.

Простой корреляционный анализ

Между переменными (СВ) может существовать функциональная связь (например, $y=f(x)$, где x, y - СВ). Но между переменными может существовать и связь другого рода, проявляющаяся в том, что одна из них реагирует на изменение другой изменением своего закона распределения. Такую связь называют стохастической. Она появляется в том случае, когда имеются общие случайные факторы, влияющие на обе переменные. В качестве меры зависимости между переменными используется коэффициент корреляции (r), который изменяется в пределах от -1 до $+1$. Чем ближе значение r к 1 , тем зависимость сильнее. Коэффициент корреляции достигает своих предельных значений $+1$ или -1 , тогда и только тогда, когда зависимость между переменными линейная. Корреляционный анализ позволяет установить силу и направление стохастической взаимосвязи между переменными (СВ)

Пары точек с координатами (x, y) наносятся на координатную сетку. Необходимо получить предварительное представление о рассеивании точек. На графике возможны случаи:

1. нет ошибок в измерениях;
2. ошибки измерения незначительные;
3. есть ошибки измерения и изменение результата, в связи с чем отсутствует явно выраженный тренд.

В ряде случаев возможно появление облака точек, где одному значению x соответствует несколько значений y и наоборот. В первом случае имеется функциональная зависимость, в остальных — стохастическая. Под функциональной зависимостью понимают соответствие некоторой величины $y \in Y$ единственной величине $x \in X$. Стохастическая зависимость предполагает что одному значению y, Y может соответствовать несколько значений x_i , и наоборот. Во втором случае значения y рассматриваются как следствия x . То есть можно предположить, что есть некоторая функция, которая причинна для y по значению x . Таким образом необходимо оценить погрешность представления данных с целью выявления тренда (причинной функции).

Традиционно для оценивания корреляции двух случайных выборок используют коэффициент корреляции (Пирсона), который демонстрирует степень тесноты линейной зависимости. Судить о тесноте связи в случае нелинейного тренда оказывается ошибочным. Существуют различные характеристики связи и взаимосвязи выборок. Наиболее часто используется коэффициент корреляции, ковариации, функция регрессии, коэффициент Спирмена.

$$r_{XY} = \frac{\text{cov}_{XY}}{\sigma_X \sigma_Y} = \frac{\sum (X - \bar{X})(Y - \bar{Y})}{\sqrt{\sum (X - \bar{X})^2 \sum (Y - \bar{Y})^2}}.$$

Коэффициент корреляции (Пирсона) определяется как отношение

Таким образом, задача разбивается на две подзадачи:

1. установить вид тренда (линейный, нелинейный);
2. подтвердить тесноту связи.

Ковариация и коэффициент корреляции Пирсона устанавливают линейность функции связи (в противном случае считается что связь нелинейная).

Коэффициенты принимают значения близкие к максимальному только в случае тесной взаимосвязи. Установить тесную связь в случае нелинейной зависимости не представляется возможным. Если степень тесноты связи высокая, то можно говорить о построении **регрессии**.

Регрессия — условное математическое ожидание случайной переменной y при условии, что другая переменная приняла значение x . Если коэффициент корреляции Пирсона близок к единице, говорят о линейной регрессии.

Моделью линейной регрессии является формализация, в которой мат. ожидание наблюдаемой величины y является линейной комбинацией независимых переменных. В случае $k > 1$ независимых переменных, говорят о множественной регрессии, при $k = 1$ о линейной регрессии.

$$y = a_0 + a_1 x_1 + a_2 x_2 + \dots + a_k x_k.$$

Коэффициент a_0 называется свободным или постоянным членом, a_i — коэффициентами линейной регрессии.

Построение линейной регрессии лежит в основе корреляционного анализа. **Корреляционный анализ** изучает стохастическую зависимость между случайными величинами на основе совокупности коэффициентов и функций связи и взаимосвязи величин. При установлении нелинейной зависимости необходимо использовать альтернативные подходы, в том числе уже изученный подход на основе методов момента и максимального правдоподобия, а также на основе коэффициентов Спирмена и Кэнделла. Такие коэффициенты являются ранговыми.

Пусть x набор n неизвестных переменных (параметров), $f_i(x)$, $i = 1, \dots, m$, $m > n$ - совокупность функций от этого набора переменных. Задача заключается в подборе таких значений x , чтобы значения этих функций были максимально близки к некоторым значениям y_i . По существу речь идет о «решении» переопределенной системы уравнений $f_i(x) = y_i$, $i = 1, \dots, m$ в указанном смысле максимальной близости левой и правой частей системы. Сущность МНК заключается в выборе в качестве «меры близости» суммы квадратов отклонений левых и правых частей $|f_i(x) - y_i|$. Таким образом, сущность МНК может быть выражена следующим образом:

$$\sum_i (y_i - f_i(x))^2 \rightarrow \min_x$$

В случае, если система уравнений имеет решение, то минимум суммы квадратов будет равен нулю и могут быть найдены точные решения системы уравнений аналитически или, например, различными численными методами оптимизации. Если количество независимых уравнений больше количества искомых переменных, то система не имеет точного решения и метод наименьших квадратов позволяет найти некоторый «оптимальный» вектор x в смысле максимальной близости векторов y и $f(x)$ (близость понимается в смысле евклидова расстояния).

Пример

Заданы выборки $X = \{x_1, \dots, x_n\}$, $Y = \{y_1, \dots, y_n\}$ и регрессионная модель $f(x) = \sum_{i=1}^3 w_i x^{i-1}$. Нужно найти такой вектор w , чтобы сумма квадратов отклонений была минимальна.

$$A = \begin{pmatrix} 1 & x_1 & x_1^2 & \dots & 1 & x_n & x_n^2 \end{pmatrix}$$

$$S = \|y_i - f(w, x_i)\|^2 = \|Y - Aw\|^2$$

Искомый w выражается как $w = \arg \min_w S$

$$\begin{aligned} \|Y - Aw\|^2 &= (Y - Aw)^T (Y - Aw) = \\ &= Y^T Y - Y^T A w - w^T A^T Y + w^T A^T A w = Y^T Y - 2Y^T A w + w^T A^T A w \end{aligned}$$

Производную по w приравняем к 0, чтобы найти минимум:

$$-2Y^T A + 2A^T A w = 0 \Rightarrow w = (A^T A)^{-1} (A^T Y)$$

26. Подходы к оцениванию параметров зависимости между ненаблюдаемыми одновременно характеристиками объекта. Метод моментов. Пример.

Величины могут оказываться ненаблюдаемыми одновременно, что делает невозможным применение метода наименьших квадратов.

Наиболее часто для построения точечных оценок используют метод моментов и метод максимального правдоподобия.

Метод моментов.

Пусть $x_1, x_2, \dots, x_n$ – независимая случайная повторная выборка из генеральной совокупности с плотностью распределения $f(x, \theta)$, зависящей от неизвестного параметра θ . В качестве оценки неизвестного параметра берется то его значение, при котором точное или “теоретическое” значение первого момента совпадает с его эмпирическим значением, найденным по результатам выборки. Найдем первый момент (математическое ожидание):

- теоретическое значение первого момента: $\mu_1 = \mu_1(\theta) = \int_{-\infty}^{\infty} xf(x)dx$.

- эмпирическое среднее: $\hat{\mu} = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$,

в качестве оценки $\hat{\theta}$ принимается решение следующего уравнения

$$\mu_1(\theta) = \bar{x}.$$

В случае нескольких неизвестных параметров они находятся из решения уравнений

$$\begin{cases} \mu_1(\theta_1, \theta_2, \dots, \theta_l) = \hat{\mu}_1 \\ \dots \\ \mu_l(\theta_1, \theta_2, \dots, \theta_l) = \hat{\mu}_l \end{cases},$$

где
$$\mu_l(\theta_1, \theta_2, \dots, \theta_l) = \int_{-\infty}^{\infty} x^l f(x, \theta_1, \theta_2, \dots, \theta_l) dx -$$

- “теоретическое” значение момента порядка l , а его эмпирическое значение найденное по выборке:

$$\hat{\mu}_l = \frac{1}{n} \sum_{i=1}^n x_i^l$$

Очевидно, при $l=2$ указанная система уравнений может быть записана в следующем эквивалентном виде:

$$\begin{cases} \mu_1(\theta_1, \theta_2) = \bar{x}, \\ D(\theta_1, \theta_2) = S^2, \end{cases}$$

$D(\theta_1, \theta_2)$, - точное или теоретическое значение дисперсии, а S^2 - эмпирическая дисперсия. Метод моментов дает состоятельные оценки, но недостаточно эффективные.

27. Подходы к оцениванию параметров зависимости между ненаблюдаемыми одновременно характеристиками объекта Метод максимального правдоподобия. Пример.

Величины могут оказываться ненаблюдаемыми одновременно, что делает невозможным применение метода наименьших квадратов.

Пусть $x_1, x_2, \dots, x_n$ – независимая случайная повторная выборка из генеральной совокупности с плотностью распределения $f(x, \theta)$, зависящей от неизвестного параметра θ . Совместная плотность распределения всех результатов выборки $f(x_1, \theta), \dots, (x_n, \theta) = L(x_1, x_2, \dots, x_n, \theta)$ называется функцией правдоподобия.

В качестве оценки $\hat{\theta} = \hat{\theta}(x_1, \dots, x_n)$ берется значение, при котором функция правдоподобия, рассматриваемая как функция от этого параметра при фиксированных результатах наблюдений $x_1, \dots, x_n$ обращается в максимум, то есть оценка максимального правдоподобия находится из соотношения

$$L(x_1, x_2, \dots, x_n, \hat{\theta}) = \max_{\theta} L(x_1, x_2, \dots, x_n, \theta)$$

В ряде случаев удобно искать максимум не из самой функции, а из ее логарифма. Предполагается, что функция дифференцируема по θ и оценка максимального правдоподобия находится по формуле

$$\frac{\partial}{\partial \theta} \ln L(x_1, x_2, \dots, x_n, \theta) = 0$$

уравнение правдоподобия (необходимое, но недостаточное условие максимума). Для многих распределений имеет единственное решение, которое и дает искомую оценку максимального правдоподобия. В случае нескольких неизвестных параметров необходимо решить систему уравнений относительно $\theta_1, \dots, \theta_l$ при фиксированных $x_1, \dots, x_n$:

$$\begin{cases} \frac{\partial}{\partial \theta_1} \ln L(x_1, x_2, \dots, x_n, \theta_1, \theta_2, \dots, \theta_l) = 0, \\ \dots \\ \frac{\partial}{\partial \theta_l} \ln L(x_1, x_2, \dots, x_n, \theta_1, \theta_2, \dots, \theta_l) = 0. \end{cases}$$

Когда существует эффективная оценка, метод максимального правдоподобия дает эту оценку. В общем случае при довольно общих условиях метод максимального правдоподобия дает асимптотически несмещенные и асимптотически эффективные оценки при $n \rightarrow \infty$.

Пусть $x_1, \dots, x_n$ – независимая случайная повторная выборка из генеральной совокупности с функцией распределения $F(x, \theta)$ и плотностью распределения $f(x, \theta)$, зависящей от неизвестного параметра θ . Предположим, что для параметра θ на основе выборки построен интервал $[\theta_-, \theta^-]$, нижняя и верхняя граница которого являются

некоторыми функциями от выборки $\theta_- = \theta_-(x_1, \dots, x_n)$ и $\theta^- = \theta^-(x_1, \dots, x_n)$. Интервал $[\theta_-, \theta^-]$ называется доверительным интервалом для параметра с коэффициентом доверия γ , если при всех возможных значениях θ

$$P(\theta_- \leq \theta \leq \theta^-) = \gamma$$

Доверительный интервал дает информацию не только о том, где находится истинное значение параметра, но и точности оценивания.

28. Дисперсионный анализ. Пример.

Дисперсионный анализ — метод в математической статистике, направленный на поиск зависимостей в экспериментальных данных путём исследования значимости различий в средних значениях

Метод наименьших квадратов вместе с систематизированным набором правил для проверки статистических гипотез называется дисперсионным анализом (analysis of variance=ANOVA). Метод, предложенный Фишером. Согласно этому методу полное изменение числового вектора $y_1, \dots, y_n$, выраженное через сумму квадратов отклонений от среднего значения $\bar{y}$.

$$\sum_{i=1}^n (y_i - \bar{y})^2,$$

разбивается на составляющие суммы квадратов, связанные с результатом действия различных классификационных факторов, которые определяются индексами данных.

Тогда, если данные в форме матрицы $m \times n$ есть результат классификации по двум признакам А и В с индексами элементов $i=1, \dots, m; j=1, \dots, n$, то результатом дисперсионного анализа будет тождество

$$\begin{aligned} \sum_{ij} (y_{ij} - y_{..})^2 \{ \text{Общая сумма} \} = \\ \sum_{ij} (y_{i.} - y_{..})^2 \{ \text{Основной эффект А} \} + \\ \sum_{ij} (y_{.j} - y_{..})^2 \{ \text{Основной эффект В} \} + \\ \sum_{ij} (y_{i.} - y_{i.} + y_{..})^2 \{ \text{Эффект взаимодействия А и В} \}, \end{aligned}$$

где точки - результаты осреднения y_{ij} по соответствующим индексам.

Путем анализа данных с помощью приведенной модели можно выделить наиболее сильный фактор. Если максимальной получилась величина от эффекта взаимодействия А и В, проверяется гипотеза с другим набором факторов.

Метод оказывается информативным в плане выделения значимых факторов, при этом требует проведения (часто масштабного) натурного эксперимента.

В некоторых случаях данные поступают последовательно. В этом случае применяются последовательные процедуры проверки гипотез.

Пусть $(x_1, x_2, \dots, x_m)$ и $(y_1, y_2, \dots, y_n)$ - выборки из нормальных распределений с неизвестными параметрами $(\mu_1, \sigma), (\mu_2, \sigma)$. Нулевую гипотезу о равенстве мат. ожиданий проверяет следующим образом.

$$\text{Вычисляются средние выборок } \bar{x} = \frac{1}{m} \sum_{i=1}^m x_i, \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i,$$

выборочные суммы квадратов

$$\begin{aligned} (m-1)s_1^2 &= \sum_{i=1}^m (x_i^2 - m\bar{x}^2), \\ (n-1)s_2^2 &= \sum_{i=1}^n (y_i^2 - n\bar{y}^2) \end{aligned}$$

и результирующую оценку общей дисперсии

$$s^2 = \left[(m-1)s_1^2 + (n-1)s_2^2 \right] / (m+n-2)$$

То есть оценкой выборочной дисперсии $\bar{x} - \bar{y}$ служит

$$\hat{s} \left(\frac{1}{m} + \frac{1}{n} \right) = \frac{m+n}{mn} s^2.$$

Статистика t подчиняется распределению Стьюдента с $m+n-2$ степенями свободы

$$\hat{t} = \frac{\bar{x} - \bar{y}}{s} \sqrt{\frac{mn}{m+n}}.$$

Пример

$$\begin{aligned} m &= 20, \bar{x} = 29,233, s_1^2 = 5,62; \\ n &= 10, \bar{y} = 27,562, s_2^2 = 2,19, \end{aligned} \quad \text{откуда}$$

$$28s^2 = (19 \cdot 5,62) + (9 \cdot 2,19) \Rightarrow s^2 = 4,5175, \text{ тогда}$$

$$s^2 \left(\frac{1}{20} + \frac{1}{10} \right) = 0,678 = (0,823)^2 \text{ и } t = \frac{1,671}{0,823} = 2,030.$$

Второй вариант

Пусть имеются выборки двух показателей: $(x_1, x_2, \dots, x_n)$ и $(y_1, y_2, \dots, y_n)$ с неизвестными параметрами $N(\mu_1, \sigma_1)$ и $N(\mu_2, \sigma_2)$ нормальных распределений. Необходимо подтвердить или опровергнуть гипотезу о равенстве матожиданий исследуемых выборок. В этом случае можно обобщить результаты дисперсионного анализа на вновь полученную выборку. Вычисляются выборочные средние

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i,$$

$$\bar{y} = \frac{1}{n} \sum_{i=1}^m y_i$$

и выборочные квадраты

$$S_x^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2,$$

$$S_y^2 = \frac{1}{m} \sum_{i=1}^m (y_i - \bar{y})^2.$$

Далее получают результирующую оценку общей дисперсии

$$\begin{aligned} S^2 &= S_x^2 + S_y^2 = \\ &= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 + \frac{1}{m} \sum_{i=1}^m (y_i - \bar{y})^2 \\ mn \cdot S^2 &= m \sum_{i=1}^n (x_i - \bar{x})^2 + n \sum_{i=1}^m (y_i - \bar{y})^2. \end{aligned}$$

Необходимо оценить выборочную дисперсию S_{x-y}^2 (используется распределение и статистика Стьюдента). Также нужно ввести статистику

$$t = \frac{\bar{x} - \bar{y}}{S} \sqrt{\frac{mn}{m+n}}.$$

Статистика подчиняется распределению Стьюдента с $m + n - 2$ степенями свободы.

Из статистических таблиц, в соответствии со значением степени свободы и выбранного уровня значимости полученного решения, получается оценка границ интервала $[t_-, t^+]$. Также оценивается величина $\hat{t}$ и принадлежность этой величины к найденному отрезку. Если принадлежит, то говорят о совпадении матожидания при совпадении СКО σ , что позволит перенести выводы, полученные по выборке X на выборку Y .

29. Анализ главных компонент. Пример.

Факторный анализ. Часто используется выбор новых признаков, являющихся линейными комбинациями прежних и «вбирающих в себя» большую часть изменчивости наблюдаемых данных, и поэтому передающих большую часть информации, заключенную в первоначальных наблюдениях. Обычно для этого используют **метод главных компонент**.

Этот метод сводится к выбору новой ортогональной системы координат в пространстве наблюдений. В качестве первой главной компоненты выбирают направление, вдоль которого массив наблюдений имеет наибольший разброс.

Последующая главная компонента выбирается таким образом, чтобы разброс наблюдений вдоль нее оказался максимальным и она была ортогональна другим компонентам, выбранным вдоль нее. Недостатком подхода является переход от интерпретируемых факторов к факторам, которые сложно или невозможно интерпретировать. Суммарный вклад отброшенных факторов в решении задачи может превосходить два главных компонента (второй недостаток).

На практике часто возникает задача анализа данных большой размерности. **Метод анализа главных компонент и классификация** позволяет решить эту задачу и служит для достижения двух целей:

- уменьшение общего числа переменных (редукция данных) для того, чтобы получить «главные» и «некоррелирующие» переменные;
- классификация переменных и наблюдений, при помощи строящегося факторного пространства.


Метод имеет сходство с факторным анализом в постановочной части решаемых задач, но имеет ряд существенных отличий:

- при анализе главных компонент не используются итеративные методы для извлечения факторов;
- наряду с активными переменными и наблюдениями, используемыми для извлечения главных компонент, можно задать вспомогательные переменные и/или наблюдения; затем вспомогательные переменные и наблюдения проектируются на факторное пространство, вычисленное на основе активных переменных и наблюдений;
- перечисленные возможности позволяют использовать метод как мощное средство для классификации одновременно переменных и наблюдений.

Решение основной задачи метода достигается созданием векторного пространства латентных (скрытых) переменных (факторов) с размерностью меньше исходной. Исходная размерность определяется числом переменных для анализа в исходных данных. **Постановка задачи** - Найти подпространства меньшей размерности, в ортогональной проекции на которые разброс данных (дисперсия) максимальна.

Алгоритм Пусть дан центрированный набор (из исходного набора вычли мат. ожидание) векторов x_i . Будем искать такое ортогональное преобразование A в новую СК, для которого были бы верны условия: **1.** Выборочная дисперсия данных вдоль 1-ой координаты максимальна **2.** Выборочная дисперсия данных вдоль 2-ой координаты максимальна при условии ортогональности 1-ой координате **3.** и т.д.

Графическая интерпретация В некоторой СК, осями которой являются факторы, построен эллипсоид рассеяния. СК вращают и выявляют компоненту, вдоль которой разброс максимален. Эту компоненту исключают и повторяют операцию. Почему компоненты, а не факторы: преобразования приводят исходные данные к некоторому другому виду, в котором они уже факторами не являются X- исходное про-во, PC - главная компонента.



30. Кластерный анализ. Пример.

Формально определим задачу кластеризации. Пусть X – множество объектов, Y – множество номеров (имён, меток) кластеров. Задана функция расстояния между объектами $\rho(x, x')$. Имеется конечная обучающая выборка объектов $X^m = \{x_1, \dots, x_m\} \subset X$. Требуется разбить выборку на непересекающиеся подмножества, называемые кластерами, так, чтобы каждый кластер состоял из объектов, близких по метрике ρ , а объекты разных кластеров существенно отличались. При этом каждому объекту $x_i \in X^m$ приписывается номер кластера y_i .

Алгоритм кластеризации – это функция $a: X \rightarrow Y$, которая любому объекту $x \in X$ ставит в соответствие номер кластера $y \in Y$. Множество Y в некоторых случаях известно заранее, однако чаще ставится задача определить оптимальное число кластеров, с точки зрения того или иного критерия качества кластеризации.

Кластеризация (обучение без учителя) отличается от классификации (обучения с учителем) тем, что метки исходных объектов y_i изначально не заданы, и даже может быть неизвестно само множество Y .

Решение задачи кластеризации принципиально неоднозначно, и тому есть несколько причин:

1. не существует однозначно наилучшего критерия качества кластеризации. Известен целый ряд эвристических критериев, а также ряд алгоритмов, не имеющих чётко выраженного критерия, но осуществляющих достаточно разумную кластеризацию «по построению». Все они могут давать разные результаты.
2. число кластеров, как правило, неизвестно заранее и устанавливается в соответствии с некоторым субъективным критерием.
3. различия в стандартизации переменных **стандартизация (standardization) или нормирование (normalization)** приводит значения всех преобразованных переменных к единому диапазону значений путем выражения через отношение этих значений к некоей величине, отражающей определенные свойства конкретного признака. Стандартизация производится с помощью экспертной оценки-начисления весов или с помощью статистических вычислений отклонений соответствующих переменных.
4. результат кластеризации существенно зависит от метрики, выбор которой, как правило, также субъективен и определяется экспертом.

Кластер имеет следующие математические характеристики: **центр, радиус, среднеквадратическое отклонение, размер кластера.**

Центр кластера - это среднее геометрическое место точек в пространстве переменных.

Радиус кластера - максимальное расстояние точек от центра кластера.

Кластеры могут быть перекрывающимися. Такая ситуация возникает, когда обнаруживается перекрытие кластеров. В этом случае невозможно при помощи математических процедур однозначно отнести объект к одному из двух кластеров. Такие объекты называют спорными.

Спорный объект - это объект, который по мере сходства может быть отнесен к нескольким кластерам.

Размер кластера может быть определен либо по радиусу кластера, либо по среднеквадратичному отклонению объектов для этого кластера. Объект относится к кластеру, если расстояние от объекта до центра кластера меньше радиуса кластера. Если это условие выполняется для двух и более кластеров, объект является спорным.

Критерием для определения схожести и различия кластеров является расстояние между точками, в частности для трех признаков евклидова мера расстояния будет иметь вид $D = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2 + (z_1 - z_2)^2}$.

Иерархические методы кластерного анализа Суть иерархической кластеризации состоит в последовательном объединении меньших кластеров в большие или разделении больших кластеров на меньшие.

Иерархические агломеративные методы Эта группа методов характеризуется последовательным объединением исходных элементов и соответствующим уменьшением числа кластеров. В начале работы алгоритма все объекты являются отдельными кластерами. На первом шаге наиболее похожие объекты объединяются в кластер. На последующих шагах объединение продолжается до тех пор, пока все объекты не будут составлять один кластер.

Иерархические дивизимные (делимые) методы Эти методы являются логической противоположностью агломеративным методам. В начале работы алгоритма все объекты принадлежат одному кластеру, который на последующих шагах делится на меньшие кластеры, в результате образуется последовательность расщепляющих групп.

Иерархические методы кластерного анализа используются при небольших объемах наборов данных. Иерархические алгоритмы связаны с построением **дендрограмм**, которые являются результатом иерархического кластерного анализа. Дендрограмма описывает близость отдельных точек и кластеров друг к другу, представляет в графическом виде последовательность объединения (разделения) кластеров.

При большом количестве наблюдений иерархические методы кластерного анализа не пригодны. В таких случаях используют неиерархические методы, основанные на разделении, которые представляют собой итеративные методы дробления исходной совокупности. В процессе деления новые кластеры формируются до тех пор, пока не

будет выполнено правило остановки. Такая неиерархическая кластеризация состоит в разделении набора данных на определенное количество отдельных кластеров.

Понятие «**расстояние между объектами**» должно отражать меру сходства, близости объектов между собой по всей совокупности используемых признаков. Иными словами служить интегральной мерой сходства объектов между собой. **Расстоянием между объектами в пространстве признаков** называется такая величина d_{ij} , которая удовлетворяет следующим достаточно разумным аксиомам:

1. $d_{ij} > 0$ (неотрицательность расстояния)
2. $d_{ij} = d_{ji}$ (симметрия)
3. $d_{ij} + d_{jk} > d_{ik}$ (неравенство треугольника)
4. Если d_{ij} не равно 0, то i не равно j (различимость нетождественных объектов)
5. Если $d_{ij} = 0$, то $i = j$ (неразличимость тождественных объектов)

Кроме термина "расстояние" часто встречается и другой термин - "**метрика**", который подразумевает метод вычисления того или иного конкретного расстояния. Наиболее распространенной и универсальной является **метрика**

Минковского, величина расстояния которой имеет вид:
$$d_{ij} = \sqrt[\lambda]{\sum_{k=1}^n |x_{ik} - x_{jk}|^\lambda}.$$

Оценка качества кластеризации может быть проведена на основе следующих процедур:

1. ручная проверка;
2. установление контрольных точек и проверка на полученных кластерах;
3. определение стабильности кластеризации путем добавления в модель новых переменных;
4. создание и сравнение кластеров с использованием различных методов.

Разные методы кластеризации могут создавать разные кластеры, и это является нормальным явлением. Однако создание схожих кластеров различными методами указывает на правильность кластеризации. На практике при больших объемах данных наиболее удобным является последний способ

Примеры:

Метод ближайшего соседа - иерархический агломеративный метод. В качестве расстояний между кластерами выбирается расстояние между двумя наиболее близкими объектами. Метрика - величина, обратная расстоянию Чебышева. В результате выделяются длины (волокнистые кластеры). Как правило, используется для описания родственно видовых связей

Метод удаленного соседа - альтернативный метод метода ближайшего соседа. Это иерархический агломеративный метод. Метрика - расстояние Чебышева. Результат работы - кластеры объектов из разных роц, значимо различающиеся хотя бы по одному признаку. Подходит для классификации облака точек Достоинства этих методов: простота реализации, возможность кластеризации при отсутствии сведений о количестве кластеров Недостатки: избирательная применимость в различных задачах.

Метод k-средних - неиерархический, работает с большими объемами данных. Предполагает наличие гипотезы о потенциальном числе кластеров. Гипотеза строится на основе предположения исследователя или на основе интуитивной оценки.

ДЛЯ ПРИМЕРА МОЖНО ВЗЯТЬ ЛАБУ ПО НЕЙРОНКАМ

Метод K-средних (K-means). Кластеры представлены в виде центроидов, являющихся «центром массы» всех объектов, входящих в кластер. В отличие от иерархических методов, которые не требуют предварительных предположений относительно числа кластеров, для возможности использования этого метода необходимо иметь гипотезу о наиболее вероятном количестве кластеров. Алгоритм k-средних предполагает построение k кластеров, расположенных на возможно больших расстояниях друг от друга. Основной тип задач, которые решает алгоритм k-средних – наличие предположений (гипотез) относительно числа кластеров, при этом они должны быть различны настолько, насколько это возможно. Выбор числа k может базироваться на результатах предшествующих исследований, теоретических соображениях или интуиции. Общая идея алгоритма: заданное фиксированное число k кластеров наблюдения сопоставляются кластерам так, что средние в кластере (для всех переменных) максимально возможно отличаются друг от друга.

Метод Варда Метод Варда является иерархическим агломеративным методом. В качестве начальных центроидов выступают все объекты выборки. В качестве расстояния между кластерами берется прирост суммы квадратов расстояний объектов до центров кластеров, получаемый в результате их объединения. В отличие от других методов кластерного анализа для оценки расстояний между кластерами, здесь используются методы дисперсионного анализа. На каждом шаге алгоритма объединяются такие два кластера, которые приводят к минимальному увеличению целевой функции, т.е. внутригрупповой суммы квадратов. Этот метод направлен на объединение близко расположенных кластеров и "стремится" создавать кластеры малого размера.

Метод ближайшего соседа Метод также встречается под названием «Одиночная связь» и является иерархическим агломеративным методом. Здесь расстояние между двумя кластерами определяется расстоянием между двумя наиболее близкими объектами (ближайшими соседями) в различных кластерах

Метод наиболее удаленного соседа. Метод также встречается под названием «Полная связь» и является иерархическим агломеративным методом. Здесь расстояния между кластерами определяются наибольшим расстоянием между любыми двумя объектами в различных кластерах (т.е. "наиболее удаленными соседями")

31. Факторный анализ. Пример.

При исследовании сложных объектов и систем часто невозможно непосредственно измерить величины, определяющие свойства этих объектов (**факторы**), а иногда неизвестны содержание и смысл факторов. Для измерений доступны только величины в той или иной степени, зависящие от факторов.

При этом, когда влияние неизвестного фактора проявляется в нескольких измеряемых признаках, эти признаки могут обнаруживать тесную связь между собой (коррелированность), поэтому общее число факторов может быть гораздо меньшим, чем число измеряемых переменных, которое обычно выбирается исследователем произвольно.

Цель факторного анализа: компактное всестороннее описание объекта исследования и выявление скрытых переменных факторов, отвечающих за наличие линейных статистических корреляций между наблюдаемыми переменными и, как следствие, сокращение количества переменных. В один фактор объединяются сильно коррелирующие между собой переменные, как следствие происходит перераспределение дисперсии между компонентами и получается максимально простая и наглядная структура факторов

$$Y_j = \sum_{i=1}^n a_{ij} x_i$$

Для обнаружения влияющих на измеряемые переменные факторов используются методы факторного анализа - выделение из множества измеряемых характеристик объекта новых факторов, более адекватно отражающих свойства объекта.

Выбор новых признаков, которые являются линейными комбинациями прежних и “вбирают” в себя большую часть общей изменчивости наблюдаемых данных, а поэтому передают большую часть информации, заключенной в первоначальных наблюдениях. Обычно для этого используют **метод главных компонент**. Этот метод сводится к выбору новой ортогональной системы координат в пространстве наблюдений. В качестве первой главной компоненты избирают направление, вдоль которого массив наблюдений имеет наибольший разброс, последующая главная компонента выбирается таким образом, чтобы разброс наблюдений вдоль нее был максимальным и она была бы ортогональна другим компонентам, выбранным до нее.

Обязательные условия факторного анализа: все признаки должны иметь количественное выражение; число наблюдений должно значимо больше числа переменных; выборка должна быть однородна, то есть элементы ее принадлежат одной генеральной совокупности; исходные переменные должны иметь симметричные распределения; потенциальные факторы должны коррелировать в большей или меньшей степени

Исходные данные: результаты ежедневных наблюдений за развитием эпидемии за период с 1 по 28 марта, всего четыре выборки: - число заболевших нарастающим итогом (X); - число заболевших за сутки (X+); - число выздоровевших (Y); - число умерших (Z);

Для тестирования модели аналогичные данные, полученные в период с 29.03.20 по 4.04.20 В качестве дополнительных данных для анализа могут быть использованы данные по болеющим на текущий день, которые формируются как выборка X* с элементами $x^*i = x_i - (y_i + z_i)$, где x_i , y_i , z_i - соответственно элементы выборок X, Y, Z

Дата	X	Y	Z	Дата	X	Y	Z
1.03.2020	1	0	0	15.03.2020	63	0	0
2.03.2020	1	0	0	16.03.2020	93	0	0
3.03.2020	1	0	0	17.03.2020	114	0	0
4.03.2020	1	0	0	18.03.2020	147	0	0
5.03.2020	1	0	0	19.03.2020	199	0	1
6.03.2020	7	0	0	20.03.2020	253	0	4
7.03.2020	11	0	0	21.03.2020	306	0	7
8.03.2020	14	0	0	22.03.2020	367	0	9
9.03.2020	17	0	0	23.03.2020	438	0	17
10.03.2020	20	0	0	24.03.2020	495	0	22
11.03.2020	28	0	0	25.03.2020	655	2	29
12.03.2020	34	0	0	26.03.2020	840	3	35
13.03.2020	45	0	0	27.03.2020	1040	5	47
14.03.2020	59	0	0	28.03.2020	1265	7	64


Прогнозировать дальнейшее развитие процесса, оценив период пика заболеваемости и период устойчивого спада эпидемии в условной стране, обосновать выбор параметров модели.

I. Модельная выборка $\{X^o\}$ заболевших к i -ому дню, $i=1,2,\dots$ за весь период эпидемии:

$$\begin{cases} x^o(i) = (1 + \hat{k} - \hat{a}i)x^o(i-1), x^o(0) = 1, \hat{a}i \leq \hat{k} \\ x^o(i) = x^o(i-1), \hat{a}i > \hat{k} \end{cases}$$

Коэффициенты a , k вычисляются как коэффициенты линейной зависимости

$\frac{x(i)}{x(i-1)} = (-ai + K), K = 1 + k, x(0) = 1$ по методу наименьших квадратов или модифицированному методу моментов на основе статистических данных о заболевших в условной стране в течение двух недель.



II. Модельная выборка $\{Z^o\}$ умерших к i -ому дню, $i=1,2,\dots$ за весь период эпидемии

$$z^o(i) = d \cdot x^o(i)$$

Коэффициент d вычисляется как коэффициент линейной зависимости $z(i) = dx(i)$ по модифицированному методу моментов на основе статистических данных о заболевших в условной стране в течение двух недель

$$\hat{d} = \sum_{i=m}^n z^o(i) / \sum_{i=m}^n x^o(i) \approx 0,008$$

III. Модельная выборка $\{Y^o\}$ выздоровевших к i -ому дню, $i=1,2,\dots$ за весь период эпидемии:

$$\begin{cases} 0, & i < \hat{l} \\ y^o(i) = x^o(i - l) - z^o(i), & i \geq \hat{l} \end{cases}$$

IV. Выборка заболевших в течение всей эпидемии может быть описана на основе функции $x(i) = \gamma - e^{-(\alpha i)^\beta}$

Коэффициенты функции α, β, γ могут быть оценены по модифицированному методу моментов (используются для оценки первый начальный, второй центральный и третий начальный моменты).

V. Выборка ежедневно заболевавших в течение всей эпидемии может быть описана как производная $x'(i) = \alpha\beta(\alpha i)^{\beta-1} e^{-(\alpha i)^\beta}$. По этой функции оценивается максимум и минимум функции, которые интерпретируются как пик заболевания и его спад.

32. Дискриминантный анализ. Пример

Пусть имеется совокупность объектов, разбитую на несколько групп (для каждого объекта можно сказать, к какой группе он относится). Пусть для каждого объекта имеется несколько количественных характеристик. Требуется найти группу, к которой принадлежит объект. Это позволит для новых объектов из этой же совокупности предсказывать группы, к которой они относятся.

Для решения этой задачи применяются **методы дискриминантного анализа**, которые позволяют строить функции измеряемых характеристик, значения которых и объясняют разбиение отрезков на группы. Желательно, чтобы этих функций (дискриминирующих признаков) было немного - в этом случае результаты легче истолковать.

Особую роль играет **линейный дискриминантный анализ**, в котором классифицирующие признаки выбираются как линейные функции от первичных признаков. (Здоров пациент, либо болен)

С облака: Дискриминантный анализ – раздел вычислительной математики, представляющий набор методов статистического анализа для решения задач распознавания образов, который используется для принятия решения о том, какие переменные разделяют (т.е. «дискриминируют») возникающие наборы данных (так называемые «группы»).

В отличие от кластерного анализа в дискриминантном анализе группы известны априори. Дискриминантный анализ вычислительно прост, особую роль имеет линейный ДА (дискриминантная функция описана плоскостью). ЛДА не так, как другие методы ДА, чувствителен к количеству признаков, но при небольшом их числе (1-3) результаты ЛДА легче интерпретировать.

Часто бывает затруднительно сравнивать объекты по измеряемым характеристикам. Нужен один обобщенный признак, который вбирает в себя оценки всех прочих признаков. Часто в качестве исходных данных используются не сами характеристики, а результаты их ранжирования. Такие методы относятся к не метрическим (можно не изменять характеристику, а указать результаты сходства, различия объектов (???)). Такой метод называется **методом многомерного шкалирования**.

Многомерное шкалирование

Метод можно рассматривать как альтернативу факторному анализу, в котором достигается сокращение числа переменных, путем выделения непосредственно не наблюдаемых факторов, объясняющих связи между наблюдаемыми переменными.

Цель многомерного шкалирования – поиск и интерпретация латентных переменных, дающих возможность пользователю объяснить сходства между объектами, заданными точками в исходном пространстве признаков. Показателями сходства объектов на практике могут быть расстояния или степени связи между ними.

В факторном анализе сходства между переменными выражаются с помощью матрицы коэффициентов корреляций. В многомерном шкалировании в качестве исходных данных можно использовать произвольный тип матрицы сходства объектов: расстояния, корреляции и т.д.

Многомерное шкалирование применимо, если задана матрица попарных сходств объектов. Существенно то, что многомерное шкалирование можно применять к любым типам расстояний или сходств. Основное предположение многомерного шкалирования заключается в том, что существует некоторое метрическое пространство существенных базовых характеристик, которые неявно и послужили основой для полученных эмпирических данных о близости между парами объектов. Следовательно, объекты можно представить как точки в этом пространстве. Предполагают также, что более близким (по исходной матрице) объектам соответствуют меньшие расстояния в пространстве базовых характеристик.

Поэтому, многомерное шкалирование – это совокупность методов анализа эмпирических данных о близости объектов, с помощью которых определяется размерность пространства существенных для данной содержательной задачи характеристик измеряемых объектов и конструируется конфигурация точек (объектов) в этом пространстве.

Это пространство («многомерная шкала») аналогично обычно используемым шкалам в том смысле, что значениям существенных характеристик измеряемых объектов соответствуют определенные позиции на осях пространства.

Пример

Предположим, что имеется матрица попарных расстояний (т.е. сходства некоторых признаков) между некоторыми городами. Анализируя матрицу, надо расположить точки с координатами городов в двумерном пространстве (на плоскости), максимально сохранив реальные расстояния между ними. Полученное размещение точек на плоскости впоследствии можно использовать в качестве приближенной географической карты. В общем случае многомерное шкалирование позволяет таким образом расположить объекты (города в нашем примере) в пространстве некоторой небольшой размерности (в данном случае она равна двум), чтобы достаточно адекватно воспроизвести наблюдаемые расстояния между ними. В результате можно измерить эти расстояния в терминах найденных латентных переменных. Так, в нашем примере можно объяснить расстояния в терминах пары географических координат Север/Юг и Восток/Запад

33. Анализ временных рядов. Основные задачи и методы.

Временной ряд - совокупность последовательных измерений значений переменной (процесса), произведенных через определенные (чаще равные) значения параметра (обычно времени). Если измеряемые значения являются многомерными, то временной ряд также называется многомерным. Для анализа полученных таким образом данных используется область статистики, называемая анализом временных рядов.

АВР используется для решения следующего класса задач:

- * для построения математической модели процесса, представленного временным рядом;
- * для исследования структуры временного ряда (для выявления изменения среднего уровня значений - тренда - и обнаружения периодических колебаний);
- * для прогнозирования будущего развития процесса, представленного временным рядом;
- * для исследования взаимодействия между различными временными рядами и пр.

Для решения этих и других задач используются:

- методы корреляционного анализа (позволяют выявить наиболее существенные периодические зависимости и их лаги - задержки в одном процессе или между несколькими процессами);
- методы спектрального анализа (позволяют находить периодические и квазипериодические зависимости в данных);
- методы сглаживания и фильтрации предназначены для преобразования временных рядов с целью удаления из них выбросов;
- методы авторегрессии и скользящего среднего (для описания и прогнозирования процессов, проявляющих однородные колебания вокруг среднего значения)

34. Планирование эксперимента. История развития научного направления.

Планирование эксперимента (experimental design techniques) – комплекс мероприятий, направленных на эффективную постановку опытов.

Основная **цель** планирования эксперимента – достижение максимальной точности измерений при минимальном количестве проведенных опытов и сохранении статистической достоверности результатов.

Таким образом, планирование эксперимента применяется при поиске оптимальных условий развития процесса, решении задач аппроксимации, выборе значимых факторов, оценке и уточнении констант теоретических моделей и др.

Решение задач теории планирования эксперимента предусматривает использование априорной информации об изучаемом процессе для выбора общей последовательности управления экспериментами, которая уточняется после очередного этапа проведения исследований на основе вновь полученных сведений. Тем самым достигается возможность рационального управления экспериментами при неполном первоначальном знании характеристик исследуемого объекта. Процедуры планирования эксперимента целесообразно применять в случае моделирования сложных систем.

Планирование эксперимента возникло как научное направление в 20-х гг XX века на основе работ Фишера (Design of experiments). Ряд исследователей: Кишен, Манн, Бойс, Гёлс, Рао и другие обосновали практические достижения Фишера и оптимизировали их. С конца 40-ых, начала 50-ых гг планирование эксперимента активно развивалось в США: Бокс, Уилсон, Юл и другие революционно упростили подход к решению задачи планирования эксперимента сводя их к степенным разложениям и методу наименьших квадратов.

Развитие теории планирования эксперимента получило развитие в категории ядерной техники (Соколов, Федоров). После чего распространилось во всех сферах науки и промышленности. Тогда же появились монографии по планированию эксперимента (Адлер, Вороновский, Маркова).

35. Планирование эксперимента. Факторные планы, дробные факторные планы. (см 34)

В ТПЭ исследуемый объект (реальный объект, модель объекта) рассматривается как "черный ящик", имеющий входы v (управляемые независимые параметры) и выходы y . Переменные v принято называть **факторами**. Предполагается активный тип экспериментов, когда имеется возможность независимо и целенаправленно менять значения факторов v во всем требуемом диапазоне.

Факторы в эксперименте бывают **качественными** и **количественными**. **Качественные факторы** можно квантифицировать или приписать им числовые обозначения, тем самым перейти к количественным значениям. В дальнейшем будем считать, что все факторы являются количественными и представлены непрерывными величинами (если другое не оговорено особо).

Переменным v можно сопоставить геометрическое понятие **факторного пространства** – пространства, координатные оси которого соответствуют значениям факторов. Совокупность конкретных значений всех факторов образует точку в многомерном факторном пространстве. На объект или систему могут влиять возмущающие факторы, но они являются случайными и не поддаются управлению.

Область планирования задается интервалами возможного изменения факторов v_i , $\min v_i < v_i < \max v_i$ для $i = 1, 2, \dots, k$, где k – количество факторов.

В теории планирования экспериментов часто используют нормализацию факторов, т.е. преобразование натуральных значений факторов в безразмерные (кодированные) величины. Переход к безразмерным значениям x_i задается преобразованием $x_i = (v_i - v_{i0})/v_i$, где v_i – натуральное значение фактора, v_{i0} – натуральное значение основного уровня фактора, соответствующее нулю в безразмерной шкале, v_i – интервал варьирования.

Совокупность основных уровней всех факторов представляет собой точку в пространстве параметров, называемую центральной точкой плана или центром эксперимента.

План эксперимента – совокупность данных, определяющих количество, условия и порядок реализации опытов.

Опыт – воспроизведение исследуемого явления в конкретных условиях с последующей регистрацией результата. В условиях случайности в одних и тех же условиях проводятся параллельные (повторные) опыты в интересах получения статистически устойчивых результатов.

Опыт u предполагает задание конкретных значений факторам v : $u = v_{1u}, v_{2u}, \dots, v_{ku}$, а совокупность значений факторов во всех N точках плана эксперимента образует матрицу плана $[v_{11}, v_{21}, \dots, v_{k1}; v_{12}, v_{22}, \dots, v_{k2}; \dots v_{1N}, v_{2N}, \dots, v_{kN}]$. Строки матрицы соответствуют опытам, столбцы – факторам, элемент матрицы v_{iz} задает значение z -го фактора в i -м опыте. Различают полный и дробный факторные планы.

Полный факторный план содержит все возможные комбинации всех факторов на определенном числе уровней равное число раз. С ростом числа факторов число опытов растет по показательному закону.

Дробный факторный план содержит часть комбинаций полного факторного плана. Строится в соответствии с критериями оптимальности планов.

36. Планирование эксперимента. Критерии оптимальности планов. Свойства планов.
(см 34)

Критерии оптимальности: В настоящее время используется свыше двадцати различных критериев оптимальности планов, которые подразделяются на две основные группы. К первой группе относят критерии, связанные с ошибками оценок коэффициентов, а ко второй – с ошибкой оценки поверхности отклика.

Критерии первой группы представляют интерес для задач оптимизации, выделения доминирующих (наиболее значимых) параметров на начальных этапах решения оптимизационных задач или для выявления несущественных параметров в задачах восстановления закономерности функционирования объекта. Геометрическое истолкование свойств ошибок коэффициентов связано со свойствами эллипсоида их рассеяния, определяемого математическим ожиданием и дисперсией значений ошибок. Пространственное расположение, форма, и размер эллипсоида полностью зависят от плана эксперимента.

Критерию D-оптимальности соответствует минимальный объем эллипсоида рассеяния ошибок (минимум произведения всех дисперсий коэффициентов полинома). В соответствующем плане эффекты факторов максимально независимы друг от друга. Этот план минимизируют ожидаемую ошибку предсказания функции отклика.

Критерию A-оптимальности соответствует план с минимальной суммарной дисперсией всех коэффициентов.

Критерию E-оптимальности – план, в котором максимальная дисперсия коэффициентов будет минимальна.

Выбор критерия зависит от задачи исследования, так при изучении влияния отдельных факторов на поведение объекта применяют критерий E-оптимальности, а при поиске оптимума функции отклика – D-оптимальности. Если построение D-оптимального плана вызывает затруднения, то можно перейти к A-оптимальному плану, построение которого осуществляется проще.

Критерии второй группы используются при решении задач описания поверхности отклика, определения ограничений на значения параметров. Основным здесь является **критерий G-оптимальности**, который позволяет построить план с минимальным значением наибольшей ошибки в описании функции отклика. Применение G-оптимального плана дает уверенность в том, что в области планирования нет точек с чрезмерно большой ошибкой описания функции.

Свойства планов: Предпочтение отдается планам, обладающим свойствами ортогональности, ротатабельности, в ряде случаев – композиционности и другими.

Ортогональным называется план, для которого выполняется условие парной ортогональности столбцов матрицы планирования, в частности, для независимых переменных, где N – количество точек плана эксперимента, k – количество независимых факторов.

При ортогональном планировании коэффициенты полинома определяются независимо друг от друга – вычеркивание или добавление слагаемых в функции отклика не изменяет значения остальных коэффициентов полинома. Для ортогональных планов эллипсоид рассеяния ориентирован в пространстве так, что направления его осей совпадают с направлениями координат пространства параметров.

Использование **ротатабельных** планов обеспечивает для любого направления от центра эксперимента равнозначность точности оценки функции отклика (постоянство дисперсии предсказания) на равных расстояниях от центра эксперимента. Это особенно важно при решении задач поиска оптимальных значений параметров на основе градиентного метода, так как исследователь до начала экспериментов не знает направление градиента и поэтому стремится принять план, точность которого одинакова во всех направлениях.

В ряде случаев при исследовании поверхности отклика требуется **униформность модели**, а именно, соблюдение постоянства значений дисперсии ошибки в некоторой области вокруг центра эксперимента. Выполнение такого требования целесообразно в тех случаях, когда исследователь не знает точно расположение области поверхности отклика с оптимальными значениями параметров. Указанная область будет определена на основе упрощенной модели, полученной по результатам экспериментов.

Для некоторых планов важную роль играет свойство **композиционности**. Так, композиционные планы для построения полиномов второго порядка получают добавлением некоторых точек к планам формирования линейных функций. Это дает возможность в задачах исследования сначала попытаться построить линейную модель, а затем при необходимости, добавив наблюдения, перейти к моделям второго порядка, используя ранее полученные результаты и сохраняя при этом некоторое заданное свойство плана, например его ортогональность

37. Методика построения аналитической статической модели.

Статические модели

Статические модели активно применяются при сравнении «срезов», полученных в разные моменты времени той или иной динамической модели. Как правило, статические модели используются в случае сложности динамических, а также для наглядности представления. В качестве примеров статических моделей можно привести принципиальные схемы устройств, перечень объектов с указанием характеристик (макет Солнечной системы), цифровые карты местности, модели поверхностей и другие.

Статическая модель может оказаться лишь иллюстративной частью проекта, использующего физическую модель исследуемого объекта или его динамическую математическую модель.

Методика построения статической модели

1. рисуется графическая схема, иллюстрирующая состояние системы в некоторый момент времени в заданной системе координат;

2. по схеме уточняются входные данные (например: матрица высот), уточняется погрешность представления измеряемой координаты. Выделяются промежуточные переменные, по которым будут оценены выходные, и непосредственно выходные данные. На схеме выделяется зависимость исследуемого показателя от остальных хар-к.




Рис. 1:

В отличие от динамической модели, параметры статической на начальном этапе моделирования не так очевидны, и могут быть оценены по результатам вспомогательных задач.

3. определяются физико-химические воздействия на объект, переводящие в данный момент систему из предыдущего в текущее состояние;

4. оценивается возможность формализации модели и её упрощения. Необходимо обосновать возможность описания и целесообразность учета выбранных на предыдущем этапе физико-химических воздействий на исследуемый объект. Если в динамических моделях большее значение имеет учет физических воздействий, то в статических — химических воздействий;

5. формулируется на языке математики общее уравнение, описывающее состояние объекта в заданный период времени, с учетом выделенных физико-химических воздействий;

6. конкретизируется описание состояния объекта, однозначно выделяются входные, выходные, промежуточные переменные, а также параметры модели;

7. при формализации модели должно выполняться условие единственности решения, в силу чего ряд входных данных может быть доопределен, либо исключен.

Если динамическая модель сложна, то часто выделяют состояние системы, вносящее значительный вклад в решение задачи. В этом случае динамическую систему моделируют с помощью конечного числа статических систем. Динамическое моделирование ресурсозатратно, но дает более точное представление о развитии процесса реального мира. Статическое моделирование описывает процесс дискретно, то есть не дает полной картины его развития. При этом демонстрирует качественное (а не количественное) решение при низкой ресурсозатратности.

38. Методика построения аналитической динамической модели.

Динамическая модель отражает изменение состояния исследуемой системы или объекта в заданный или формируемый период времени. Примером динамической модели является баллистическая модель.

Методика динамической модели:

1. Оценивается постановка задачи и процесс изменения объекта во времени иллюстрируется графической схемой в начальный t_0 , в некоторый фиксированный t^* , в конечный момент времени T . Для описания процесса может быть также построена диаграмма в выбранной графической нотации.

2. По схеме уточняются и обозначаются начальные и конечные входные данные, выходные данные полученные в процессе моделирования, выделяются переменные, которые являются выходными на одном этапе решения задачи и выходными на другом;

3. Определяются физико-химические воздействия на объект, влияющие на изменения выходных данных;

4. Оценивается возможность упрощения модели, ряд воздействий не учитывается;

5. Проводится формализация модели – с учетом известных формул описываются учитываемые воздействия и составляется общее уравнение (равенство, неравенство, система уравнений и т.п.), связывающее входные и выходные данные (в левой и правой части уравнения - величины одинаковой размерности).

6. Конкретизируется описание каждого отдельного воздействия.

7. Повторно оценивается возможность упрощения модели, так как число неизвестных не должно превышать числа уравнений в системе, уточняются значения коэффициентов и констант (в т.ч. начальных, конечных значений переменных), входящих в описание.

39. Методика построения имитационной модели систем массового обслуживания.

В отличие от процесса моделирования статических или простых динамических систем, в имитационном моделировании участвует несколько специалистов (а, в ряде случаев, структурных подразделений). Различают квалификации специалистов предметной области, математиков и IT-специалистов.

Пункты методики:

1. постановка задачи в терминах предметной области, классификация сложной динамической системы (структурно-сложная, меняющая поведение во времени, гибридная и др.);
 2. построение структурной схемы исследуемой системы с целью выделения компонент и определения взаимодействия между ними;
 3. по схеме уточняются известные входные данные, параметры системы, определяются неизвестные промежуточные переменные, выходные данные, определяются ограничения, обратная (положительная или отрицательная) связь, управляющие воздействия на систему, начальные и краевые условия задачи. На этом этапе модель окончательно классифицируется как сложная, предварительно выбирается схема организации квазипараллелизма модели;
 4. вместе со специалистом в предметной области строится концептуальная модель исследуемой системы;
 5. преобразование концептуальной модели в имитационную;
 6. уточнение значений входных переменных и параметров системы или получение методики оценивания этих значений;
 7. формализация модели;
 8. отладка модели на ЦВМ;
 9. счет по программе;
 10. проверка качества модели на практике, оценка необходимости модификации модели;
 11. совместно со специалистами предметной области и IT-специалистами выявляются «узкие места» модели.
- Для сокращения обсуждения уточнение модели проводится начиная с этапа концептуального проектирования.
- В редких случаях дефект может быть уже на этапе описания предметной области (первый пункт).
12. проведение вычислительного эксперимента с использованием построенной математической модели.

Для этапа построения концептуальной модели:

СМО (системы массового обслуживания) - системы, функционирование которых заключается в обработке большого числа заявок. Система с накопителем — СМО с ожиданием, система с потерями — СМО с отказами.

Заявка — транзакт, очередь — канал обслуживания заявки, устройство — то/кто обслуживает заявки, приоритетное обслуживание.

Пропускная способность СМО: характеризуется средним временем нахождения в системе и интенсивностью выходного ... заявок. Задержка — время проведенное заявкой в ожидании обслуживания. Интенсивность входного потока (λ) — среднее число заявок поступающее в СМО в единицу времени (в генераторе — распределения Пуассона). Если источник входного потока расположен вне системы то СМО — открытая, а если заявка снова возвращается в поток — закрытая.

(22 вопрос)

40. Методика построения имитационной стохастической модели.

В отличие от процесса моделирования статических или простых динамических систем, в имитационном моделировании участвует несколько специалистов (а, в ряде случаев, структурных подразделений). Различают квалификации специалистов предметной области, математиков и IT-специалистов.

Пункты методики:

1. постановка задачи в терминах предметной области, классификация сложной динамической системы (структурно-сложная, меняющая поведение во времени, гибридная и др.);
 2. построение структурной схемы исследуемой системы с целью выделения компонент и определения взаимодействия между ними;
 3. по схеме уточняются известные входные данные, параметры системы, определяются неизвестные промежуточные переменные, выходные данные, определяются ограничения, обратная (положительная или отрицательная) связь, управляющие воздействия на систему, начальные и краевые условия задачи. На этом этапе модель окончательно классифицируется как сложная, предварительно выбирается схема организации квазипараллелизма модели;
 4. вместе со специалистом в предметной области строится концептуальная модель исследуемой системы;
 5. преобразование концептуальной модели в имитационную;
 6. уточнение значений входных переменных и параметров системы или получение методики оценивания этих значений;
 7. формализация модели;
 8. отладка модели на ЦВМ;
 9. счет по программе;
 10. проверка качества модели на практике, оценка необходимости модификации модели;
 11. совместно со специалистами предметной области и IT-специалистами выявляются «узкие места» модели.
- Для сокращения обсуждения уточнение модели проводится начиная с этапа концептуального проектирования.
- В редких случаях дефект может быть уже на этапе описания предметной области (первый пункт).
12. проведение вычислительного эксперимента с использованием построенной математической модели.

Для этапа построения концептуальной модели:

Стохастическая модель - такая модель, входными и выходными данными которой являются случайные величины, а преобразование входных данных в выходные осуществляется посредством случайной функции (процесса).

если стохастическая - то статистическая, вероятностная или феноменологическая.

Если модель основана (базируется) на основной задаче теории вероятности, то речь идет о **вероятностной модели**

Если на одной из трех задач математической статистики — то о **статистической**.

Отдельно выделяют класс **феноменологических моделей**, построенных на результатах конкретного(уже оконченного) эксперимента.

Основная задача теории вероятности - поиск вероятности в схеме Бернулли

Основные задачи математической статистики:

- точечное оценивание параметров распределения характеристики объекта
- интервальное оценивание (построение доверительных интервалов) для параметров распределения характеристики объекта
- проверка статистических гипотез

Статистической гипотезой H называют любое утверждение относительно функции распределения $F(x)$ некоторой СВ x , касающейся типа ФР, значения ее параметров и т.д.

Гипотезы H проверяют путем сопоставления выдвинутых предположений с результатами эксперимента, который в статистике представляет собой n независимых наблюдений над СВ x , то есть выборку $x_1, \dots, x_n$, где $x_i, i = 1, \dots, n$ - независимые одинаково распределенные СВ, каждая с ФР $F(x)$.

Гипотезу называют **простой**, если ее условиям удовлетворяет единственная ФР $F(x)$, в противном случае - гипотеза сложная

Гипотеза, справедливость которой проверяется в ходе эксперимента называется **основной** или **нулевой** гипотезой H_0 .

В зависимости от того, какие отклонения от H_0 возможны, формулируют альтернативные (конкурирующие) гипотезы H_1 .

Статистические гипотезы проверяют с помощью статистических критериев.

Статистический критерий - это совокупность правил, позволяющих по полученной выборке принять H_0 или отвергнуть гипотезу H_1 .

(15 вопрос)